일반국민/대학(원)생 부문

제 6 회 K-인공지능 제조데이터 분석 경진대회 보고서

프로젝트명	**사출성형 공정데이터 기반 품질불량 위험 예측 및 검사 우선순위 결정**
팀명	j2tori
내용요약	- 최종모델(Extra Trees + 추정 캐비티)의 PR-AUC 0.121 로 무작위의 6.9 배, 보정 확률 기준 위험 등급의 실제 불량률이 정상 등급의 24 배이며, 제품별 상위 20%만 검사해도 CN7 불량 12/13 건을 포착함(개발셋 OOF 합산) - 사출성형 데이터(라벨 2,393 건, 불량 42 건·1.8%)에서 공정값이 같은 행을 한 번의 사출로 묶는 구조를 복원하고(교차 기록된 짝 포함), 불량의 86%가 그룹의 첫 행(추정 캐비티 0)에 몰린 현상을 확인함 - 모든 분할을 사출 그룹 단위로 설계해 누수를 막고(행 단위 검증 대비 과대평가 52% 차단), 무작위 사출 그룹 CV · 생산순번 블록 CV · 과거→미래 대리 검증으로 성능 범위를 제시함 - 모델 7 종 × 특성셋 2 종을 같은 25 개 fold 에서 비교하고 사전 규칙대로 최종모델을 선정함(fold 평균 Recall@20% 0.700, 운영 기준 F1@20% 1 위) - 운영안: 제품별 상위 k% 검사, 위험등급별 조치, 가동 초기 강화검사 규칙, 공정 흔들림 사전경보, 무작위 표본 검사 모니터링. RG3 는 공정변수 외 정보(캐비티별 센서)가 필요해 기존 검사를 병행함

상기 본인(팀)은 위의 내용과 같이 제 6 회 K-인공지능 제조데이터 분석 경진대회 결과 보고서를 제출합니다.

2026 년 10 월 8 일

팀장 : 전건우 (서명)

(사)중소기업기술혁신협회 귀중

□ 제 1 장. 데이터 이해 및 진단 〔15 점〕

◦ 현장 문제 정의

구분	내용
문제	최종검사에서야 불량을 확인하므로 선제 대응이 어렵고, 검사 자원이 모든 제품에 같은 비율로 투입됨
예측 시점	사출이 끝난 뒤, 품질검사 전. 사이클·충전 시간, 최대 사출압, 쿠션 위치 등은 사출 중·후에 확정되는 값이므로 사출 전 예측은 아님
목표	① 제품별 위험점수 산출 ② 같은 검사 용량에서 불량 포착률 향상 ③ 오류 조건 파악과 현장 운영 규칙 도출
역할	기존 품질검사를 대체하지 않고, 한정된 검사 용량을 어디에 먼저 쓸지 정하는 검사 보조 도구

◦ 데이터 개요

파일	행 수	공정변수	불량(비율)	활용
moldset_labeled_cn7	1,211	24	17 (1.4%)	학습·평가
moldset_labeled_rg3	1,182	24	25 (2.1%)	학습·평가
moldset_unlabeled_cn7	35,239	24	-	결합 가능성 진단
moldset_unlabeled_rg3	35,941	24	-	결합 가능성 진단

◦ 데이터 정의와 확인 수준

항목	내용	근거
행 단위	성형품 1 개. 공정값이 같은 2 행은 한 번의 사출에서 나온 제품 2 개로 봄	추정 (사출 번호 컬럼 없음)
타깃	PassOrFail. 소수 클래스 1 을 불량으로 봄	확인 필요 (데이터 설명서)
생산 순번	이름 없는 첫 열. CN7 0~1210, RG3 1211~2392, 누락 없음	확인 (실제 시각 없음)
공정변수 24 개	시간·위치·속도·압력·온도 (아래 표)	변수명 기준 추정, 단위 미상
값의 척도	모든 파일이 평균 0, 표준편차 1 근처	파일별 표준화로 추정
사출·캐비티 번호	원본에 없어 공정값으로 추정	설비 기록 확인 필요

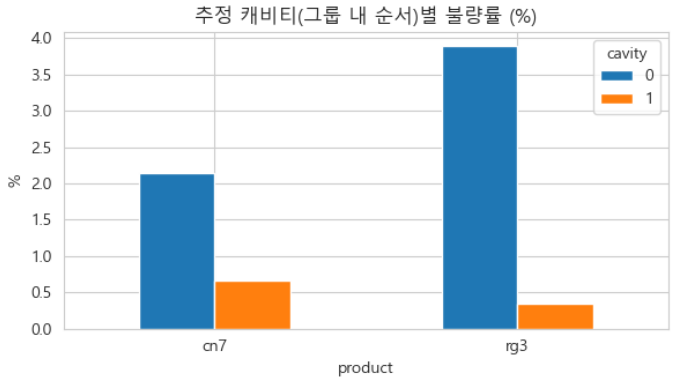
구분	변수	공정 의미 (추정)	사출 단계
시간	Injection·Filling·Plasticizing·Cycle·Clamp_Close_Time	사출·충전·가소화·사이클·형체 시간	충전, 가소화, 형개폐
위치	Cushion·Plasticizing·Clamp_Open_Position	쿠션량·계량 위치·형개 위치	보압, 가소화, 형개폐
속도	Max_Injection_Speed, Max/Average_Screw_RPM	사출 속도·스크류 회전	충전, 가소화
압력	Max_Injection·Switch_Over·Back_Pressure 등	사출압·V/P 전환압·배압	충전, 보압, 가소화
온도	Barrel_Temperature_1~6, Hopper, Mold_3·4	실린더·호퍼·금형 온도	가소화, 냉각

◦ 추정 사출 그룹 구조

- 연속한 행의 공정값 24 개가 완전히 같으면 한 번의 사출에서 나온 제품 2 개로 보고 같은 그룹으로 묶음. 이 규칙만 쓰면 짝이 없는 1 행 그룹이 CN7 71 개, RG3 34 개 생기는데, 이 중 104 개는 2~5 행 떨어진 곳에 공정값이 완전히 같은 짝이 있음. A·B·A·B 처럼 교차 기록된 사출로 보고 같은 그룹으로 병합함

제품	연속 2 행	연속 규칙상 1 행	교차 짝 병합	최종 그룹 수	순번 누락	추정 캐비티 0 불량률	추정 캐비티 1 불량률
CN7	570	71	35 쌍	606	0	2.1% (13 건)	0.7% (4 건)
RG3	574	34	17 쌍	591	0	3.9% (23 건)	0.3% (2 건)

- 불량 42 건은 모두 연속 2 행 그룹에 있고, 36 건(86%)이 그룹의 첫 행(추정 캐비티 0)에서 나옴. 한쪽 캐비티에 불량이 몰렸을 가능성이 있으나, 행 순서가 실제 캐비티 위치와 같은지는 확인할 수 없음



[그림 1-1] 제품·추정 캐비티별 불량률

* 공정값이 같은 두 행이 학습과 평가에 나뉘면 정답이 새므로, 이후 모든 분할은 이 그룹 단위로 함

◦ 데이터 품질 진단

항목	진단 결과	처리
결측	전 변수 결측 0 건	없음
상수 변수	Clamp_Open_Position 이 두 제품 모두 단일값	제거 (개발셋 기준으로 정하고 테스트에 같은 열 적용)
중복	공정값이 같은 행 대부분이 같은 사출 그룹의 짝	삭제하지 않고 그룹으로 묶어 검증 (삭제 시 불량 라벨 손실)
극단값 (|z|>4)	11 개 변수 88 행, 그중 불량 14 건 (불량률 16%)	삭제하지 않음 (가동 초기 불안정과 함께 나타나는 불량 신호)
라벨 충돌	같은 공정값에 양품·불량 공존: CN7 불량 11/17, RG3 25/25	삭제·수정하지 않고 예측 상한으로 해석
불균형	불량률 CN7 1.4%, RG3 2.1%	클래스 가중치 + PR-AUC 주지표
시간 분포	CN7 불량이 생산순번 47~120 에만 있음	가동 초기 불안정으로 보고 시간 검증 추가

- RG3 불량 25 건은 모두 공정값이 완전히 같은 양품이 존재함. 공정변수만 보는 모델은 이 둘을 구분할 수 없으므로 RG3 성능의 상한을 정하는 진단 결과임



[그림 1-2] 생산 순번별 불량 발생 위치 (위: CN7, 아래: RG3)

◦ 비라벨 데이터 결합 가능성 진단

실험	방법	결과
도메인 판별	라벨 행과 비라벨 행을 구분하는 분류기의 CV AUC (0.5 = 비슷한 분포)	CN7·RG3 모두 AUC 1.00. 파일별 순위 변환 후에도 같음
자기학습	라벨 모델이 비라벨에 매긴 점수 상·하위를 가짜 라벨로 추가해 재학습 (5-fold × 3 회)	PR-AUC 0.098 → 0.136~0.128, Recall@20% 0.617 → 0.512~0.649

- 자기학습으로 PR-AUC 가 올랐으나 Recall@20%는 설정에 따라 오르내림. 두 데이터가 완전히 구분될 만큼 분포가 달라 이 변화를 일반화된 개선으로 보기 어렵고, 분포 차이의 원인(기간, 조건, 전처리)도 확인되지 않아 비라벨 데이터는 학습에 넣지 않음. 비라벨은 분포 진단과 운전구간 군집에만 사용함

◦ **전처리 및 검증 전략**

- 전처리: 상수 변수 제거, 추정 사출 그룹·추정 캐비티 생성, 제품 구분 변수(is_rg3) 추가, 로지스틱 회귀에만 표준화 적용
- 분할: 사출 그룹·불량 층화로 테스트셋 20%(484 행, 불량 8 건) 분리. 개발셋 1,909 행(불량 34 건)에서 모든 실험 수행

검증	분할 방식	보는 것	한계
① 무작위 사출 그룹 CV (주 검증)	5-fold × 5 회, 사출 그룹 단위	같은 기간 안의 일반화	같은 시기 이웃 사출이 학습에 들어가 낙관적일 수 있음
② 생산순번 블록 CV	연속 구간 8·16 개를 통째로 평가	같은 시기 사출을 뺐을 때	평가 구간 뒤 데이터도 학습에 쓰임
③ 과거→미래 대리 검증	5 구간 expanding window	시간 순서를 지킨 운영 상황	생산 순번 기준, 불량 없는 구간은 평가 불가

- 입력 열 선택, 임계값, 확률 보정, 스태킹 메타 학습은 모두 각 학습 데이터 안에서만 정함. 홀드아웃·외부 CV·내부 3-fold·생산순번 블록의 모든 분할에서 같은 그룹이 양쪽에 들어가지 않음을 코드로 확인함(split_audit.csv)
- 평가지표: PR-AUC(주지표, 무작위 기준 = 불량률), Recall@k%(검사 용량 k%에서의 포착률), 운영점 F1@20%. 임계값 F1 은 참고용

□ 제 2 장. AI 예측모델 개발 및 성능평가 〔40 점〕

◦ 비교 모델 설계

모델	계열	불균형 처리	주요 설정
Logistic Regression	베이스라인 (선형)	class_weight=balanced	표준화, C=0.1
Random Forest	배깅	balanced_subsample	500 그루, min_samples_leaf=2
Extra Trees	배깅 (무작위 분할)	balanced_subsample	500 그루, min_samples_leaf=2
LightGBM	부스팅	is_unbalance	300 회, lr 0.03, leaves 15
XGBoost	부스팅	scale_pos_weight=50	300 회, depth 2, lr 0.03
CatBoost	부스팅	SqrtBalanced	300 회, depth 6, l2=10
RF + ET 앙상블	소프트 보팅	구성 모델 가중치	RF·ET 확률 평균

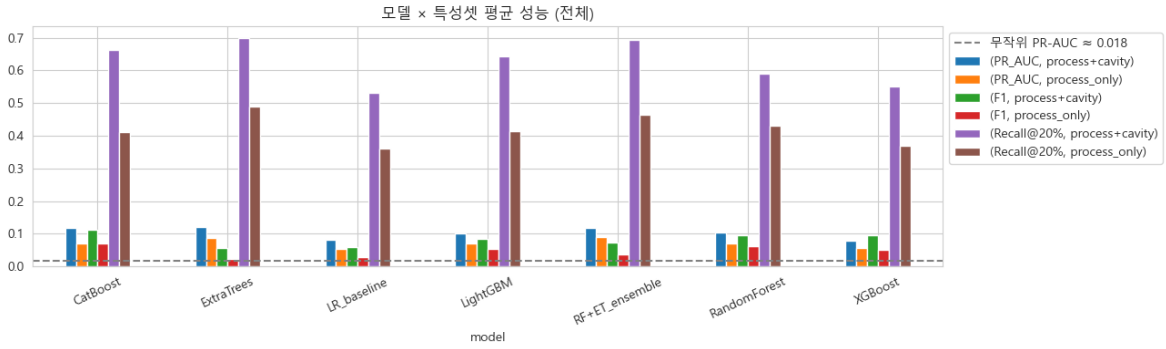
- 각 모델을 ① 공정변수만, ② 공정변수 + 추정 캐비티 두 특성셋으로 학습해 14 개 조합을 같은 25 개 fold 에서 비교함
- 최종모델 선정 규칙은 분석 전에 정함: 개발셋 CV 전체 PR-AUC 평균이 가장 높은 조합. 테스트셋은 선정에 쓰지 않음
- 하이퍼파라미터는 탐색하지 않고 과적합을 줄이는 값으로 고정함(위 표). fold 당 평가 불량이 6~7 건이라 내부 CV 로 조합을 고르면 선택이 잡음에 좌우되고(같은 조합의 fold 간 PR-AUC 표준편차 약 0.11), 불량 34 건으로 튜닝하면 검증 성능이 낙관적으로 부풀기 쉬움. 대신 모델 간 차이의 통계적 유의성을 함께 보고하고, 데이터가 늘면 중첩 그룹 CV 로 튜닝하는 것을 향후 과제로 둠

◦ 모델 비교 결과 (무작위 사출 그룹 CV, 공정변수 + 추정 캐비티)

모델	PR-AUC	ROC-AUC	F1	Recall@10%	Recall@20%	F1@20%
Extra Trees (최종)	**0.121±0.110**	**0.845**	**0.057**	**0.480**	**0.700**	**0.110**
RF + ET 앙상블	0.119±0.100	0.840	0.072	0.415	0.694	0.107
CatBoost	0.118±0.075	0.831	0.113	0.440	0.663	0.104
Random Forest	0.103±0.072	0.807	0.095	0.399	0.589	0.093
LightGBM	0.101±0.069	0.816	0.084	0.363	0.643	0.101
LR (베이스라인)	0.082±0.056	0.770	0.061	0.357	0.530	0.084
XGBoost	0.079±0.051	0.784	0.095	0.303	0.551	0.091

* Recall@k%·F1@20%는 25 개 평가 fold 각각에서 계산한 값의 평균(fold 평균). 4 장 검사 용량표는 개발셋 전체 OOF 점수를 제품별 상위 k%로 검사해 합산한 건수(OOF 합산)라 값이 조금 다름 (예: 상위 20% 검사 시 fold 평균 0.700, OOF 합산 22/34 = 64.7%)

* 무작위 PR-AUC = 불량률 0.018. 공정변수만 쓴 특성셋의 최고는 RF + ET 앙상블 0.092, 베이스라인 LR 0.053



[그림 2-1] 모델 × 특성셋별 평균 성능 (점선: 무작위 PR-AUC)

- 상위 3 개 조합의 PR-AUC 차이는 0.003 로, fold 간 표준편차보다 훨씬 작음. 배깅·앙상블 계열이 상위권이고 트리 모델은 모두 LR 베이스라인보다 높음
- 임계값 F1 은 선정에 쓰지 않음. fold 당 평가 불량이 6~7 건이라 학습 fold 안에서 고른 임계값이 평가 fold 에 잘 맞지 않아 모델 순위가 크게 흔들리기 때문임(최종모델 0.057, 범위 0.057~0.113). 검사량을 고정한 운영 기준 F1@20%에서는 최종모델이 0.110 로 14 개 조합 중 1 위임

◦ 제품별 성능

모델 (+추정 캐비티)	CN7 PR-AUC	CN7 ROC	CN7 Recall@20% (fold 평균)	RG3 PR-AUC	RG3 ROC	RG3 Recall@20% (fold 평균)
Extra Trees	**0.258**	**0.936**	**0.901**	**0.083**	**0.768**	**0.478**
RF + ET 앙상블	0.254	0.941	0.946	0.091	0.752	0.463
CatBoost	0.227	0.926	0.864	0.114	0.752	0.485
Random Forest	0.222	0.932	0.930	0.098	0.702	0.412
LightGBM	0.179	0.905	0.883	0.107	0.747	0.465

* CN7 은 일부 fold 에 불량이 없어 그 fold 는 CN7 지표 계산에서 빠짐 (N/A 로 기록)

◦ 최종모델 대비 유의성 검정

- 최종모델과 나머지 13 개 조합을 같은 fold 끼리 짝지어 Wilcoxon 부호순위 검정과 Nadeau-Bengio 보정 t-검정(반복 k-fold 의 학습 데이터 겹침 보정)으로 비교하고, 13 개 동시 비교이므로 Holm 보정 p 도 함께 제시함

비교 대상	PR-AUC 차이	승/패	보정 t p	Holm p	Recall@20% 차이	보정 t p	Holm p
RF + ET 앙상블	+0.002	15/10	0.872	1.000	+0.006	0.903	1.000
CatBoost	+0.003	14/11	0.944	1.000	+0.037	0.644	1.000
Random Forest	+0.018	17/8	0.695	1.000	+0.111	0.161	0.967
LR (베이스라인)	+0.040	20/5	0.316	1.000	+0.169	0.184	0.967
XGBoost	+0.043	18/7	0.433	1.000	+0.149	0.193	0.967
Extra Trees (공정변수만)	+0.033	25/0	0.001	0.011	+0.210	0.027	0.271

- PR-AUC 기준 상위권 모델 간 차이는 유의하지 않음. Recall@20%는 7 개 조합에서 보정 t $p<0.05$ 이나 Holm 보정 후에는 0 개임
- 추정 캐비티의 효과는 같은 Extra Trees 에서 PR-AUC +0.033(25 승 0 패, Holm $p=0.011$)로 다중비교 보정 후에도 유의함. 1 위를 먼저 고른 뒤 비교했으므로 1 위의 우위는 과대평가될 수 있어, 최종모델은 상위권과 비슷한 수준으로 해석함

◦ 불균형 처리 방식 비교

방식	PR-AUC 전체	CN7	RG3	Recall@20%
클래스 가중치 (채택)	**0.121**	**0.258**	**0.083**	**0.700**
가중치 없음	0.127	0.276	0.095	0.717
BorderlineSMOTE	0.107	0.227	0.076	0.636
ADASYN	0.104	0.216	0.091	0.722
SMOTE-NC	0.101	0.212	0.088	0.723

- 클래스 가중치는 선정 전에 정한 설계값이며 여기서는 민감도만 확인함. 가중치 없음과의 차이는 PR-AUC 보정 t p=0.66 로 유의하지 않아 설계값을 유지함. SMOTE 계열은 모두 PR-AUC 가 낮음. 같은 공정값의 양품·불량 사이에서 합성 표본을 만들어 구분이 더 어려워진 것으로 봄

◦ 스태킹 앙상블과 딥러닝(MLP) 검토

방식	모델	PR-AUC	ROC-AUC	Recall@20%	최종모델 대비 승/패
배깅 앙상블	**Extra Trees (최종)**	**0.121**	**0.845**	**0.700**	**-**
스태킹	ET·RF·XGB·LR → 로지스틱 회귀	0.109	0.805	0.598	9/16
딥러닝	MLP 32-16	0.064	0.734	0.493	4/21
딥러닝	MLP 64-32-16	0.062	0.693	0.512	1/24

- 스태킹의 메타 학습용 내부 CV 도 사출 그룹 단위로 나눔. 스태킹과 MLP 모두 최종모델보다 낮음. 학습 fold 의 불량이 약 27 건이라 메타 모델이나 신경망 가중치를 안정적으로 학습하기 어려움. CNN·LSTM 은 이미지·연속 시계열용 구조여서 사출당 요약값 24 개인 표 데이터에는 쓰지 않음

◦ **통합 모델과 제품별 모델**

- 같은 25 개 fold 에서 PR-AUC 는 CN7 통합 0.258 / 제품별 0.266, RG3 통합 0.083 / 제품별 0.081 로 차이가 작아, 관리가 단순한 통합 모델을 사용함

◦ **시간 검증: 생산순번 블록 CV 와 과거→미래 대리 검증**

검증	PR-AUC	ROC-AUC	Recall@20%
① 무작위 사출 그룹 CV	**0.121**	**0.845**	**0.700**
② 생산순번 블록 CV (8 구간)	0.045	0.729	0.420
② 생산순번 블록 CV (16 구간)	0.060	0.802	0.579

- CN7 불량이 한 시기에 몰려 있어, 그 시기의 사출을 학습에서 빼면 PR-AUC 가 0.045~0.060 로 낮아짐(무작위의 약 2.5~3.4 배). 추정 캐비티를 뺀 같은 모델은 0.034·0.039 로 캐비티 효과는 이 검증에서도 유지됨
- ③ 과거→미래 대리 검증에서 CN7 은 4 개 평가 구간 모두 불량이 없어 PR-AUC 를 계산할 수 없음(개발셋 CN7 불량이 모두 첫 구간). RG3 는 4 개 구간에서 PR-AUC 0.026~0.063(무작위 0.016~0.043), 구간당 불량이 3~8 건이라 변동이 큼
- 따라서 ①은 같은 기간 안의 검사 결과로 학습한 경우의 낙관적인 값이고, 처음 겪는 불안정 구간을 미리 예측할 수 있는지는 이 데이터로 검증할 수 없음. 운영에서는 검사 결과를 라벨로 쌓아 재학습하고, 처음 보는 구간은 규칙과 공정 흔들림 경보로 대응함(4 장)

◦ **테스트셋 성능**

범위	PR-AUC (95% CI)	ROC-AUC	F1	Recall	Recall@20%
전체	0.343 (0.015~0.706)	0.781	0.067	0.500	0.500
CN7	0.674 (0.111~1.000)	0.987	0.267	1.000	1.000
RG3	0.017 (0.007~0.042)	0.391	0.000	0.000	0.000

- 테스트 불량이 8 건(CN7 4, RG3 4)뿐이라 사출 그룹 부트스트랩 1000 회 95% 신뢰구간이 넓음. CN7 4 건은 상위 5% 안에 모두 들었고, RG3 4 건은 포착하지 못함(RG3 PR-AUC 가 무작위 수준)
- 테스트셋은 모델 선정과 설정 변경에 쓰지 않았음. 불량이 8 건뿐이라 성능 결론은 개발셋 CV 와 시간 검증을 중심으로 냄

  * F1·Recall 은 개발셋 내부 그룹 CV 로 정한 공통 임계값 0.052 기준

◦ **임계값 판정과 상위 k% 검사**

판정 기준	TP	FN	FP	비고
A. 외부 fold 임계값 (반복별)	3~12	22~31	99~205	fold 임계값 0.028~0.432
B. 반복 평균 점수 + 공통 임계값	26	8	371	진단용
C. 제품별 상위 20% 검사	**22**	**12**	**360**	**운영 기준**

- fold 마다 정한 임계값이 크게 흩어져 같은 모델이라도 반복에 따라 TP 가 크게 달라짐. 고정 임계값으로 양·불을 판정하는 방식은 이 데이터에서 안정적이지 않아, 운영과 오류분석은 검사 용량 기준(C)으로 함

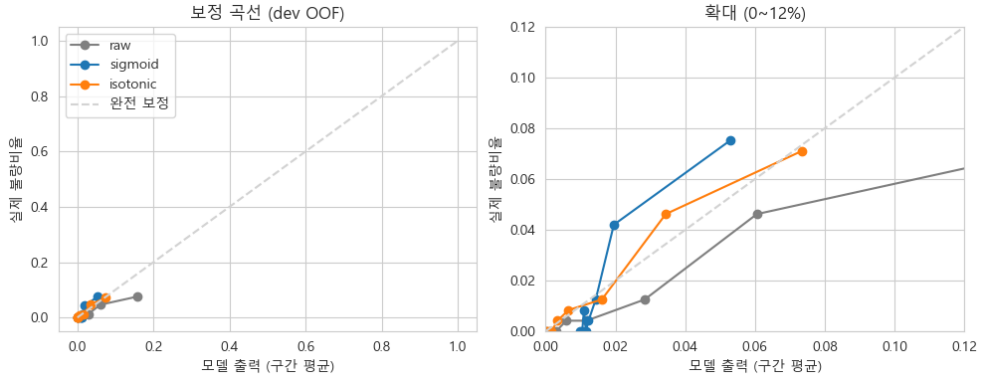
◦ **비지도 이상탐지(오토인코더)와 비교**

모델	PR-AUC 전체	CN7	RG3	Recall@20%
Extra Trees + 추정 캐비티 (최종)	**0.121**	**0.258**	**0.083**	**0.700**
오토인코더 (양품만 학습)	0.114	0.244	0.029	0.302
무작위 기준	0.018	0.014	0.021	0.200

- 오토인코더는 CN7 가동 초기의 눈에 띄는 공정 이상은 잡지만 RG3 에서 무작위 수준이고 Recall@20%가 낮아, 라벨이 부족한 신규 제품에서의 대안으로만 남김

◦ 확률 보정

방식	Brier	PR-AUC	Recall@20%	평균 예측값
보정 없음	0.0186	0.121	0.700	0.034
sigmoid	0.0173	0.117	0.691	0.018
isotonic	0.0173	0.085	0.688	0.017

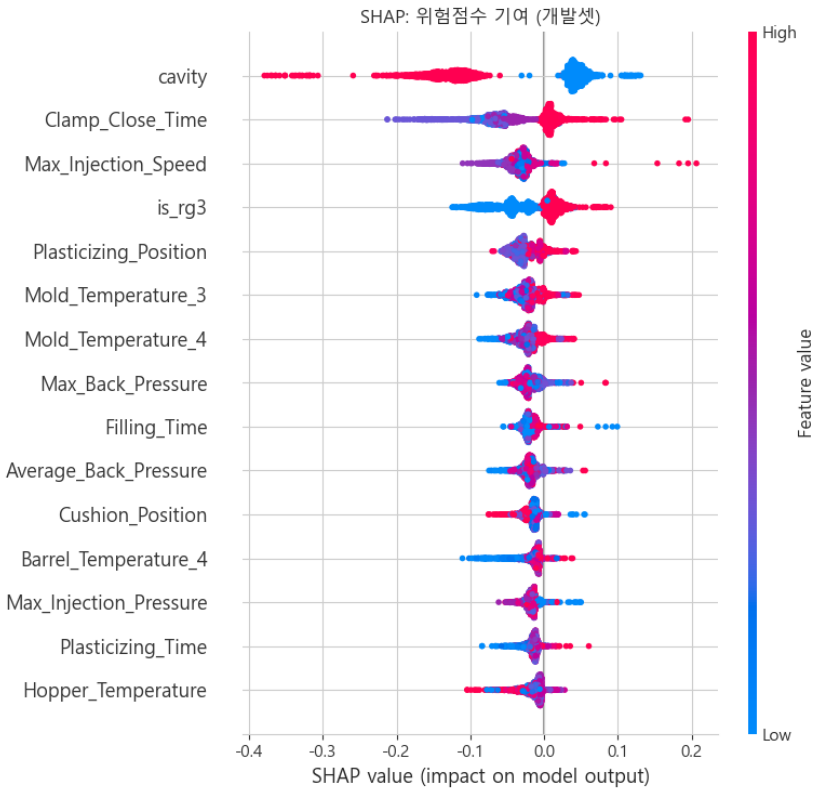


[그림 2-2] 보정 곡선 (개발셋 OOF, 오른쪽은 0~12% 확대)

- 보정 전 평균 점수(0.034)는 실제 불량률(0.018)과 다름. 보정기는 각 학습 fold 안의 사출 그룹 3-fold 로 학습함. Brier 는 sigmoid 가 가장 낮지만 보정 과정에서 PR-AUC 가 소폭 낮아져, 검사 순위는 보정 전 위험점수로 매기고 현장에 보여 줄 확률과 위험등급만 보정 확률을 씀

□ 제 3 장. 영향요인 및 오류분석 〔15 점〕

◦ 예측 기여 변수 (SHAP)



[그림 3-1] 최종모델 SHAP 요약 (위험점수 기여, 개발셋)

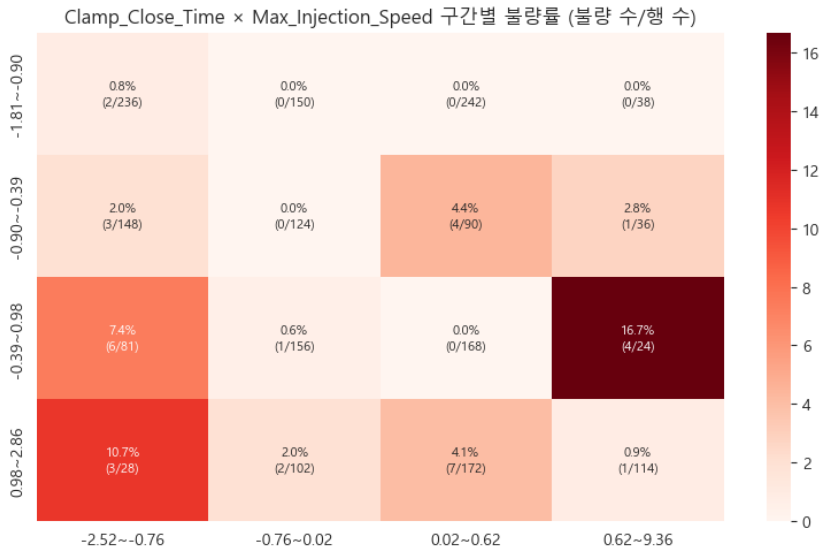
순위	변수	평균 |SHAP|	CN7 방향	RG3 방향
1	cavity (추정)	0.091	값↑ → 점수↓	값↑ → 점수↓
2	Clamp_Close_Time	0.044	값↑ → 점수↑	값↑ → 점수↑
3	Max_Injection_Speed	0.035	값↑ → 점수↑	비단조/약함
4	Plasticizing_Position	0.026	값↑ → 점수↑	값↑ → 점수↑
5	Mold_Temperature_3	0.024	값↑ → 점수↑	비단조/약함
6	Mold_Temperature_4	0.023	값↑ → 점수↑	비단조/약함
7	Max_Back_Pressure	0.021	-	-

* 방향 = 변수값과 SHAP 값의 순위상관 (±0.3 이상). is_rg3(제품 구분)는 조치 대상이 아니라 제외

- 공정변수 중에서는 Clamp_Close_Time, Max_Injection_Speed, Plasticizing_Position 의 기여가 크고, CN7 에서는 이 변수들의 값이 클수록 점수가 올라감. RG3 에서는 방향이 뚜렷하지 않음

- SHAP 은 모델이 점수를 높게 준 이유를 나눈 값이며 불량의 인과적 원인이 아님. 상관이 높은 변수끼리는 기여가 나뉘므로, 실제 조정 효과는 공정 실험으로 확인해야 함

◦ 상위 변수 조합별 불량률



[그림 3-2] Clamp_Close_Time × Max_Injection_Speed 구간별 불량률 (불량 수/행 수)

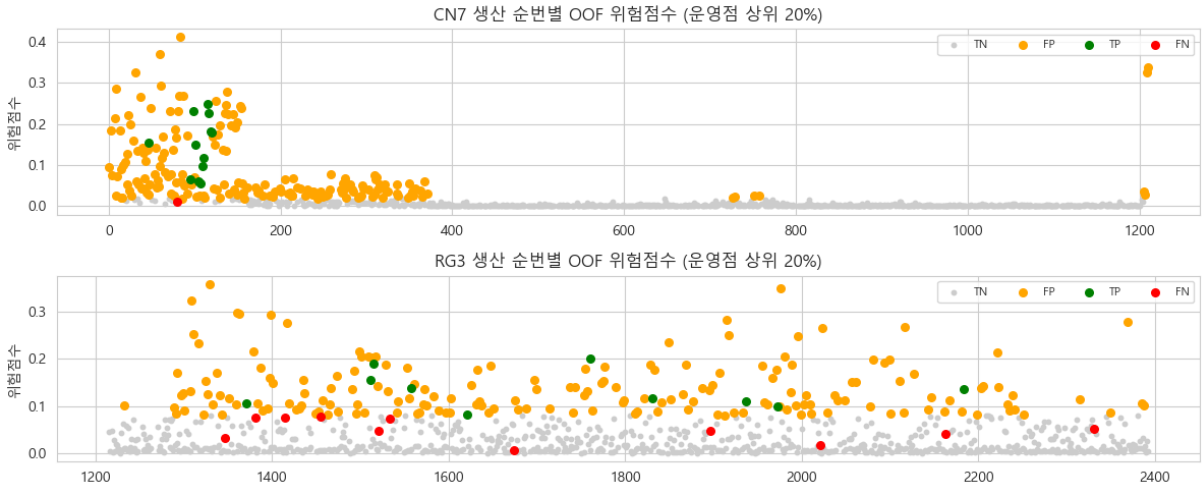
- 형체 시간 중상위 구간과 사출속도 최상위 구간이 겹치는 칸의 불량률이 가장 높음(16.7%, 4/24). 다만 칸마다 불량이 몇 건뿐이고 상호작용을 검정한 것이 아니므로, 같은 조건이 다시 나타날 때 표본 검사로 확인할 가설로 둠

◦ 운영점 기준 미탐지(FN)·오경보(FP) 분석

- 운영 방식대로 제품별 위험점수 상위 20%를 검사한다고 보고 오류를 정의함 (개발셋 OOF)

제품·추정 캐비티	불량	TP	FN (유출)	FP (검사했으나 양품)	FN 비율
CN7 추정 캐비티 0	10	10	0	124	0.00
CN7 추정 캐비티 1	3	2	1	57	0.33
RG3 추정 캐비티 0	20	10	10	177	0.50
RG3 추정 캐비티 1	1	0	1	2	1.00

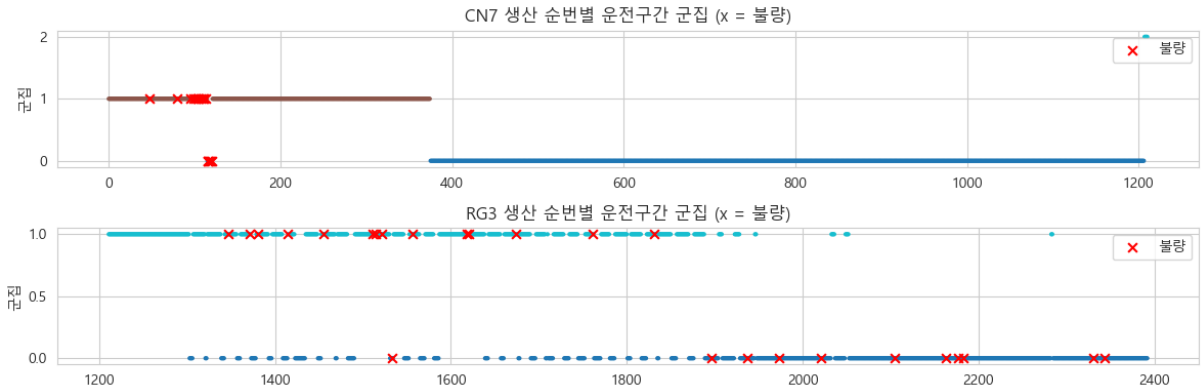
- 놓친 불량 12 건 중 11 건이 RG3 임. RG3 불량은 같은 공정값의 양품과 구분되지 않아(1 장) 모델 조정으로 줄이기 어려움
- CN7 오경보는 생산순번 0~20% (순번 0~238)에 125 건이 몰려 있음. 불량 다발 시기의 양품도 공정값이 비슷해 함께 검사 대상에 오른 것으로, 이 시기에는 강화검사로 보는 것이 맞음



[그림 3-3] 생산 순번별 OOF 위험점수와 판정 유형 (제품별 상위 20% 검사)

- 깊이 3 의사결정나무로 FN·FP 가 몰리는 조건을 규칙으로 정리했으나(op_rules_FN.txt, op_rules_FP.txt), 불량 34 건으로 만든 요약이라 새 데이터에서 그대로 성립한다고 보지 않음

◦ 라벨 없이 찾은 운전구간 (K-평균 군집)



[그림 3-4] 생산 순번별 운전구간 군집 (x = 불량)

제품	군집	생산순번	행 수	불량	불량률
CN7	0	115 ~ 1,206	838	6	0.7%
CN7	1	0 ~ 374	369	11	3.0%
RG3	0	1,303 ~ 2,392	636	11	1.7%
RG3	1	1,211 ~ 2,284	546	14	2.6%

- CN7 은 라벨을 쓰지 않아도 초반 구간이 별도 군집으로 나뉘고 불량률이 4.2 배 높음. 가동 초기 강화검사 규칙과 공정 흔들림 경보(4 장)의 근거로 씀. RG3 는 군집 간 차이가 작음

□ 제 4 장. 현장 활용방안 [10 점]

- 모델은 기존 품질검사를 대체하지 않음. 같은 검사 용량에서 불량을 더 많이 잡도록 검사 순서를 정하는 데 씀

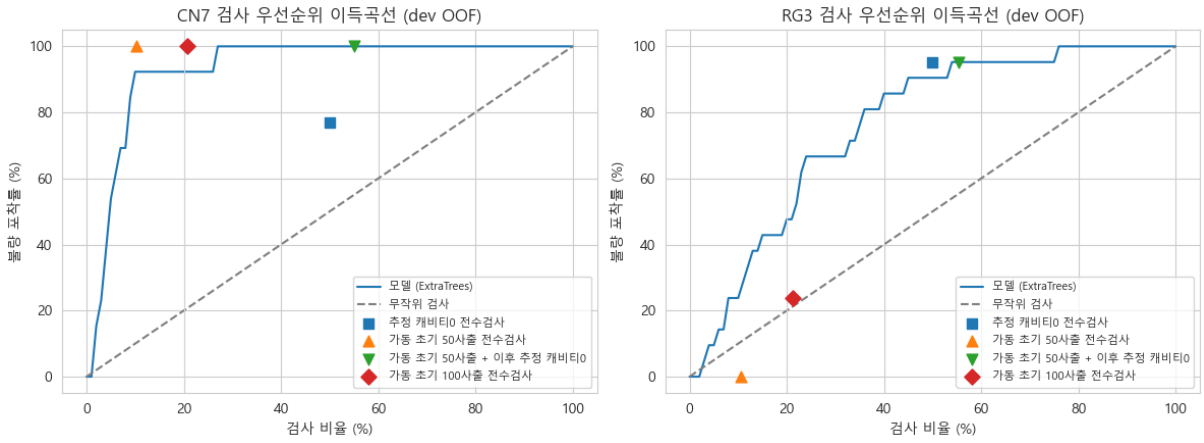
범위	검증 결과	적용 수준
CN7	상위 20% 검사로 개발셋 불량 12/13 건 포착(OOF 합산). 불량이 가동 초기 한 구간에 몰려 있음	가동 초기 강화검사 규칙과 모델 순위를 함께 쓰고 시범 운영으로 확인
RG3	불량 전부가 라벨 충돌, 테스트 성능 무작위 수준	모델 단독 사용 불가. 추정 캐비티 0 샘플 검사와 기존 검사 유지, 센서 추가 필요

◦ ① 검사 용량별 불량 포착

검사 용량	검사 수	포착 / 불량	미탐지	포착률	CN7 포착	RG3 포착
5%	97	9 / 34	25	26.5%	7 / 13	2 / 21
10%	192	17 / 34	17	50.0%	12 / 13	5 / 21
20%	**382**	**22 / 34**	**12**	**64.7%**	**12 / 13**	**10 / 21**
30%	574	27 / 34	7	79.4%	13 / 13	14 / 21

* 개발셋 OOF 합산, 제품별 할당(제품마다 같은 비율 검사). 동점은 생산 순번이 앞선 제품 우선, 검사 수는 올림. 2 장의 Recall@20%(fold 평균)와 계산 방식이 다름

- 두 제품을 한 줄로 세우는 통합 순위로 20%를 검사하면 26 건을 잡지만 RG3 검사 비율이 31%로 바뀜. 제품 간 점수 척도가 같다는 보장이 없어 제품별 할당을 기본 정책으로 함



[그림 4-1] 검사 비율 대비 불량 포착률과 규칙 베이스라인 (개발셋 OOF)

◦ ② 단순 규칙과 비교

규칙	범위	검사 비율	규칙 포착률	같은 검사량의 모델
추정 캐비티 0 전수검사	전체	50.0%	88%	94%
추정 캐비티 0 전수검사	RG3	50.0%	95%	90%
가동 초기 50 사출 전수검사	CN7	10.3%	100%	92%
가동 초기 100 사출 전수검사	CN7	20.6%	100%	92%

- CN7 가동 초기 50 사출 전수검사(검사 10.3%)는 불량의 100%를 잡아 같은 검사량의 모델(92%)보다 높음. RG3 에서는 추정 캐비티 0 전수검사가 모델보다 약간 높음. 다만 초기 50 사출은 불량이 초기에 몰린 것을 보고 정한 규칙이라 새 가동에서도 같은 효과를 낸다는 보장이 없음
- 따라서 가동 초기·금형 교체 직후에는 규칙으로 강화검사하고, 안정 구간에는 모델 상위 k%를 검사하며, RG3 는 추정 캐비티 0 샘플 검사를 병행하는 방식을 제안함

◦ ③ 위험등급과 조치

등급	보정 확률 기준	개발셋 비중	실제 불량률	검사	재검사·공정 조치
위험	≥ 0.027	상위 10%	7.3% (14/191)	같은 사출 그룹 2 개 모두	불량이면 재검사 기준 강화, 기여 변수 단계 설정값 점검
주의	0.015 ~ 0.027	10~30%	4.2% (16/382)	그룹 중 1 개 샘플	연속 3 사출 이상 주의면 설비 담당 확인
정상	< 0.015	하위 70%	0.3% (4/1336)	기존 샘플링 + 무작위 표본	없음

- 위험 등급의 불량률은 정상 등급의 약 24 배이고, 정상 등급에 남는 불량은 34 건 중 4 건임. 등급 경계는 개발셋 분위로 고정하고 재학습할 때만 바꿈

◦ ④ 예측 기여 변수 제시

순위	제품	추정 캐비티	위험점수	보정 확률	기여 변수 1	기여 변수 2	실제
1	CN7	1	0.873	0.474	Max_Injection_Speed	Filling_Time	불량
2	CN7	0	0.871	0.476	Max_Injection_Speed	Filling_Time	불량
3	CN7	0	0.339	0.228	추정 cavity	Clamp_Close_Time	양품
4	CN7	0	0.326	0.166	Clamp_Close_Time	추정 cavity	양품

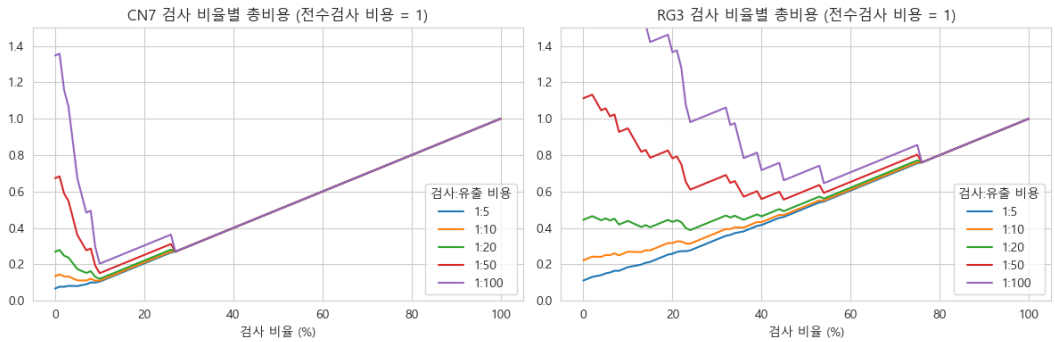
- 테스트 예측결과에는 제품마다 점수를 가장 크게 올린 변수 3 개를 함께 기록함. 순위 1·2 위(같은 사출의 두 제품, 모두 불량)는 사출속도가 1 순위였고, 제품별 상위 20%에서는 추정 cavity(78 회), Clamp_Close_Time(47 회), Plasticizing_Position(26 회) 순으로 많았음
- 기여 변수는 원인이 아니라 먼저 확인할 항목으로 표시함. 공정변수가 1 순위면 해당 공정 단계의 설정값을, 추정 cavity 가 1 순위면 같은 그룹의 다른 제품과 금형 상태를 확인하도록 안내함

◦ ⑤ 비용 시나리오와 손익분기 (가정)

- 검사 비용·유출 비용 자료가 없어 검사 1 건 비용 1, 유출 1 건 비용 r 로 가정한 시나리오만 제시함

유출 : 검사 비용	CN7 최적 검사 비율	RG3 최적 검사 비율	CN7 절감 (단순 대안 대비)
10 : 1	10%	0%	18%
20 : 1	10%	24%	55%
50 : 1	10%	45%	77%
100 : 1	10%	54%	80%

* 단순 대안 = 전수검사·무검사 중 비용이 낮은 쪽. 손익분기: 보정 확률 p 인 제품은 $p \geq 1/r$ 이면 검사하는 편이 기대비용상 낫다 (보정 확률이 실제 빈도와 맞는다는 가정)



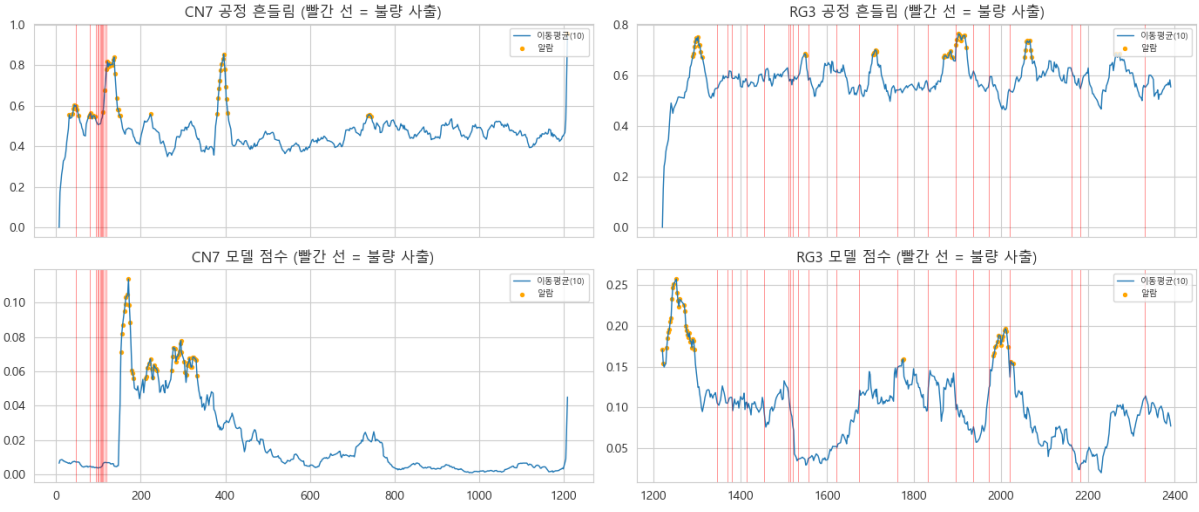
[그림 4-2] 검사 비율별 총비용 (전수검사 비용 = 1)

- CN7 은 비용비 가정이 바뀌어도 최적 검사 비율이 10% 안팎으로 안정적이고, RG3 는 가정에 따라 크게 달라짐. 현장 비용비가 정해지면 같은 표로 제품별 검사 비율을 정함

◦ ⑥ 사전경보

신호	제품	첫 알람	첫 불량	사전 감지 비율	알람 비율	알람 후 불량 비율
공정 흔들림 (라벨 미사용)	CN7	31	47	100%	10%	31%
모델 점수 (블록 CV)	CN7	153	47	0%	10%	0%
공정 흔들림 (라벨 미사용)	RG3	1291	1347	14%	10%	30%

* 공정 흔들림 = 각 사출의 공정값이 직전 10 사출 평균에서 벗어난 정도, 이동평균 알람 (상위 10% 분위). 사전 감지 = 불량 사출 직전 10 사출 안에 알람

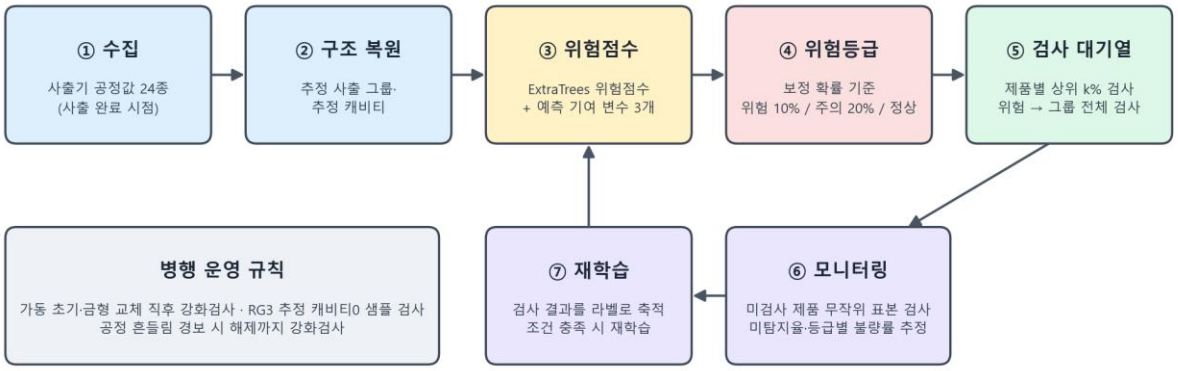


[그림 4-3] 신호별 이동평균과 알람 (빨간 선: 불량 사출)

- CN7 에서 공정 흔들림 경보는 첫 불량보다 먼저 울렸고 불량 사출을 모두 미리 감지함. 모델 점수 경보는 처음 보는 불안정 구간을 학습한

적이 없어 늦게 울림. 알람 기준을 같은 데이터에서 정했고 CN7 불안정 구간이 한 번뿐이라 낙관적인 결과이며, RG3 에서는 효과가 약함

◦ ⑦ 운영 흐름과 모니터링



[그림 4-4] 현장 적용 흐름

- 1 사출 추론 시간은 약 0.1 초로 사출 사이클 안에 처리 가능함. 저장된 모델로 재학습 없이 추론하는 스크립트(predict.py)를 제공함
- 선택한 제품만 검사하면 검사하지 않은 제품의 불량을 알 수 없어 성능이 과대평가되므로, 검사 대상에서 빠진 제품 중 일부(예: 2~5%)를 무작위로 검사해 미탐지율과 등급별 실제 불량률을 추정함
- 재학습 조건(예시, 현장과 합의 필요): 새 불량 라벨이 일정 건수 이상 쌓였을 때, 표본 검사로 본 미탐지율이 개발 단계 추정치보다 뚜렷이 높을 때, 금형·자재·설정 변경 후, 공정 흔들림 경보가 반복될 때. 재학습 시에도 같은 분할·검증 절차와 선정 규칙을 적용함

◦ ⑧ 오프라인 검증 요약

지표	기준	결과	비고
PR-AUC (무작위 사출 그룹 CV)	0.018 (무작위)	0.121	약 6.9 배
PR-AUC (생산순번 블록 CV)	0.018 (무작위)	0.045~0.060	같은 시기 사출 제외
CN7 상위 20% 검사 시 포착	20% (무작위)	92% (12/13)	개발셋 OOF 합산
RG3 상위 20% 검사 시 포착	20% (무작위)	48% (10/21)	개발셋 OOF 합산
위험 / 정상 등급 불량률	1 배	7.3% / 0.3%	약 24 배

* 모든 수치는 개발셋 오프라인 검증 결과이며, 실제 효과는 시범 운영으로 확인해야 함

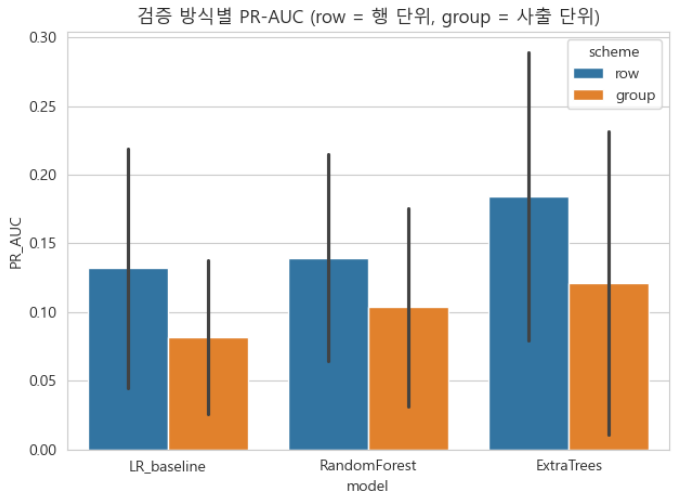
□ 제 5 장. 창의성 및 차별성 〔10 점〕

◦ ① 생산 구조 복원과 그룹 단위 검증

- 데이터에 없는 사출·캐비티 구조를 공정값의 연속성으로 복원하고, 교차 기록된 짝까지 찾아 같은 그룹으로 묶음. 같은 그룹이 학습·평가에 나뉘지 않도록 모든 분할을 설계하고 코드로 점검함

모델	행 단위 CV	사출 그룹 CV	차이
LR (베이스라인)	0.132	0.082	+ 61%
Random Forest	0.140	0.103	+ 35%
Extra Trees	**0.184**	**0.121**	**+ 52%**

* PR-AUC, + 추정 캐비티 특성셋, 5-fold × 5 회, 같은 개발셋 (leakage_cv.csv)



[그림 5-1] 검증 방식별 PR-AUC (row = 행 단위, group = 사출 그룹 단위)

- 행 단위로 검증했다면 최종모델 성능을 52% 높게 보고했을 것임. 행 단위 분할을 쓴 연구의 수치와는 직접 비교하지 않음

◦ ② 성능 범위를 보여 주는 검증 3 종

- 무작위 사출 그룹 CV(0.121), 생산순번 블록 CV(0.045~0.060), 과거→미래 대리 검증(CN7 평가 불가)을 함께 제시해, 하나의 숫자 대신 운영 조건에 따른 성능 범위를 제시함

◦ **③ 데이터에 맞춘 모델과 처리 방식 선택**

- 부스팅(XGBoost·CatBoost·LightGBM), 배깅, 보팅, 스태킹, MLP, 오토인코더를 같은 fold 에서 비교하고, 유의성 검정과 다중비교 보정으로 차이가 의미 있는지 확인함. 불량이 30 여 건인 데이터에서 복잡한 모델의 이득이 없음을 보이고 단순한 배깅 앙상블을 사용함
- SMOTE 계열이 성능을 낮추는 이유를 라벨 충돌 구조로 설명하고, 추정 캐비티의 효과가 모델 선택보다 크고 다중비교 보정 후에도 유의함을 보임

◦ **④ 예측 상한 진단과 비라벨 데이터 판단**

- 같은 공정값에 양품·불량이 공존하는 비율로 공정변수로 예측 가능한 불량과 불가능한 불량을 구분함(RG3 25/25 건 구분 불가). 이를 근거로 캐비티별 압력·온도 센서 추가 수집을 제안함
- 비라벨 7 만 행은 도메인 판별과 자기학습 실험 후 분포 차이를 이유로 학습에 넣지 않음

◦ **⑤ 운영 관점의 평가**

- 임계값 판정과 검사 용량 기반 운영을 구분해 평가하고, 단순 규칙(가동 초기 전수검사, 캐비티 0 전수검사)과 같은 검사량에서 비교함. 규칙이 나은 경우도 그대로 반영해 규칙과 모델을 함께 쓰는 운영안을 제시함
- 라벨 없이 작동하는 공정 흔들림 경보, 비용 시나리오, 무작위 표본 검사 기반 모니터링과 재학습 조건까지 운영 절차로 정리함

◦ ⑥ 선행연구와 비교

연구	데이터	방법	검증	결과	본 연구와의 차이
홍지수 외 (2023)	KAMP 사출성형	XGBoost·LightGBM + SHAP·ICE	-	관리범위 적용 시 불량률 1.00% → 0.21%	원 단위 관리범위 제시 (본 데이터는 표준화되어 불가)
조현민·신현준 (2021)	KAMP 사출성형 36 변수	DAE·LSTM·CNN	-	Accuracy·F1 약 100%	검증 분할 방식 확인 불가
한용희·고방원 (2025)	KAMP 886,227 건, 불량 1.2%	CNN-LSTM + 부스팅 앙상블, SMOTE·ADASYN	시간 분할, 층화 10-fold	F1 0.815, AUC 0.978	불량 1 만 건 규모에서는 부스팅 우세. 본 데이터(불량 42 건)에서는 배깅 우세, SMOTE 효과 없음
Kim et al. (2021)	자동차 사이드몰딩, 불량 약 4%	표 + 금형 내 온도 시계열	-	F1 0.625 → 0.75	센서 시계열의 가치 → 센서 추가 제안 근거
본 연구	경진대회 제공본 2,393 건, 불량 42 건	7 종 비교 + 추정 캐비티	사출 그룹 CV 5×5, 블록·과거→미래 검증	PR-AUC 0.121, Recall@20% 0.700	생산 구조 복원, 검증 3 종, 운영점 평가

- 데이터 규모와 버전이 달라 수치를 직접 비교할 수는 없음

◦ ⑦ KAMP 분석도구 활용

분석도구 / 키워드	적용	위치
기술통계 · 상관분석	데이터 진단, 변수 상관 확인	1 장
랜덤 포레스트 · XGBoost	배깅·부스팅 7 종 비교	2 장
오토인코더	양품 학습 이상탐지와 비교	2 장
K-평균 군집분석	라벨 없이 운전구간 분리	3·4 장
준지도 학습	자기학습 실험으로 비라벨 결합 여부 판단	1 장

- 이미지·음향·연속 시계열·회귀용 도구(CNN, YOLOv8, LSTM, 회귀분석)는 과제 형태(정형 공정값, 이진 판정)에 맞지 않아 쓰지 않음

□ 제 6 장. 코드 구성 및 재현성 〔10 점〕

◦ 폴더 구성

경로	내용
README.md	실행 방법, 폴더 구성, 산출물 설명
requirements.txt / requirements-lock.txt	최저 버전 지정 / 결과를 만든 환경의 정확한 버전
run_all.py	전처리부터 진단, 모델 비교, 최종 학습·보정·저장, 테스트 추론, 오류·현장 분석, 부가 실험까지 실행
predict.py	저장된 모델로 새 CSV 추론 (위험점수, 보정 확률, 등급, 검사 대상, 기여 변수)
analysis.ipynb	결과 시각화와 해설 (평가 항목 순서)
src/config.py · data.py · models.py · evaluate.py	설정, 적재·구조 복원·진단, 비교 모델 7 종, 그룹 CV·지표
src/insights.py · experiments.py	분할 점검, 시간 검증, 운영점 분석, 보정, 비용, 사전경보 / 유의성, 불균형, 스태킹·MLP, 군집, 오토인코더, SHAP
data/	제공 데이터 원본 4 종
outputs/	진단표, CV 결과, 테스트 예측결과(test_predictions.csv), 모델 파일, 실행 기록

◦ 실행 방법과 환경

pip install -r requirements.txt (KAMP-NOTE: pip install --user -r requirements.txt)

python run_all.py (--quick: 반복 1 회 점검, --no-extra: 부가 실험 생략, --clean: 출력 폴더 초기화)

python predict.py --input data/moldset_labeled_cn7.csv --product cn7

환경	Python	scikit-learn	pandas	numpy	lightgbm	xgboost	catboost	shap
결과 생성 (로컬)	3.12.7	1.5.1	2.2.2	1.26.4	4.6.0	3.4.1	1.2.10	0.50.0
KAMP-NOTE (노트북 실행 확인)	3.11.9	1.4.2	2.1.4	1.26.4	4.5.0	--user 설치	--user 설치	0.49.1

- CPU 기준 전체 실행 약 60 분(모델 14 개 조합 × 25 fold + 부가 실험). 노트북은 결과 파일을 읽어 그림·표를 재현하며 약 5 분 걸림

◦ 재현성 확보 방안

- 난수 시드 42 고정, 선정 규칙과 테스트 분할 규칙을 코드로 고정

- 분석 로직은 src/ 모듈에만 두고 run_all.py 와 노트북이 같은 함수를 사용함. 노트북에서 테스트 위험점수, 임계값, 입력 열이 저장 결과와 같은지 확인함
- run_manifest.json 에 실행 시각·소요 시간·패키지 버전·입력 데이터와 코드의 해시를 기록하고, 노트북은 해시가 다르면 경고하며 FORCE_RERUN 으로 다시 실행할 수 있음
- 최종모델·보정 모델·입력 열 목록·임계값·등급 경계를 outputs/model/에 저장해 재학습 없이 추론 가능

◦ 테스트데이터 예측결과 파일 (outputs/test_predictions.csv)

컬럼	설명
prod_idx / product	원본 생산 순번, 제품
shot_id / cavity / pair_type	추정 사출 그룹, 추정 캐비티(그룹 내 순서), 그룹 유형
PassOrFail	실제 판정 (평가용)
risk_score	위험점수 (보정 전, 검사 순위용)
risk_prob_cal / risk_grade	보정 확률, 위험등급 (위험·주의·정상)
pred_common_thr	공통 임계값 판정 (1=불량, 참고용)
inspect_rank_all / inspect_rank_product / inspect_top20_product	통합 검사 순위 / 제품별 순위 / 제품별 상위 20% 여부
contrib_1 ~ contrib_3	점수를 가장 크게 올린 변수와 기여도 (SHAP, 원인 아님)

◦ 한계 및 향후 과제

한계	근거	필요한 것
불량 표본 부족	학습 불량 34 건, 테스트 8 건. 모델 간 차이 비유의, 신뢰구간 넓음	운영하며 라벨 축적 후 재평가
공정값에 불량 정보 없음	RG3 불량 25 건 모두 같은 공정값의 양품 존재	캐비티별 압력·온도 센서
독립적인 불량 사건 부족	CN7 불량이 한 구간에만 있어 과거→미래 검증 불가	불안정 구간이 여러 번 포함된 긴 기간 데이터
구조·변수 정보 추정	사출·캐비티 번호, 변수 단위·측정 시점, 타깃 코딩 미확인	설비 기록, 원 단위 값, 데이터 설명서
비용 정보 없음	검사·유출 비용을 가정값으로 사용	현장 비용 자료

□ 경진대회 만족도 조사 완료 페이지 캡쳐 화면

- 만족도 조사 url : https://naver.me/FetWt7SN

