제6회 K-인공지능 제조데이터 분석 경진대회

과제 ① 사출성형기 AI 데이터셋

사출성형 공정데이터 기반 품질불량 위험 예측과 검사 우선순위 결정

생산 구조를 반영한 검사 보조 모델

추정 사출 그룹 검증 · 검증 3종 · 검사 용량 기반 운영 · 사전경보

팀 j2tori
발표 전건우

검사 전에, 위험한 제품부터 골라 검사한다

문제

최종검사에서야 불량 확인
선제 대응이 어려움
검사 자원은 모든 제품에 같은 비율

예측 시점

사출 완료 후, 검사 전
사이클·충전 시간, 사출압 등은
사출 중·후에 확정되는 값

목표

① 제품별 위험점수
② 같은 검사량에서 포착률 향상
③ 오류 조건과 운영 규칙

판정기가 아니라 검사 보조 도구: 위험점수 순으로 검사하고, 기존 품질검사는 그대로 유지

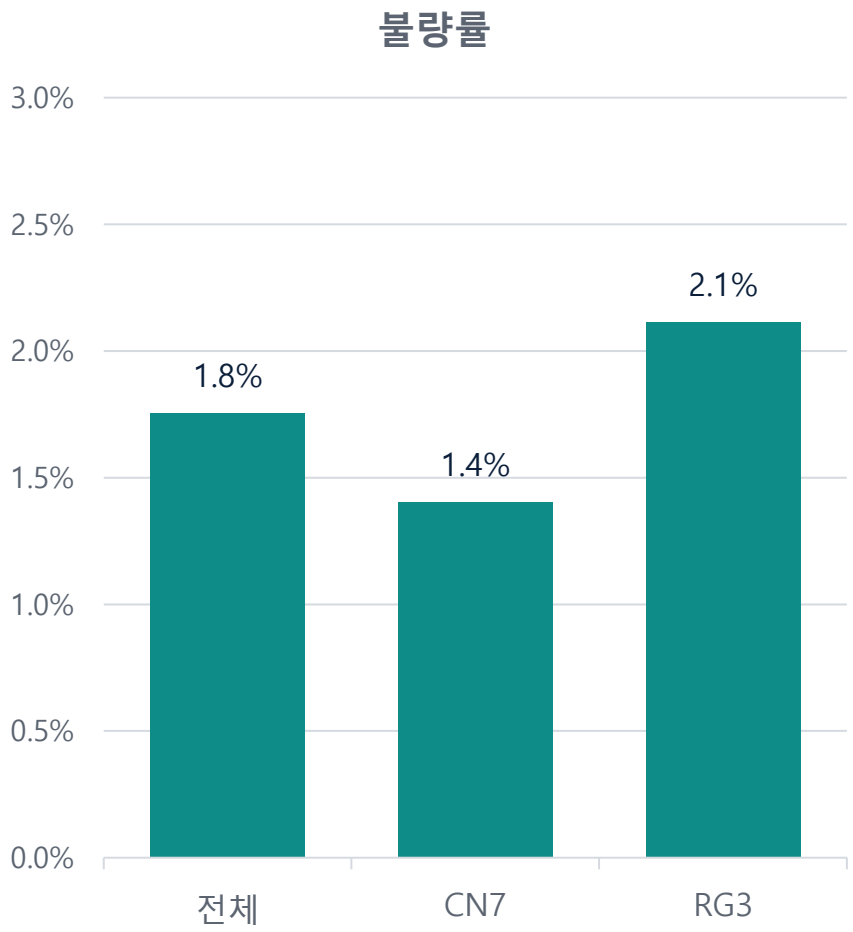
출처 과제공개 문서

데이터는 2,393행, 불량은 42개

2,393
라벨 데이터 (CN7 1,211 · RG3 1,182)

42
불량 (CN7 17 · RG3 25)

98.2%
전부 양품이라 해도 나오는 정확도



평가 지표

- **PR-AUC (주지표)**: 무작위 기준 = 불량률 0.018
- **Recall@k%**: 검사 용량 k%에서 불량 포착률
- **F1@20%**: 상위 20% 검사를 판정으로 본 F1
- **임계값 F1**: 참고용 (임계값이 불안정)

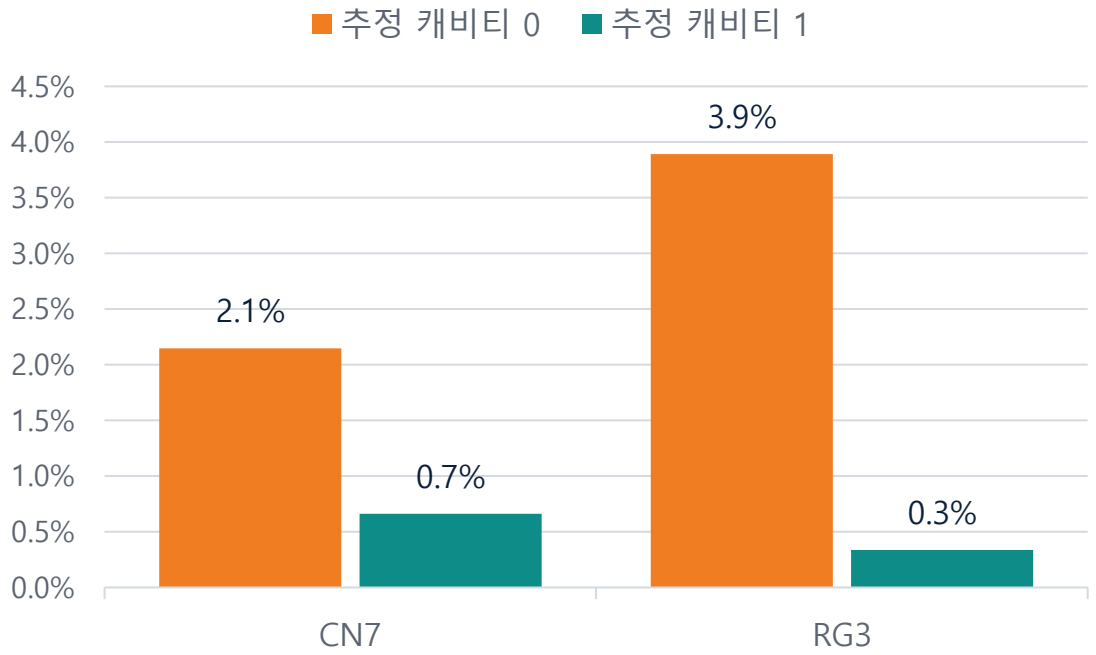
출처 outputs/data_diagnosis.csv

공정값이 같은 2행은 한 번의 사출, 불량의 86%는 그룹의 첫 행

추정 사출 그룹 (사출 번호 없음)

	CN7	RG3
연속 2행	570	574
연속 규칙상 1행	71	34
교차 짝 병합	35쌍	17쌍
최종 그룹	606	591
순번 누락	0	0

1행 그룹 대부분은 2~5행 떨어진 곳에 같은 공정값 짝이 있음
(A·B·A·B 교차 기록) → 같은 그룹으로 병합



불량 42건 중 36건이 그룹의 첫 행
행 순서가 실제 캐비티 위치인지는 확인 필요

출처 outputs/structure_summary.csv

RG3 불량은 모두 같은 공정값의 양품이 있다

25 / 25

RG3 불량 중 같은 공정값의 양품이 있는 비율

11 / 17

CN7 불량 중 같은 공정값의 양품이 있는 비율

의미

- 공정값만 보는 모델은 이 짝을 구분할 수 없음
- RG3 성능 한계는 데이터의 예측 상한
- RG3 에는 센서 등 다른 정보가 필요

중복 제거의 함정

'완전히 같은 행 = 중복 → 삭제'

이 데이터에 적용하면
같은 사출의 짝이 사라지고
불량 라벨도 함께 삭제

→ 지우지 않고 그룹으로 묶음

중복은 오류가 아니라 생산 구조: 삭제하지 않고 검증 설계(그룹 분할)에 반영

출처 노트북 1-3 라벨 충돌

비라벨 7만 행은 분포가 달라 학습에 넣지 않았다

① 도메인 판별: 라벨 vs 비라벨 구분 AUC

1.00
CN7 원값

1.00
CN7 순위변환

1.00
RG3 원값

1.00
RG3 순위변환

0.5 = 비슷한 분포, 1.0 = 완전히 구분됨

② 자기학습 (그룹 CV 5×3)

방식	PR-AUC	RG3	Recall@20%
라벨만	0.098	0.093	0.617
자기학습 (보수적)	0.136	0.118	0.649
자기학습 (느슨함)	0.128	0.116	0.512

PR-AUC는 올랐으나 Recall@20%는 설정에 따라 오르내림.
분포 차이의 원인(기간·조건·전처리)은 확인되지 않음

비라벨은 분포 진단과 운전구간 군집에만 사용. 원 단위 데이터와 수집 기간 정보가 있으면 다시 판단

출처 outputs/unlabeled_domain_auc.csv · self_training_cv.csv

같은 사출 그룹은 같은 쪽으로, 검증은 세 가지로

그룹 단위 분할
개발 1,909 / 테스트 484
사출 그룹·불량 층화

→

반복 그룹 CV
5-fold × 5회
14개 조합 같은 fold

→

학습 데이터 안에서만
입력 열·임계값
보정·스태킹

→

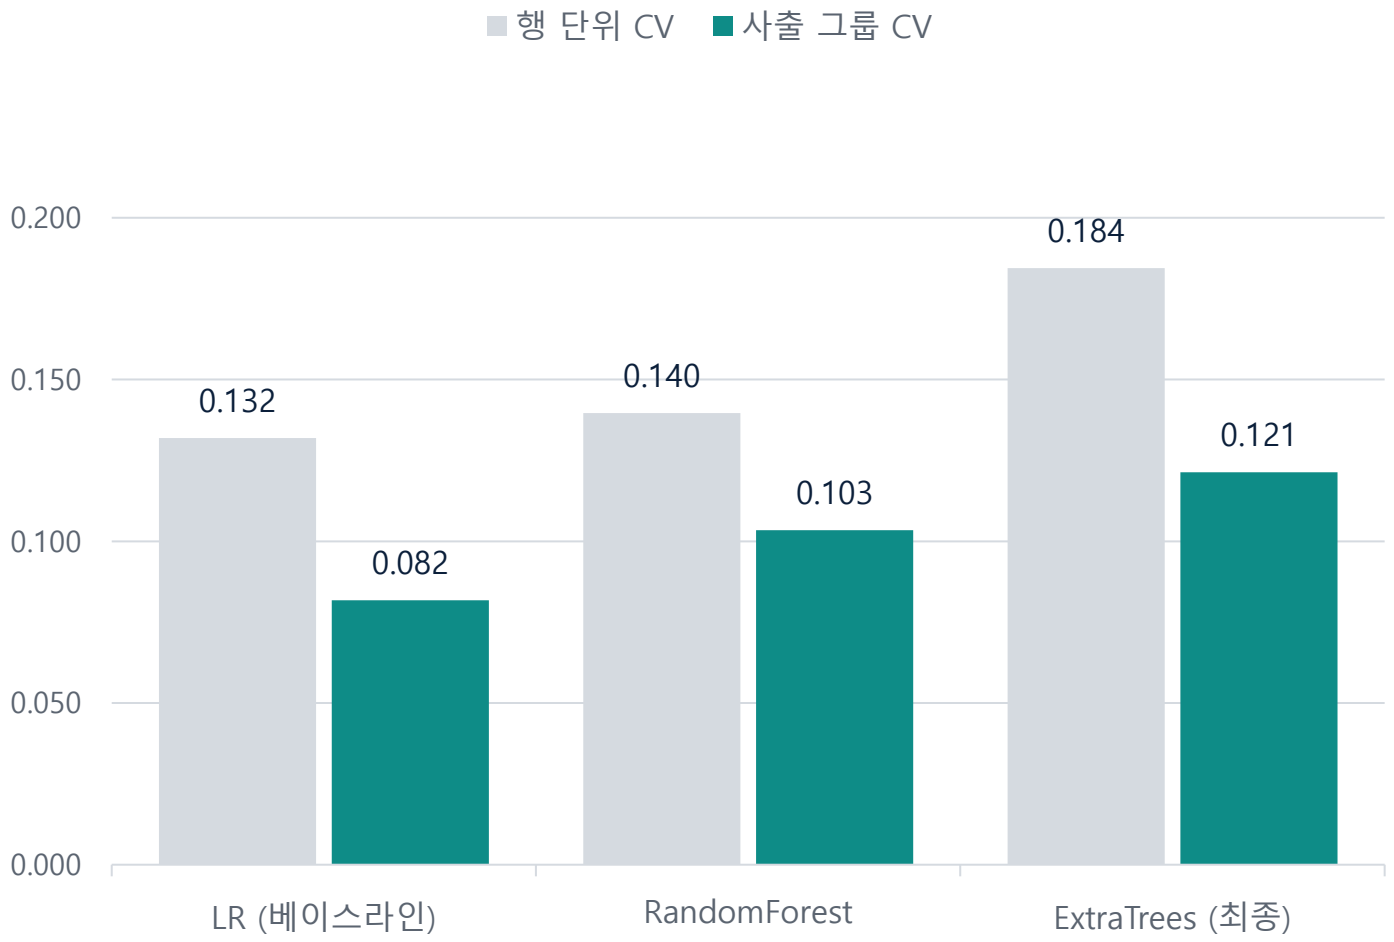
누수 점검
7개 분할 모두
겹친 그룹 0

검증	분할	보는 것	한계
① 무작위 사출 그룹 CV (주 검증)	그룹을 무작위로 fold 배정	같은 기간 안의 일반화	같은 시기 이웃 사출이 학습에 들어감
② 생산순번 블록 CV	연속 구간 8·16개를 통째로 평가	같은 시기 사출을 뺐을 때	평가 구간 뒤 데이터도 학습
③ 과거→미래 대리 검증	앞 구간으로 학습, 다음 구간 평가	시간 순서를 지킨 운영	생산 순번 기준, 불량 없는 구간은 N/A

테스트셋은 모델 선정과 설정 변경에 쓰지 않음

출처 src/evaluate.py · src/insights.py · outputs/split_audit.csv

행 단위로 검증했다면 최종모델 성능을 52% 높게 봤다



+52%

ExtraTrees (0.184 vs 0.121)

+35% · +61%

RandomForest · LR

행 단위 분할을 쓴 연구 수치와는 직접 비교하지 않음

출처 outputs/leakage_cv.csv (5-fold × 5회)

7종 비교: 상위권은 비슷하고, 규칙대로 ExtraTrees 선정

모델 (+추정 캐비티)	계열	PR-AUC	ROC-AUC	Recall@20%*
ExtraTrees ★	**배깅**	**0.121**	**0.845**	**0.700**
RF + ET 앙상블	앙상블	0.119	0.840	0.694
CatBoost	부스팅	0.118	0.831	0.663
RandomForest	배깅	0.103	0.807	0.589
LightGBM	부스팅	0.101	0.816	0.643
LR (베이스라인)	선형	0.082	0.770	0.530
XGBoost	부스팅	0.079	0.784	0.551

무작위 PR-AUC = 0.018 → 최종모델 약 6.9배 · *25개 fold 평균 (17번 슬라이드는 OOF 합산) · 선정 규칙은 분석 전에 정함

해석

- 상위 3개 차이 **0.003**, fold 표준편차 0.110
- **임계값 F1 은 선정에 쓰지 않음:** fold당 불량 6~7건이라 불안정. 운영 기준 F1@20% 는 최종 모델 1위
- **학습 불량 34건:** 복잡한 부스팅의 이점이 작음
- **하이퍼파라미터 고정:** fold당 불량 6~7건이라 튜닝은 잡음에 좌우됨, 과적합을 줄이는 값으로 고정

최종모델은 상위권과 비슷한 수준으로 해석. 어느 상위 모델을 써도 운영상 결론은 크게 다르지 않음

출처 outputs/cv_summary.csv (무작위 사출 그룹 CV, 공정변수 + 추정 캐비티)

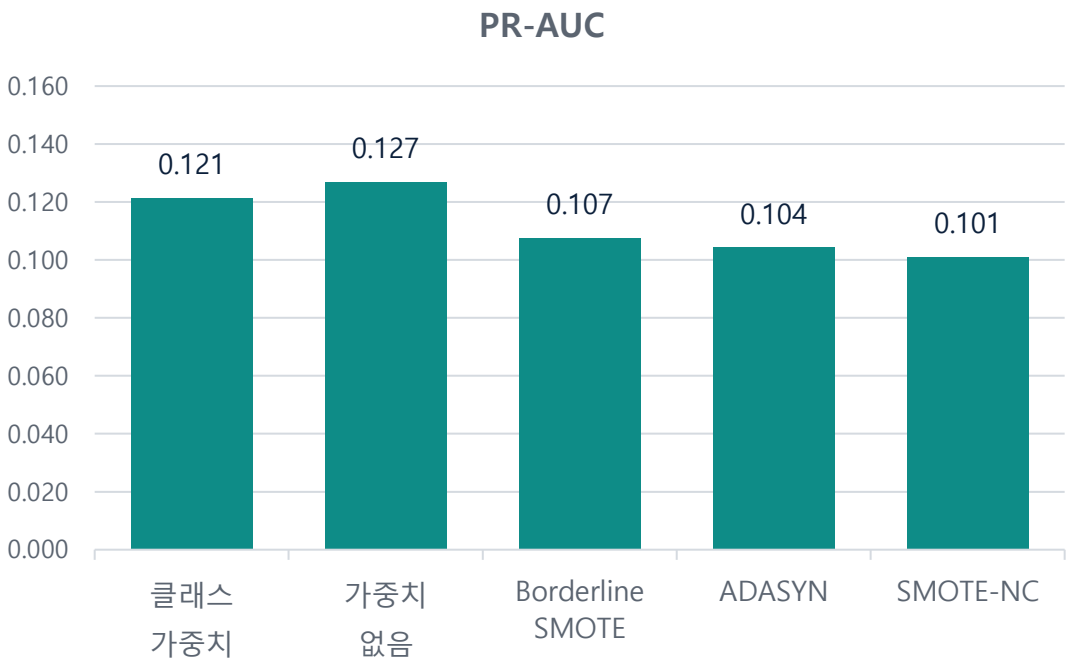
모델 차이보다 추정 캐비티 효과가 크다

① 최종모델 대비 짝 비교 (25 fold, PR-AUC)

비교 대상	승/패	보정 t p	Holm p
RF + ET 앙상블	15/10	0.872	1.000
CatBoost	14/11	0.944	1.000
RandomForest	17/8	0.695	1.000
LR (베이스라인)	20/5	0.316	1.000
ExtraTrees (캐비티 제외)	**25/0**	**0.001**	**0.011**

Recall@20%: 보정 t p<0.05 7개 → Holm 보정 후 0개

② 불균형 처리 비교 (최종모델 구조)



가중치 유무 차이는 유의하지 않음(p=0.66) → 설계값 유지. SMOTE 계열은 같은 공정값의 짝 사이에 합성 표본을 만들어 효과 없음

출처 outputs/significance.csv · imbalance_cv.csv

더 복잡한 모델은 이득이 없었다

방식	모델	PR-AUC	Recall@20%	ET 대비 승/패
배깅 앙상블	**ExtraTrees ★**	**0.121**	**0.700**	-
스태킹	ET·RF·XGB·LR → LR	0.109	0.598	9/16
딥러닝	MLP 32-16	0.064	0.493	4/21
딥러닝	MLP 64-32-16	0.062	0.512	1/24
비지도	오토인코더 (양품 학습)	0.114	0.302	-

같은 25개 fold · 스태킹 내부 CV도 사출 그룹 단위

통합 모델 vs 제품별 모델

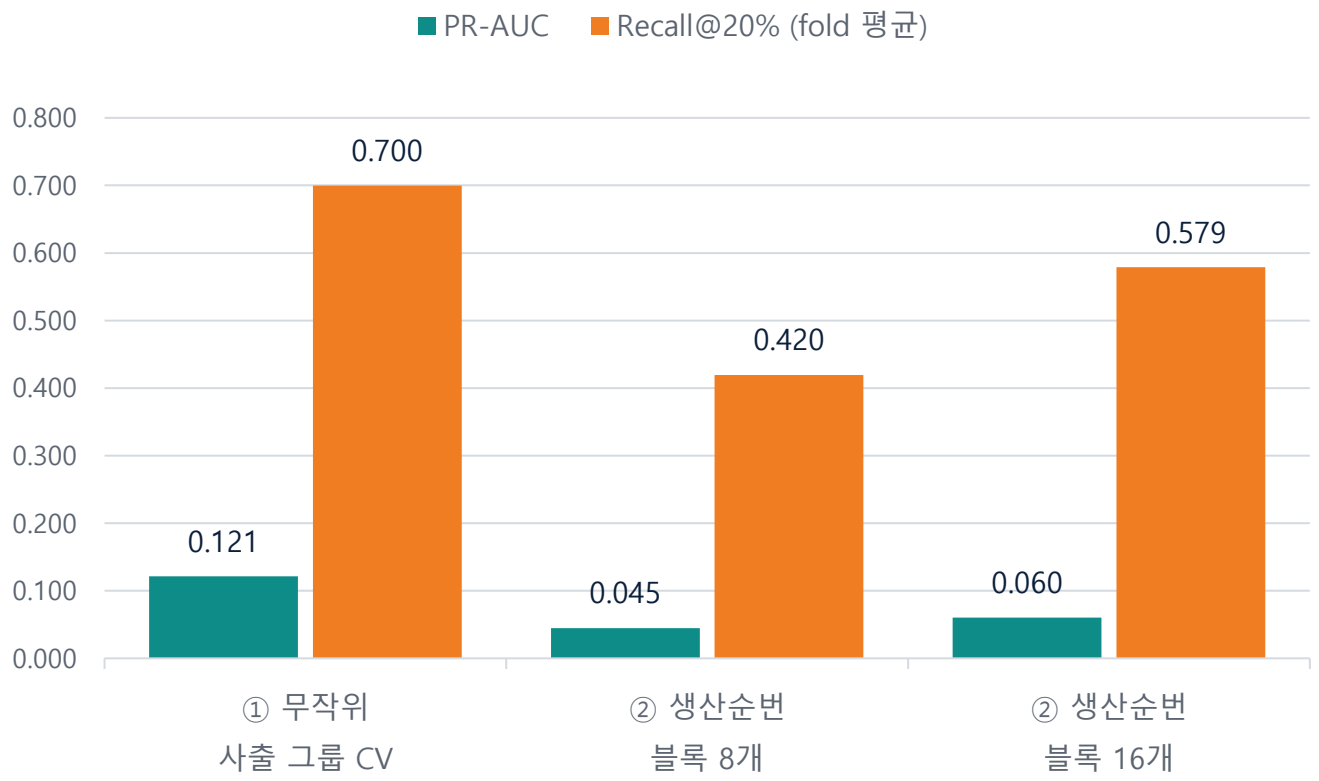
PR-AUC	통합	제품별
CN7	0.258	0.266
RG3	0.083	0.081

- 차이가 작아 관리가 단순한 통합 모델 사용
- CNN·LSTM은 이미지·시계열용이라 표 데이터에 쓰지 않음

데이터 규모와 형태에 맞는 모델: 불량 수십 건에서는 단순한 배깅 앙상블이 가장 안정적

출처 outputs/dl_stacking_cv.csv · autoencoder_cv.csv · product_model_cv.csv

같은 시기 사출을 빼면 성능이 크게 낮아진다



최종모델 ExtraTrees + 추정 캐비티 · 무작위 PR-AUC = 0.018

N/A

③ 과거→미래: CN7 평가 구간 4개 모두 불량 0건

③ 과거→미래: RG3

- PR-AUC **0.026~0.063** (무작위 0.016~0.043)
- 구간당 불량 3~8건이라 변동이 큼
- 추정 캐비티 효과는 블록 CV 에서도 유지

운영: 검사 결과를 라벨로 쌓아 재학습 · 처음 보는 불안정 구간은 규칙과 공정 흔들림 경보로 대응

출처 outputs/time_block_cv.csv · forward_cv.csv

테스트 불량은 8건뿐, 판정은 임계값보다 검사 용량 기준으로

범위	PR-AUC (95% CI)	ROC	Recall@20%
전체	0.343 (0.015~0.706)	0.781	0.500
CN7	0.674 (0.111~1.000)	0.987	1.000
RG3	0.017 (0.007~0.042)	0.391	0.000

사출 그룹 부트스트랩 1000회

개발셋 OOF 판정 기준별 비교

기준	TP	FN	FP
A. fold 임계값	3~12	22~31	99~205
B. 평균점수+공통임계값	26	8	371
C. 제품별 상위 20%	**22**	**12**	**360**

fold 임계값 0.028~0.432로 흩어짐

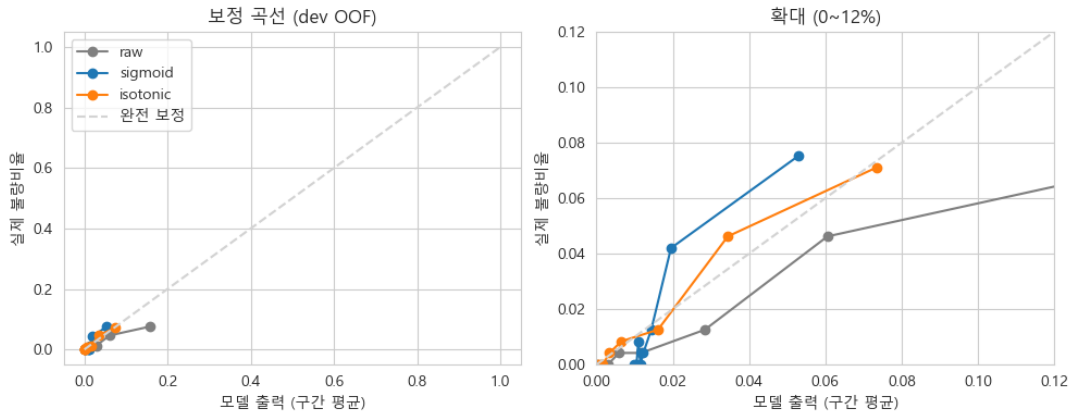
CN7 테스트 불량 4/4 를 상위 5% 안에서 포착, RG3 0/4
결론은 개발셋 CV 와 시간 검증 중심으로, 운영과 오류분석은 C 기준(검사 용량)으로

출처 outputs/test_metrics.json · test_bootstrap_ci.csv · oof_threshold_views.csv

순위는 보정 전 점수로, 화면에는 보정 확률로

방식	Brier	PR-AUC	평균 예측값
보정 없음	0.0186	0.121	0.034
sigmoid	**0.0173**	**0.117**	**0.018**
isotonic	0.0173	0.085	0.017

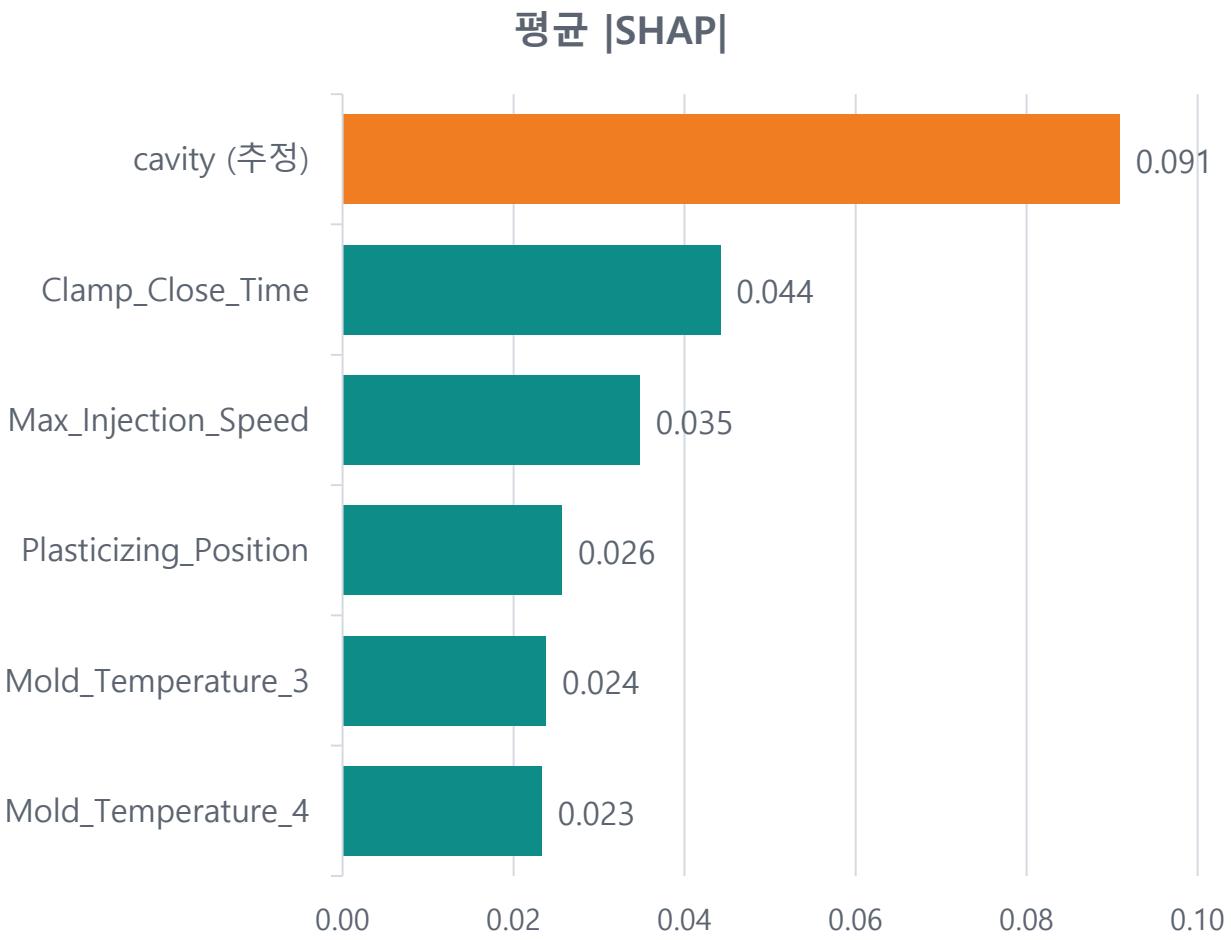
실제 불량률 0.018 · 같은 25개 fold

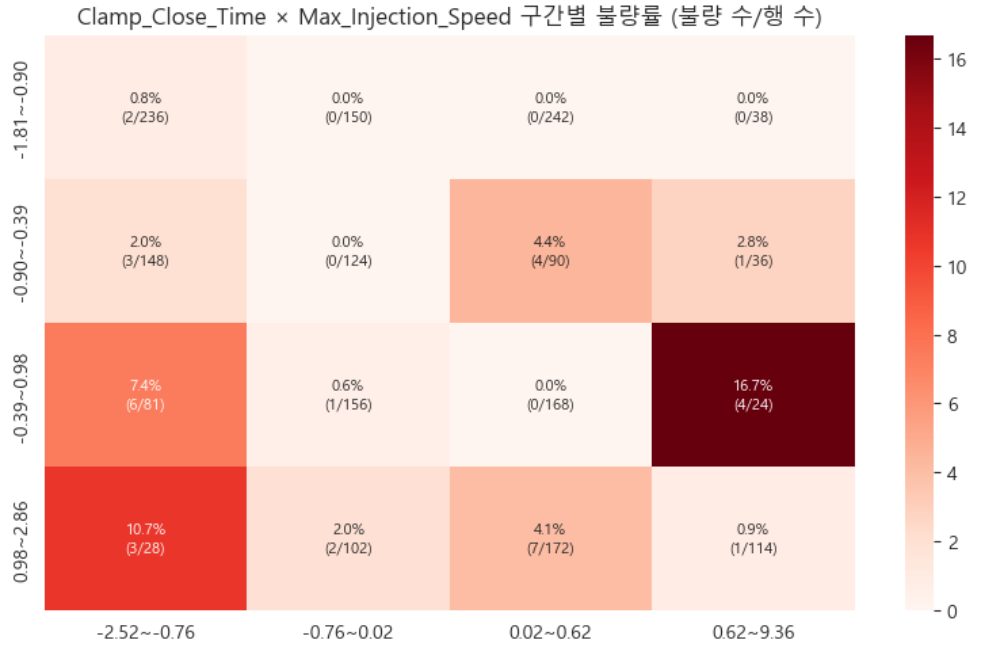


검사 순위: 보정 전 위험점수 · 현장 표시와 위험등급: sigmoid 보정 확률
보정 확률도 불량 34건으로 추정한 값이라 무작위 표본 검사로 계속 확인

출처 outputs/calibration_cv.csv

점수를 가장 크게 움직인 변수: 추정 캐비티와 형체 시간





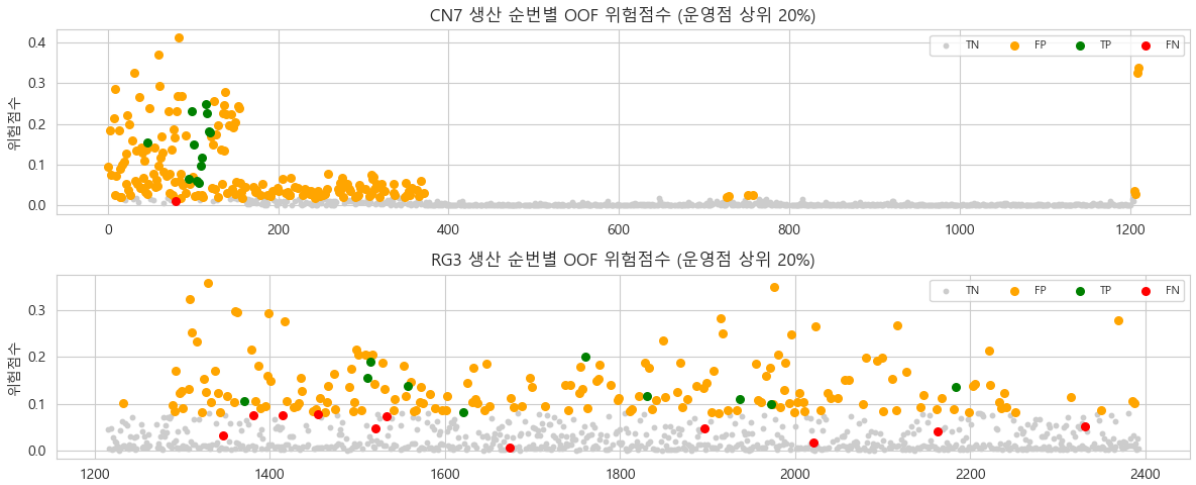
형체 시간 중상위 × 사출속도 최상위
불량률 16.7% (4/24)
표본이 작아 확인할 가설로 둠

출처 노트북 3-1 · 3-2

놓친 불량은 대부분 RG3, CN7 오경보는 가동 초기에 몰린다

제품·추정 캐비티	불량	TP	FN	FP
CN7 캐비티 0	10	10	0	124
CN7 캐비티 1	3	2	1	57
RG3 캐비티 0	20	10	10	177
RG3 캐비티 1	1	0	1	2

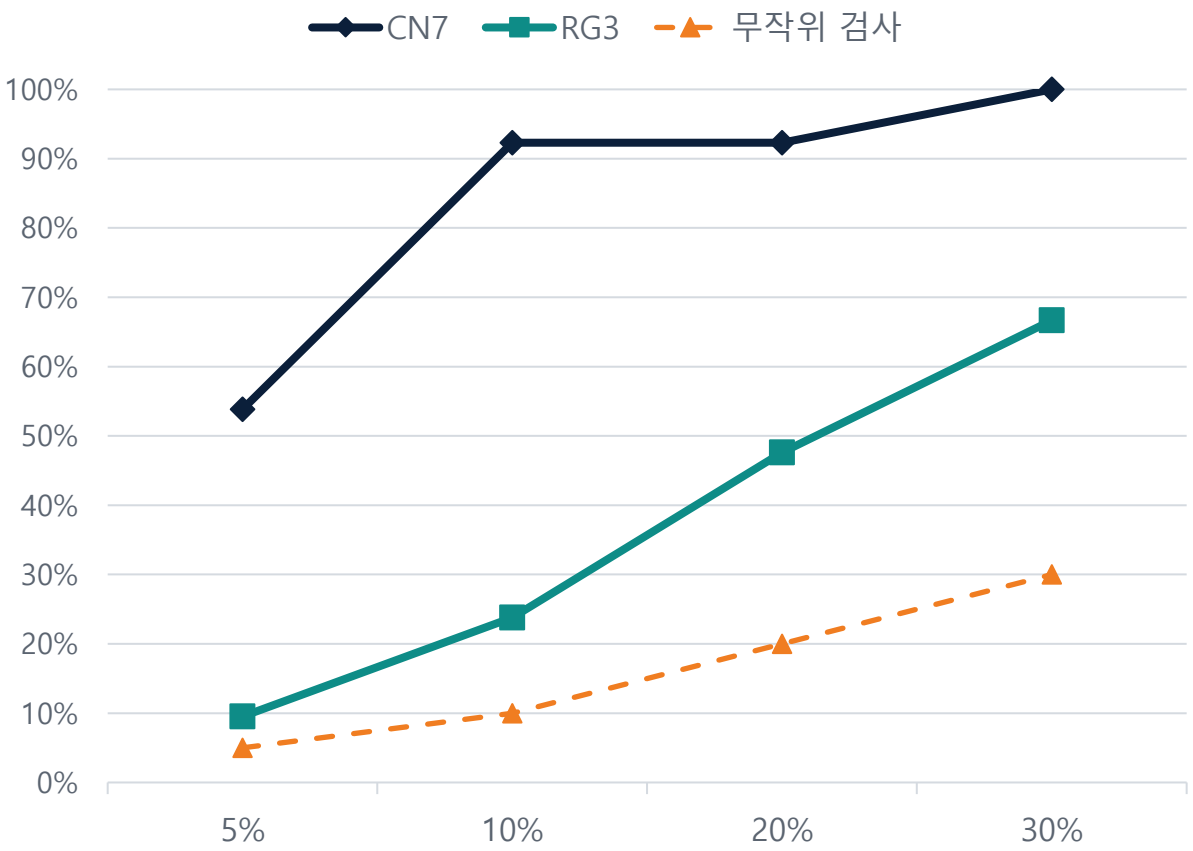
CN7 오경보 125건이 생산순번 0~20% (순번 0~238)에 집중



RG3 의 FN 은 라벨 충돌 때문이라 모델 조정으로 줄이기 어려움 → 추정 캐비티0 샘플 검사로 보완
오류 규칙나무(깊이 3)는 불량 34건으로 만든 요약이라 가설로만 사용

출처 outputs/oof_dev.csv · op_concentration.csv

검사 용량별 포착과 단순 규칙 비교



x축: 검사 비율(제품별 위험점수 상위) · y축: 불량 포착률 (개발셋 OOF 합산)

규칙	검사 비율	규칙	같은 양의 모델
CN7 초기 50사출 전수	10.3%	100%	92%
CN7 초기 100사출 전수	20.6%	100%	92%
추정 캐비티0 전수 (전체)	50.0%	88%	94%
추정 캐비티0 전수 (RG3)	50.0%	95%	90%

가동 초기·금형 교체 직후: 규칙으로 강화검사
안정 구간: 모델 상위 k% 검사
RG3: 추정 캐비티0 샘플 검사 병행

출처 outputs/capacity_table.csv · rule_baselines.csv (개발셋 OOF)

위험 등급의 불량률은 정상의 24배, 확인할 변수도 함께 제시

위험 · 상위 10%

191 불량 14 · 7.3%

같은 사출 그룹 2개 모두 검사

주의 · 다음 20%

382 불량 16 · 4.2%

그룹 중 1개 샘플 검사

정상 · 하위 70%

1,336 불량 4 · 0.3%

기존 샘플링 + 무작위 표본

테스트 예측결과 상위 예시

순위	제품·추정 캐비티	위험점수	보정 확률	기여 변수 1	기여 변수 2	기여 변수 3	실제
1	CN7 · 1	0.873	0.474	Max_Injection_Speed	Filling_Time	Cushion_Position	불량
2	CN7 · 0	0.871	0.476	Max_Injection_Speed	Filling_Time	Clamp_Close_Time	불량
3	CN7 · 0	0.339	0.228	추정 cavity	Clamp_Close_Time	Plasticizing_Position	양품
4	CN7 · 0	0.326	0.166	Clamp_Close_Time	추정 cavity	Mold_Temperature_4	양품

출처 outputs/test_predictions.csv (contrib_1~3)

비용 시나리오와 사전경보

① 비용 시나리오 (가정)

유출 : 검사	CN7 최적 검사	RG3 최적 검사
10 : 1	10%	0%
20 : 1	10%	24%
50 : 1	10%	45%
100 : 1	10%	54%

손익분기: 보정 확률 p ≥ 1/r 이면 검사하는 편이 기대비용상 유리
현장 비용비가 정해지면 같은 표로 검사 비율을 정함

② 사전경보 (이동평균 알람)

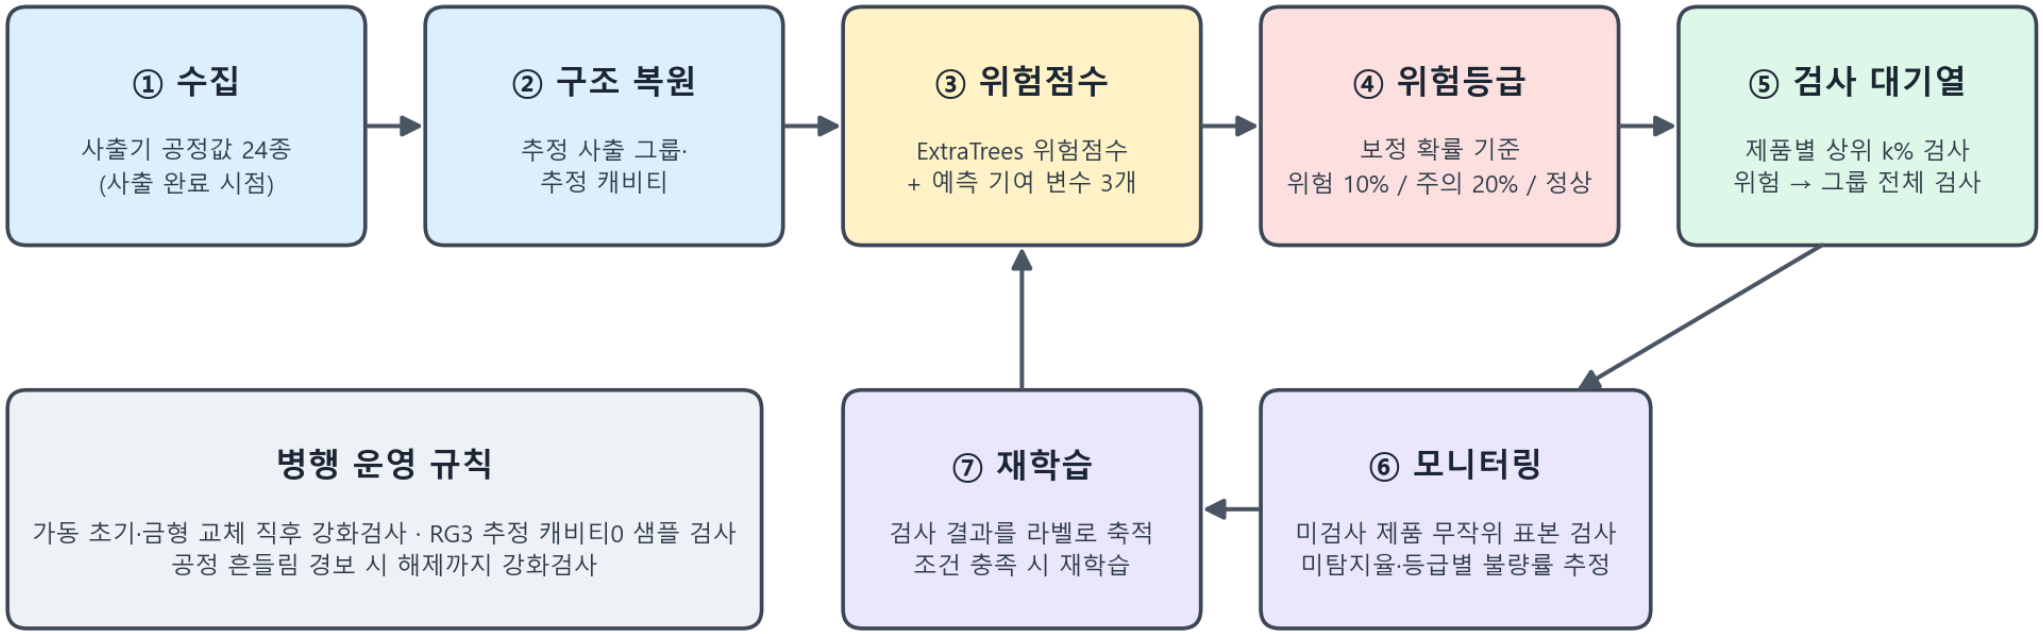
신호	첫 알람	첫 불량	사전 감지
CN7 공정 흔들림	**31**	**47**	**100%**
CN7 모델 점수	153	47	0%
RG3 공정 흔들림	1291	1347	14%

공정 흔들림 = 직전 10사출 평균 대비 공정값 편차 (라벨 미사용)
알람 기준을 같은 데이터에서 정했고 CN7 불안정 구간이 한 번뿐이라 낙관적

경보가 울리면 해제될 때까지 강화검사하고, 그 기간의 검사 결과를 라벨로 쌓아 재학습에 사용

출처 outputs/cost_best.csv · early_warning_summary.csv

현장 운영: 위험점수 → 등급 → 검사 → 모니터링 → 재학습



무작위 표본 검사

검사 대상에서 빠진 제품의 2~5%
→ 미탐지율·등급별 실제 불량률 추정

재학습 조건 (예시)

새 불량 라벨 누적 · 미탐지율 상승
금형·자재·설정 변경 · 경보 반복

재학습 절차

같은 그룹 분할·시간 검증·선정 규칙
등급 경계와 보정도 함께 갱신

출처 보고서 4장 · predict.py

선행연구와 비교

연구	데이터	방법	결과	본 연구와의 차이
한용희·고방원 (2025)	KAMP 886,227건 · 불량 1.2%	CNN-LSTM + 부스팅 앙상블, SMOTE·ADASYN	F1 0.815, AUC 0.978	불량 1만 건 → 부스팅 우세 / 본 데이터는 배깅 우세
홍지수 외 (2023)	KAMP 사출성형	XGBoost·LightGBM + SHAP·ICE	불량률 1.00% → 0.21%	원 단위 관리범위 (본 데이터는 표준화되어 불가)
조현민·신현준 (2021)	KAMP 36변수	DAE·LSTM·CNN	Accuracy·F1 약 100%	검증 분할 방식 확인 불가
Kim et al. (2021)	차량 사이드몰딩 · 불량 4%	표 + 금형 내 온도 시계열	F1 0.625 → 0.75	센서 시계열의 가치 → 센서 추가 제안 근거
본 연구	**제공본 2,393건 · 불량 42**	**7종 비교 + 추정 캐비티, 검증 3종**	**PR-AUC 0.121**	**생산 구조 복원 · 운영점 평가**

행 단위 무작위 분할에서는 같은 사출의 짝이 학습·평가에 나뉘어 성능이 높게 나올 수 있음
본 데이터에서는 ExtraTrees 기준 +52%

출처 한용희·고방원(2025) · 홍지수 외(2023) · 조현민·신현준(2021) · Kim et al.(2021)

흔한 접근과 다른 점

흔한 접근	문제	본 프로젝트
정확도 KPI	전부 양품이어도 98%	PR-AUC · Recall@k%
완전 동일 행 삭제	같은 사출의 불량 라벨 삭제	추정 사출 그룹으로 유지
행 단위 무작위 분할	성능 +52% 과대평가	그룹 분할 + 누수 점검
검증 숫자 하나	시간 효과를 놓침	검증 3종으로 성능 범위
임계값 판정	fold 마다 임계값이 흔들림	검사 용량 기준 운영 + 규칙 비교

KAMP 분석도구 활용

기술통계 · 상관분석	데이터 진단
K-평균 군집	운전구간 분리
랜덤포레스트 · XGBoost	모델 7종 비교
오토인코더	비지도 비교

제외: CNN · YOLOv8(이미지), LSTM(시계열·음향),
회귀분석(연속 목표)
준지도(자기학습)는 별도 실험으로 판단

출처 KAMP 분석도구 · 제조AI 기술 동향

명령 한 줄로 전처리부터 예측결과까지 재현

실행

```
pip install --user -r requirements.txt
python run_all.py
```

- CPU 약 60분 · --quick(반복 1회) · --no-extra · --clean
- 로직은 src/ 모듈에만, run_all.py 와 노트북이 같은 함수 사용
- run_manifest.json: 버전·입력 해시 기록, 노트북이 불일치 경고
- outputs/model/ 저장 → predict.py 로 재학습 없이 추론

환경

	결과 생성 (로컬)	KAMP-NOTE (노트북 확인)
Python	3.12.7	3.11.9
scikit-learn	1.5.1	1.4.2
lightgbm	4.6.0	4.5.0
xgboost · catboost	3.4.1 · 1.2.10	--user 설치

제출 산출물

test_predictions.csv: 위험점수 · 보정 확률 · 등급 · 검사 순위 · 기여 변수
analysis.ipynb: 보고서 그림·표 재현, 결과 일치 확인

출처 README.md · outputs/run_manifest.json

CONCLUSION · Q&A

생산 구조를 반영해 검증하고 검사 우선순위로 연결했다

6.9배

무작위 대비 PR-AUC (그룹 CV)

12/13

CN7 상위 20% 검사 포착 (OOF 합산)

24배

위험 vs 정상 등급 불량률

+52%

행 단위 검증의 과대평가

한계와 다음 단계

같은 시기 사출을 빼면 PR-AUC 0.045~0.060, CN7 과거→미래 검증 불가 · 불량 42건으로 모델 간 차이 비유의

RG3 는 공정값에 신호 없음 → 캐비티별 압력·온도 센서 · CN7 시범 운영과 무작위 표본 검사로 효과 확인

Q&A