MATRIX 25-2 컨퍼런스 · 2팀 프로젝트 분석 보고서

Animal Shelter 프로젝트 분석 보고서

보호동물 입양·안락사 예측 프로젝트의 구조, 내용, 문제점과 개선 방향

대상 자료 | 노트북 3종 · 발표자료(19p) · 기획서 교수님 코멘트 · 원본 데이터 재검증
작성일 | 2026년 9월 25일

한 줄 요약

> 오스틴 동물보호센터의 입·퇴소 기록 12만 건으로 **입양 가능성**과 **안락사 위험**을 예측해, 보호소가 **입소 즉시 누구에게 먼저 개입할지** 정하는 우선순위 점수를 만드는 프로젝트입니다. 교수님 피드백은 대부분 성실히 반영되었지만, **최종 모델 선정 근거**와 **안락사 성능의 원천**에 대해 재검토가 필요한 지점이 원본 데이터 재검증에서 확인되었습니다.

목차

1	한눈에 보기	프로젝트를 1페이지로 요약
2	프로젝트 개요	목적 · 데이터 · 핵심 질문
3	파일 구조	폴더 안 파일들이 각각 무엇인지
4	분석 흐름 (Step 1~12)	노트북이 실제로 하는 일을 단계별로
5	주요 결과	EDA · 다중분류 · 안락사 모델 비교 · 불균형 대응 · 운영 전략
6	교수님 피드백 반영 현황	8개 코멘트별 반영 / 부분 반영 / 미반영
7	문제점 분석	원본 데이터로 재검증한 7가지 문제와 해결 방법
8	개선 로드맵	무엇부터 고칠지 우선순위
부록	개념 정리	이 프로젝트에 등장하는 머신러닝·통계 개념 30여 개

SECTION 1

한눈에 보기

바쁘다면 이 페이지만 읽어도 프로젝트 전체를 파악할 수 있도록 정리했습니다.

구분	내용
무엇을	보호소에 들어온 동물이 **입양될지**, **안락사될지**를 입소 시점 정보만으로 예측
왜	공간·예산이 제한된 보호소가 **입양이 어렵고 안락사 위험이 높은 동물**을 조기에 찾아 자원을 먼저 배분하기 위해
데이터	Kaggle Animal Shelter Analytics (미국 오스틴 동물보호센터, 2013.10~2021.03) · 입소 124,120건 + 퇴소 124,491건 → 병합 후 122,847건
방법	① 결과 5종 다중분류로 전체 구조 탐색 → ② 입양 이진모델 → ③ 안락사 모델을 **직접모델**(전체 개체)과 **2단계모델**(비입양 개체)로 비교 → ④ 로지스틱 회귀 · 랜덤포레스트 · LightGBM 3종 비교
결과	안락사 모델: 2단계 LightGBM 채택 (Recall 0.817, PR-AUC 0.777, ROC-AUC 0.932) 운영 점수: **우선순위 = (1 - P(입양)) × P(안락사 | 비입양)**
잘한 점	교수님 피드백 1:1 반영 · 동물 ID 기준 분할로 재방문 누수 차단 · Outcome Subtype·체류기간 등 사후 정보 제외 · Recall/PR-AUC 중심 평가

재검증에서 확인된 핵심 문제 3가지

#	문제	한 줄 설명	심각도
1	최종 모델 선정 근거	2단계 PR-AUC 0.777 vs 직접 0.746은 **평가 대상 집단이 달라서** 생긴 차이. 같은 기준으로 비교하면 **0.754 vs 0.746, 사실상 동률**	높음
2	안락사 성능의 원천	안락사의 **54%가 야생동물(박쥐 등)**. 개·고양이만 보면 PR-AUC가 **0.41**로 급락	높음
3	입·퇴소 병합 오류	방문 순번끼리 짝지으면서 **체류기간이 음수인 행 694개** 발생 → 일부 기록이 엉뚱한 퇴소와 연결	중간

총평

결론적으로 **분석 설계는 탄탄하지만**, 발표에서 "2단계 모델이 성능상 우월하다"고 주장하는 부분과 "안락사 위험을 0.8 이상의 재현율로 잡아낸다"는 부분은 **근거를 보완하거나 표현을 조정**해야 합니다. 자세한 내용은 7장, 개념 설명은 부록에 있습니다.

SECTION 2

프로젝트 개요

2.1 문제 정의

> **"데이터로 입양이 어렵고 안락사 위험이 높은 개체를 입소 즉시 선별할 수 있는가?"**

- 오스틴 보호센터는 연간 수만 건의 입소가 발생하지만, 모든 동물에게 충분한 관리를 제공하기 어렵습니다.
- 현재는 실무자의 **경험적 판단**에 의존 → 입양 가능성이 낮은 동물을 **조기에** 찾아내는 데이터 기반 체계가 부족합니다.
- 목표: 실무자의 판단을 **보조**하는 조기 선별 도구 (자동 처분 결정용이 아님)

2.2 데이터

파일	내용	규모
Austin_Animal_Center_Intakes.csv	입소 기록: 입소 일시, 발견 장소, 입소 유형(유기·소유자 인계·야생동물 등), 건강 상태, 동물 종류, 성별·중성화, 나이, 품종, 색상, 이름	124,120행 × 12열
Austin_Animal_Center_Outcomes.csv	퇴소 기록: 퇴소 일시, 생년월일, **결과 유형(Outcome Type)**, 결과 세부사유(Subtype) 등	124,491행 × 12열
Austin_Animal_Center_Stray_Map.csv	유기동물 발견 위치 (프로젝트에서는 미사용)	소량

결과(Outcome) 5개 범주의 분포 — 이 분포가 이후 모든 설계의 출발점입니다.

결과	의미	비율	성격
입양 (Adoption)	새 가정으로 입양	44.3%	가장 좋은 결과
이송 (Transfer)	다른 보호단체·구조단체로 이동	29.5%	중립
반환 (Return to Owner)	원래 주인에게 돌아감	17.4%	좋은 결과
안락사 (Euthanasia)	안락사	6.8%	가장 나쁜 결과 · 소수 클래스
기타	사망·실종·폐기 등	2.0%	잡음이 많음

2.3 팀과 진행 경과

- 팀: MATRIX 25-2 컨퍼런스 2팀 (전건우 · 이시현 · 성소연)
- 기획서 단계: 입양/비입양 이진분류 + 비입양군 안락사 2단계 모델로 계획 → 교수님께 8가지 질문
- 피드백 반영: 다중분류 탐색, 전체 개체 직접모델 추가, 나이 오류 삭제, 불균형 대응 전략 비교 등
- 최종 발표: 19페이지 발표자료 (입양 모델 LightGBM + 안락사 모델 비입양군 LightGBM + 운영 지침)

SECTION 3

파일 구조

프로젝트 폴더에 있는 파일들이 각각 어떤 역할을 하는지 정리했습니다.

파일	역할	비고
Animal Shelter Analytics.ipynb	**초기 버전**. 입양 이진분류 기준 전처리까지 (step 1~10)	피드백 반영 전
Animal_Shelter_Analytics_updated.ipynb	**피드백 반영 버전**. 다중분류 탐색, 안락사 타깃, 나이 오류 삭제, is_multicolor 추가	step 1~10
Animal_Shelter_Analytics_Final.ipynb	**최종 버전**. updated + 안락사 모델 3종×2전략 비교(step 11) + 불균형 전략 비교(step 12) + 다중분류 부록	**기준 노트북**
.ipynb_checkpoints/	주피터 자동 저장본	무시해도 됨
X_train / X_test.csv	전처리·인코딩이 끝난 특성 데이터 (65개 열)	98,342 / 24,505행
y_train / y_test.csv	입양 여부 타깃 (target_adoption)	
y_euth_train / y_euth_test.csv	안락사 여부 타깃 (target_euthanasia_all)	
target_distribution.png 외 3개	EDA 그래프 이미지	안락사 비교 그래프는 폴더에 없음
반려동물 데이터셋.zip	원본 CSV 3개	
2조_기획서_코멘트.docx	기획서 + 교수님 피드백 8개	
컨퍼런스2조 발표자료.pdf	최종 발표 슬라이드 19페이지	

참고

세 노트북은 **같은 코드가 점점 확장된 것**입니다. 앞부분(step 1~10)은 거의 동일하고, Final에만 모델링(step 11~12)과 다중분류 부록이 있습니다. 단, 발표자료에 나오는 **입양 모델 튜닝과 SHAP 분석 코드는 이 폴더에 없습니다** (다른 팀원 파일로 추정). 제출·재현을 위해서는 하나의 최종 노트북으로 합치는 것이 좋습니다.

SECTION 4

분석 흐름 (Step 1~12)

Final 노트북이 실제로 수행하는 과정을 순서대로 정리했습니다.

1	**데이터 병합**	입소·퇴소를 **Animal ID + 방문 순번(visit_seq)**으로 짝지음. 같은 동물이 여러 번 들어온 경우 1번째 입소↔1번째 퇴소, 2번째↔2번째… → 123,566행
2	**기본 탐색**	컬럼·타입·결측치 확인. Outcome Subtype 결측 54%, 이름 결측 31.5%
3	**타깃 정의**	결과를 5개 범주(입양/반환/이송/안락사/기타)로 정리 → **target_adoption**(입양=1), **target_euthanasia_all**(안락사=1) 두 개의 이진 타깃 생성
4	**결측치 처리**	이름 없음 → 'Unknown', 성별 결측 1건 → 최빈값. Outcome Subtype은 **결과를 누설**하므로 삭제
5	**나이 처리**	'2 years' 같은 문자열 → 일(day) 단위 숫자. 음수·30세 초과 **7건 행 삭제**
6	**날짜 파생**	입소 연·월·요일, 계절(6구간), 재방문 여부, 체류기간(음수 행 삭제)
7	**범주형 처리**	Bird·Livestock → Other. 품종 2,619종·색상 594종 → **상위 15개 + Other**. 혼종 여부, 다색 여부, 이름 유무, 성별/중성화 분리
8	**EDA**	동물 종류·입소 유형·나이대·계절별 입양률, 체류기간 비교
9	**인코딩**	특성 14개 선택 → 원-핫 인코딩 → 65개 열 (122,847행)
10	**데이터 분할**	**GroupShuffleSplit**(Animal ID 기준) 8:2. 같은 동물이 학습·평가에 동시에 들어가지 않음 (중복 0건)
11	**안락사 모델 비교**	모델 3종(로지스틱 회귀 · LightGBM · 랜덤포레스트) × 전략 2종(직접 / 2단계) = 6개 조합을 test에서 평가
12	**불균형 전략 비교**	2단계 데이터로 ① class_weight ② 임곗값 조정 ③ SMOTE를 반복 교차검증으로 비교
부록	**다중분류**	5개 범주를 LightGBM 하나로 직접 분류 (참고용)

데이터 준비 | 타깃 설계 | 전처리 · 특성공학 | 모델링 · 평가 | 참고

4.1 최종 운영 구조 (발표자료 기준)

입소 동물 정보 입력 → **1차 모델** P(입양) → **2차 모델** P(안락사 | 비입양) → **우선순위 점수** (1-P(입양)) × P(안락사|비입양)

- **학습할 때**: 1차·2차 모델은 각각 **실제 정답**으로 따로 학습 (2차 모델은 실제 비입양 개체만 사용) → 1차 모델의 오류가 2차 학습에 섞이지 않음
- **사용할 때**: 새 동물이 오면 두 모델을 차례로 적용해 점수를 계산하고 상·중·하 등급으로 분류
- **운영 원칙**: 모델은 보조 도구 · 직원 검토 필수 · 월별 Recall/PR-AUC 모니터링

SECTION 5

주요 결과

5.1 EDA — 입양에 영향을 주는 요인

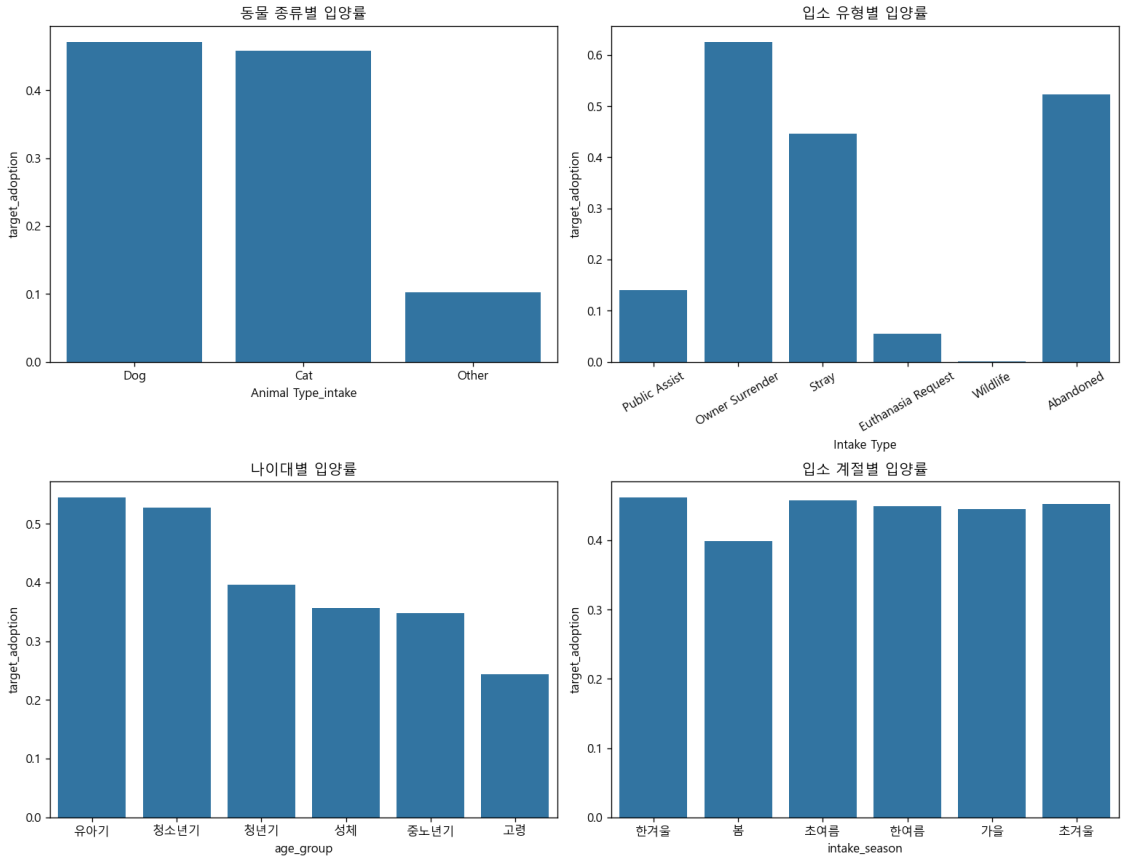


그림 1. 동물 종류 · 입소 유형 · 나이대 · 계절별 입양률 (노트북 step 8 출력)

관찰	수치 / 내용	해석
동물 종류	개 47.1% · 고양이 45.8% · 기타 10.3%	기타(야생동물 등)는 입양이 거의 없음
입소 유형	소유자 인계는 높고, 안락사 요청·야생동물은 매우 낮음	입소 경로가 결과를 강하게 결정
나이	나이가 많을수록 입양률 감소	고령 동물 맞춤 지원 필요
계절	계절별 차이 작음	변수 유지 여부는 제외 실험으로 결정해야 함
이름 유무	이름 있음 52.4% · 없음 26.7% (재검증)	강한 신호지만 누수 점검 필요 (문제 4)

5.2 다중분류 — 결과 5개를 한 번에 예측하면?

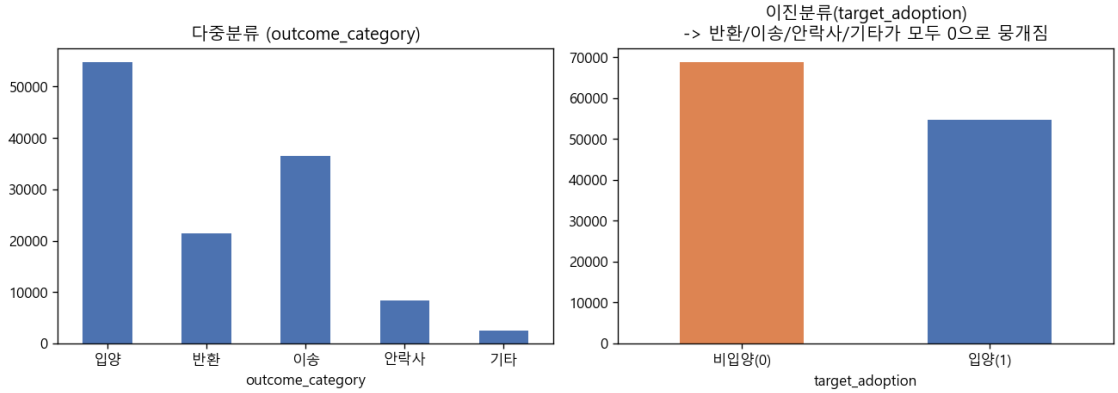


그림 2. 다중분류(왼쪽)와 입양 이진분류(오른쪽). 이진분류에서는 반환·이송·안락사·기타가 모두 0으로 합쳐짐

클래스	Precision	Recall	F1	test 건수	해석
입양	0.69	0.64	0.66	10,944	비교적 잘 구분
반환	0.49	0.81	0.61	4,224	많이 잡지만 오탐도 많음
이송	0.71	0.44	0.54	7,130	입양·반환과 자주 혼동
안락사	0.65	0.74	0.69	1,695	소수지만 패턴이 뚜렷
기타	0.09	0.19	0.13	512	사실상 예측 불가

Accuracy 0.608 · Balanced Accuracy 0.564 (LightGBM, class_weight=balanced). → 결과마다 특성이 달라 **운영 목적별 이진 모델로 나누는 결정**의 근거가 되었습니다.

5.3 안락사 모델 비교 (노트북 step 11, test 기준)

전략	모델	Recall	Precision	F1	PR-AUC	ROC-AUC
2단계 (비입양군)	**LightGBM**	0.817	0.587	0.683	**0.777**	0.932
2단계 (비입양군)	Random Forest	0.750	0.722	**0.736**	0.775	0.928
2단계 (비입양군)	Logistic Reg.	0.809	0.552	0.657	0.743	0.918
직접 (전체개체)	LightGBM	0.819	0.506	0.626	0.746	**0.941**
직접 (전체개체)	Random Forest	0.749	0.692	0.719	0.744	0.937
직접 (전체개체)	Logistic Reg.	**0.823**	0.438	0.571	0.723	0.933

- LightGBM은 Recall·PR-AUC가 높고, 랜덤포레스트는 Precision·F1이 높음 → **모델마다 강점 지표가 다름**
- 팀의 결론: PR-AUC가 가장 높은 **2단계 LightGBM을 최종 채택**. 단, 이 비교에는 함정이 있음 → **7장 문제 1**

5.4 불균형 대응 전략 비교 (노트북 step 12, 2단계 데이터 · 로지스틱 회귀)

전략	방법	Recall	PR-AUC	비고
① class_weight	소수 클래스(안락사)에 가중치를 더 줌	0.798 ± 0.013	0.731 ± 0.013	5-fold × 5회 반복
② + 임곗값 조정	Recall ≥ 0.8이 되는 기준점 탐색	0.800	—	임곗값 0.499 (기본값과 거의 같음)
③ SMOTE	학습 폴드 안에서만 소수 클래스 합성	0.706 ± 0.014	0.702 ± 0.011	오히려 성능 하락

교수님 권고("class_weight → 임곗값 → 반복 CV 우선, 오버샘플링은 학습 폴드 안에서만")를 따른 설계입니다. 결과적으로 **class_weight만으로 충분**했고 SMOTE는 도움이 되지 않았습니다. 다만 검증 방식에 보완점이 있습니다 (문제 5).

5.5 발표자료의 최종 결론

항목	내용
입양 모델	LightGBM (튜닝 + 동물 ID 그룹 검증). 실제 비입양 개체의 69.2%를 사전 식별, 비입양 예측의 79.7%가 실제 비입양
입양 주요 요인 (SHAP)	성별 미확인 → 입양↓ · 고연령 → 입양↓ · 이름 보유 → 입양↑ · 입소 유형별 차이. 계절·성별은 영향 작음
안락사 모델	비입양군 2단계 LightGBM (Recall 0.817 · PR-AUC 0.777)
안락사 주요 요인	1위 나이, 2~4위 입소 시점 · 이름 유무 · 건강상태(부상·질병)
운영 전략	고령 → 입양 프로그램·임시보호 / 건강 문제 → 입소 시 의료 스크리닝 / 이름 없음 → 프로필·이름 부여·홍보

SECTION 6

교수님 피드백 반영 현황

기획서에 달린 교수님 코멘트 8개가 최종 노트북에 어떻게 반영되었는지 점검했습니다.

#	교수님 코멘트 (요약)	반영 상태	실제 반영 내용 / 남은 과제
1	입양/비입양만 쓰면 결과 의미가 뭉개짐 → 5개 범주로 탐색·다중분류 후 목적별 이진모델	반영	outcome_category 생성, 다중분류 LightGBM 부록, 두 이진 타깃 파생
2	비입양군 내부 모델 + 전체 개체 직접모델도 만들어 비교	부분 반영	두 전략 모두 구현. 단 **평가 대상 집단이 달라** 공정 비교가 아님 (문제 1)
3	class_weight · 임곗값 · 반복 CV 우선, 오버샘플링은 폴드 안에서만. Recall·PR-AUC 중심	부분 반영	3전략 비교 구현. 단 임곗값을 학습 데이터로 정함, CV가 동물 ID 단위가 아님 (문제 5)
4	나이 오류 7건은 중앙값 대체보다 행 삭제	반영	7건 삭제로 변경
5	나이는 연속형 유지 + 생애단계 변수. 동물은 사람과 나이 스케일이 다름	부분 반영	age_days 유지 + age_group 추가. 단 **개·고양이에 같은 구간** 사용
6	품종·색상 → 순종/혼종, 주된 품종군, 단색/다색 등 상위 범주	부분 반영	is_mixed_breed, is_multicolor 추가. **품종군**(목양견·테리어 등)은 미구현
7	계절 변수는 넣은 뒤, 뺐을 때 성능과 비교해 결정	미반영	제외 실험(ablation) 없음
8	결과 범주와 데이터 누수 가능성 정리	부분 반영	Outcome Subtype·체류기간 제외는 잘 됨. **이름 변수**와 병합 오류 점검 필요 (문제 3, 4)

요약

8개 중 **완전 반영 2개, 부분 반영 5개, 미반영 1개**. 방향은 모두 맞게 잡았고, "부분 반영"은 대부분 **검증 방식의 세부**에서 생긴 빈틈이라 짧은 코드 수정으로 보완할 수 있습니다.

SECTION 7

문제점 분석

원본 데이터와 저장된 X/y 파일로 직접 다시 계산해 확인한 문제들입니다. 모든 수치는 재현 스크립트로 계산했습니다 (부록 B).

문제 1 직접모델 vs 2단계 모델 비교 기준이 다르다

심각도 높음

무엇이 문제인가

2단계 모델은 **실제로 입양되지 않은 동물만** 모은 test(13,561건, 안락사 12.5%)에서 평가했고, 직접모델은 **전체** test(24,505건, 안락사 6.9%)에서 평가했습니다. PR-AUC는 **양성 비율이 높을수록 자동으로 올라가는 지표**라서 두 숫자를 나란히 놓고 비교할 수 없습니다.

근거 (수치)

평가 방식	직접모델	2단계	차이
노트북 방식 (서로 다른 집단)	0.746	0.777	+0.031
공정 비교: 전체 test, 동일 기준	**0.746**	**0.754**	**+0.008**
공정 비교 ROC-AUC	0.941	0.941	0.000
Recall 0.8에서 Precision	0.579	0.577	-0.002

왜 중요한가

발표의 **최종 모델 선정 근거**("PR-AUC 우위")가 흔들립니다. 또한 수학적으로 (1-P(입양)) × P(안락사|비입양) = P(비입양) × P(안락사|비입양) ≒ **P(안락사)**이므로, 두 방식은 **같은 값을 다른 경로로 추정**하는 셈이라 성능이 비슷한 것이 자연스럽습니다.

해결 방법

① 두 방식 모두 **전체 test에서 최종 점수로** 평가하는 표를 추가 ② 선정 근거를 "성능 우위"에서 **"성능은 동등하고, 입양→안락사 순서의 운영 흐름과 맞으며 해석이 쉬움"**으로 수정

```
p_adopt  = adopt_model.predict_proba(X_test)[:, 1]
p_stage2 = stage2_model.predict_proba(X_test)[:, 1]   # 전체 test에 적용
p_pipe   = (1 - p_adopt) * p_stage2                   # 발표의 우선순위 점수
p_direct = direct_model.predict_proba(X_test)[:, 1]

for name, p in [("직접", p_direct), ("2단계", p_pipe)]:
    print(name, average_precision_score(y_euth_test, p), roc_auc_score(y_euth_test, p))
```

문제 2 안락사 예측 성능의 대부분은 야생동물에서 나온다

심각도 높음

무엇이 문제인가

안락사 사례의 절반 이상이 **개·고양이가 아니라 야생동물**(박쥐·너구리 등, 'Other')입니다. 야생동물은 광견병 위험으로 거의 자동 안락사되므로, 모델이 "야생동물이면 안락사"라는 쉬운 규칙만으로도 높은 점수를 받습니다.

근거 (수치)

항목	값
안락사 중 Other(야생동물 등) 비율	**54.2%** (고양이 23.2%, 개 21.2%)
안락사 중 입소 유형 Wildlife 비율	51.4%
안락사 사유 1위	광견병 위험 (Rabies Risk) 45.4%, 고통(Suffering) 39.8%
직접모델 PR-AUC — Other만	0.897 (안락사 비율 63.1%)
직접모델 PR-AUC — **개·고양이만**	**0.413** (안락사 비율 3.3%)

왜 중요한가

보호소가 실제로 **개입할 수 있는 대상은 개·고양이**입니다. 박쥐를 "안락사 고위험"으로 맞히는 것은 운영에 도움이 되지 않으므로, 발표의 Recall 0.82·PR-AUC 0.78은 **실제 활용 가치보다 과대평가**된 수치입니다.

해결 방법

① 안락사 모델을 **개·고양이만으로** 다시 학습·평가 (또는 종류별 성능을 따로 보고) ② 야생동물은 규칙(입소 유형 = Wildlife)으로 따로 처리한다고 명시 ③ 개·고양이 기준 성능을 발표의 주 수치로 사용

문제 3 입·퇴소 병합 시 순번이 어긋나는 기록이 있다

심각도 중간

무엇이 문제인가

같은 동물의 n번째 입소를 n번째 퇴소와 짝짓는 방식은 **입소·퇴소 횟수가 같을 때만** 정확합니다. 데이터 수집 시작(2013.10) 이전에 입소한 동물, 기록 누락·중복이 있으면 순번이 한 칸씩 밀립니다.

근거 (수치)

항목	값
입소 횟수 ≠ 퇴소 횟수인 동물	1,478마리 / 111,740마리
병합 후 체류기간이 음수인 행	**694행** (최소 -2,274일)
완전히 같은 중복 행 (입소 / 퇴소)	19행 / 17행

왜 중요한가

노트북은 음수 체류기간 행만 지웠지만, **순번이 밀린 동물의 다른 행**은 양수라도 엉뚱한 퇴소와 연결되어 있을 수 있습니다. 타깃(결과) 자체가 틀린 행이 섞이는 문제입니다.

해결 방법

중복 행을 먼저 제거하고, **'입소 이후 가장 가까운 퇴소'**를 찾는 **pd.merge_asof**로 병합합니다.

```
intakes  = intakes.drop_duplicates().sort_values("t_in")
outcomes = outcomes.drop_duplicates().sort_values("t_out")
df = pd.merge_asof(intakes, outcomes, left_on="t_in", right_on="t_out",
                   by="Animal ID", direction="forward")  # 입소 이후 첫 퇴소
# 두 입소가 같은 퇴소에 붙은 경우 → 더 최근 입소만 남김
df = df.drop_duplicates(subset=["Animal ID", "t_out"], keep="last")
```

문제 4 이름 유무 변수에 데이터 누수 가능성

심각도 중간

무엇이 문제인가	이 데이터의 이름 중 **22.6%가 '*'로 시작**하는데, 이는 **보호소가 붙여준 이름**이라는 표시입니다. 보호소는 보통 입양 홍보를 위해 이름을 붙이므로, 이름이 **입소 시점에 있었는지, 나중에 붙었는지** 불분명합니다.
근거 (수치)	이름 있음 입양률 52.4% vs 없음 26.7% — 매우 강한 신호. 발표에서 has_name을 **'예측 핵심 변수'**로 소개하고, 안락사 모델에서도 2~4위 중요 변수로 나옵니다.
왜 중요한가	만약 이름이 입양 준비 과정에서 붙는 것이라면, 모델은 "입양될 동물"이 아니라 **"이미 입양 준비 중인 동물"**을 맞히는 것이 됩니다. 이는 실제 입소 순간에는 쓸 수 없는 정보(누수)입니다.
해결 방법	① '*' 이름을 '이름 없음'으로 보는 버전(**has_original_name**)을 만들어 성능 비교 ② has_name을 빼고 학습해 성능이 얼마나 떨어지는지 확인 ③ 발표에서 "이름 부여 → 입양"을 **인과**처럼 표현하지 않기

문제 5 불균형 실험(step 12)의 검증 방식

심각도 중간

무엇이 문제인가	교수님 권고를 따른 구조는 맞지만 세부 구현에 세 가지 빈틈이 있습니다.
근거 (수치)	① **임곗값을 학습 데이터로 정함** — 학습에 쓴 데이터로 기준점을 찾으면 성능이 낙관적으로 나옵니다. 결과 임곗값 0.499는 기본값 0.5와 같아 사실상 효과가 없습니다. ② **교차검증이 동물 ID 단위가 아님** — RepeatedStratifiedKFold는 같은 동물의 여러 방문을 학습 폴드와 검증 폴드에 나눠 넣을 수 있습니다. step 10에서 GroupShuffleSplit으로 막은 누수가 여기서 다시 생깁니다. ③ **원-핫 데이터에 일반 SMOTE 적용** — 0/1 변수 사이를 보간해 0.37 같은 값이 생깁니다. 범주형이 섞인 데이터에는 SMOTENC가 맞습니다.
왜 중요한가	발표의 "3가지 전략 CV 검증", "GroupSplit으로 누수 차단"이라는 주장과 실제 코드가 어긋나 질의응답에서 약점이 될 수 있습니다.
해결 방법	StratifiedGroupKFold로 바꾸고, 임곗값은 **각 폴드의 검증 데이터**에서 정해 평균을 사용합니다.

```
from sklearn.model_selection import StratifiedGroupKFold
cv = StratifiedGroupKFold(n_splits=5, shuffle=True, random_state=42)
for tr, va in cv.split(X, y, groups=animal_ids):   # 같은 동물은 같은 폴드
    model.fit(X.iloc[tr], y.iloc[tr])
    proba = model.predict_proba(X.iloc[va])[:, 1]
    thr, prec, rec = find_threshold_for_min_recall(y.iloc[va], proba, 0.8)
```

문제 6 발표자료와 노트북의 수치 불일치 · 재현성

심각도 중간

무엇이 문제인가	발표 슬라이드의 일부 수치가 최종 노트북 결과와 맞지 않고, 일부 결과를 만든 코드가 폴더에 없습니다.
근거 (수치)	• 슬라이드 14 "2단계 Recall 0.799 · PR-AUC 0.730 / 직접 Recall 0.811 · PR-AUC 0.711" → 노트북 test 결과와 다름 (step 12 로지스틱 회귀 CV 값과 유사). 바로 다음 슬라이드 15는 test 값 사용 • 입양 모델 튜닝 · SHAP · 69.2%/79.7% 계산 코드가 폴더에 없음 • 노트북이 저장하는 euth_*.png 그래프 파일이 폴더에 없음 · 데이터 경로가 개인 PC 절대경로로 고정
왜 중요한가	발표를 듣는 사람이 같은 모델의 성능이 슬라이드마다 다르다고 느낄 수 있고, 제출물만으로 결과를 재현할 수 없습니다.
해결 방법	① 슬라이드 14 수치의 출처(CV인지 test인지)를 표기하거나 test 값으로 통일 ② 입양 모델 코드를 Final 노트북에 합치기 ③ 경로를 상대경로(**./data/**)로 변경

문제 7	그 밖의 작은 문제들	심각도 낮음
무엇이 문제인가	결과를 크게 바꾸지는 않지만 완성도를 위해 정리하면 좋은 항목들입니다.	
근거 (수치)	• **상위 15개 품종·색상을 분할 전 전체 데이터로** 정함 → test 정보가 아주 조금 섞임 (영향은 미미) • **나이 구간이 개·고양이 공통** → 고양이 1살과 대형견 1살은 생애단계가 다름 • **계절 변수 제외 실험 없음** (교수님 코멘트 7) • **시간 순서 검증 없음** — 2013~2021 데이터를 무작위로 나눔. 실제로는 과거로 학습해 미래를 예측하므로 시간 기준 분할(예: ~2019 학습, 2020~ 평가)이 더 현실적이며, 2020년 코로나 시기 운영 변화도 확인 필요 • 특성 중요도는 **연관성**일 뿐 인과가 아님 (발표에서도 이미 언급한 점은 좋음)	
왜 중요한가	심사에서 "실제 운영에 쓸 수 있는가?"라는 질문에 답하려면 특히 시간 기준 검증이 중요합니다.	
해결 방법	순서대로 ablation 실험 1개, 종별 나이 구간, 시간 기준 분할 1회를 추가하는 것을 권장합니다.	

SECTION 8

개선 로드맵

영향이 크고 작업량이 적은 것부터 정렬했습니다.

순서	할 일	관련 문제	작업량	효과
1	직접 vs 2단계를 전체 test·동일 기준으로 비교하는 표 추가, 모델 선정 근거 문구 수정	문제 1	작음	발표 논리 보강
2	개·고양이만으로 안락사 모델 재학습 / 종류별 성능 분리 보고	문제 2	작음	실제 활용 성능 제시
3	슬라이드 14 수치 출처 통일, 입양 모델 코드 병합	문제 6	작음	신뢰성 · 재현성
4	merge_asof 병합으로 교체 후 전체 재실행	문제 3	중간	타깃 정확도
5	has_name 누수 점검 (* 이름 처리, 제외 실험)	문제 4	작음	누수 방지
6	StratifiedGroupKFold + 폴드 내 임곗값 선정	문제 5	중간	검증 신뢰성
7	계절 제외 실험 · 종별 나이 구간 · 시간 기준 검증	문제 7	중간	완성도 · 현실성

APPENDIX

부록 A. 개념 정리

이 프로젝트에 등장하는 개념을 주제별로 정리했습니다. 각 개념 아래 '이 프로젝트에서'는 해당 개념이 어디에 쓰였는지 연결해 줍니다.

A-1. 문제 설정

분류 (Classification)

Classification

정답이 몇 가지 범주 중 하나인 문제. 범주가 2개면 **이진분류**, 3개 이상이면 **다중분류**입니다. 모델은 보통 각 범주의 **확률**을 내고, 기준(임곗값)을 넘으면 그 범주로 판정합니다.

이 프로젝트에서 입양 여부 · 안락사 여부 = 이진분류, 결과 5종 = 다중분류

타깃 변수 (Target)

Target / Label

모델이 맞혀야 하는 정답 열. 타깃을 어떻게 정의하느냐에 따라 모델이 배우는 내용이 완전히 달라집니다. 좋은 결과(반환)와 나쁜 결과(안락사)를 같은 0으로 묶으면 모델이 배우는 신호가 흐려집니다.

이 프로젝트에서 교수님 코멘트 1의 핵심. target_adoption, target_euthanasia_all 두 개로 분리

조건부 확률

Conditional Probability

P(A|B)는 "B가 일어났을 때 A가 일어날 확률". 곱셈 법칙에 의해 P(A 그리고 B) = P(B) × P(A|B)가 성립합니다.

이 프로젝트에서 P(안락사|비입양) × P(비입양) = P(안락사) → 2단계 점수와 직접모델이 같은 값을 추정하는 이유 (문제 1)

2단계 모델 (계층형 모델)

Two-stage / Hierarchical Model

문제를 두 단계로 쪼개 순서대로 푸는 방식. 1단계에서 큰 갈래를 나누고, 2단계에서 그 안을 세분화합니다. 학습은 각 단계를 **실제 정답**으로 따로 하고, 사용할 때만 이어 붙이면 1단계의 오류가 2단계 학습에 섞이지 않습니다.

이 프로젝트에서 1단계 입양 모델 → 2단계 비입양군 안락사 모델

A-2. 데이터 준비

데이터 병합

Merge / Join

두 표를 공통 열(키)로 연결하는 작업. 한 키에 여러 행이 있으면 무엇끼리 짝지을지 규칙이 필요합니다. **merge_asof**는 정확히 같은 값이 아니라 "가장 가까운 시점"으로 짝짓는 병합으로, 입소 이후 첫 퇴소를 찾을 때 적합합니다.

이 프로젝트에서 Animal ID + visit_seq 병합 → 순번 밀림 694행 (문제 3)

결측치 (Missing Value)

Missing Value

값이 비어 있는 칸. 처리 방법은 ① 행 삭제 ② 대체(평균·중앙값·최빈값·'Unknown') ③ 결측 자체를 정보로 활용(결측 여부 변수) 등이 있습니다. 결측이 무작위가 아니라 의미가 있을 때는 ③이 유용합니다.

이 프로젝트에서 이름 결측 → has_name 변수, 성별 결측 1건 → 최빈값

이상치 (Outlier)

Outlier

다른 값들과 동떨어진 값. **입력 오류**(음수 나이)라면 복구가 불가능할 때 삭제가 자연스럽고, **실제 극단값**(아주 오래 머문 동물)이라면 정보이므로 함부로 지우면 안 됩니다.

이 프로젝트에서 음수·30세 초과 나이 7건 삭제 (교수님 코멘트 4)

파생변수 · 특성공학

Feature Engineering

원본 열을 가공해 모델이 쓰기 좋은 새 변수를 만드는 일. 도메인 지식이 가장 많이 들어가는 단계입니다.

이 프로젝트에서 혼종 여부, 다색 여부, 이름 유무, 성별/중성화 분리, 계절, 생애단계

원-핫 인코딩 One-Hot Encoding

범주형 값을 0/1 열 여러 개로 바꾸는 방법. 예) 동물 종류 {개, 고양이, 기타} → '개?' '기타?' 두 열 (drop_first로 하나는 기준으로 생략). 모델이 문자열을 직접 못 다루기 때문에 필요합니다.

이 프로젝트에서 특성 14개 → 65개 열

고카디널리티 High Cardinality

범주 종류가 매우 많은 변수. 그대로 원-핫 하면 열이 수천 개가 되고, 드문 범주는 학습할 데이터가 부족해 과적합됩니다. 해결: 상위 N개 + 기타로 묶기, 의미 있는 상위 범주로 묶기, 타깃 인코딩 등.

이 프로젝트에서 품종 2,619종 · 색상 594종 → 상위 15개 + 혼종/다색 변수

스케일링 (표준화) Standardization

수치 변수를 평균 0, 표준편차 1로 맞추는 작업. 로지스틱 회귀처럼 값의 크기에 민감한 모델에 필요하고, 트리 모델은 영향을 받지 않습니다. **학습 데이터로만 fit**하고 test에는 transform만 해야 누수가 없습니다.

이 프로젝트에서 age_days, intake_month에 StandardScaler (train으로만 fit — 올바르게 구현됨)

A-3. 검증 설계

학습/테스트 분할 Train / Test Split

데이터를 학습용과 평가용으로 나눠, 모델이 **처음 보는 데이터**에서 얼마나 잘하는지(일반화 성능) 측정합니다. test는 모델 선택·튜닝에 쓰지 않고 마지막 평가에만 써야 합니다.

이 프로젝트에서 8:2 분할, 98,342 / 24,505행

데이터 누수 Data Leakage

실제 예측 시점에는 알 수 없는 정보가 학습에 섞이는 것. 성능이 비현실적으로 높게 나오고, 실제 사용 시 무너집니다. 대표 유형: ① 결과 이후에 생기는 정보(퇴소 사유) ② 같은 개체가 학습·평가에 동시 등장 ③ 전처리를 전체 데이터로 fit.

이 프로젝트에서 Outcome Subtype·체류기간 제외(○), GroupShuffleSplit(○), 이름 변수·CV 방식은 점검 필요(문제 4, 5)

그룹 분할 GroupShuffleSplit / GroupKFold

같은 그룹(같은 동물)의 행이 학습과 평가 양쪽에 나뉘지 않도록 **그룹 단위로** 나누는 방법. 같은 동물이 여러 번 방문하면 모델이 동물을 "외워서" 맞히는 문제를 막아줍니다.

이 프로젝트에서 Animal ID 기준 분할 → train/test 중복 동물 0마리

교차검증 (K-Fold CV) Cross Validation

학습 데이터를 K조각으로 나눠 한 조각씩 돌아가며 검증에 쓰고 K번 평균을 내는 방법. 한 번 나눈 결과보다 안정적입니다. **Stratified**: 각 조각의 클래스 비율 유지 / **Repeated**: 섞는 방식을 바꿔 여러 번 반복 / **Group**: 그룹 단위로 나눔 / **StratifiedGroupKFold**: 두 가지를 동시에.

이 프로젝트에서 RepeatedStratifiedKFold 5×5 사용 → StratifiedGroupKFold 권장 (문제 5)

시간 기준 검증 Temporal Validation

과거 데이터로 학습하고 이후 기간으로 평가하는 방법. 실제 운영 상황(과거로 배워 미래 예측)과 같아서, 정책 변화나 추세 변화에도 모델이 버티는지 확인할 수 있습니다.

이 프로젝트에서 미구현 — 발표에서 향후 과제로 언급 (문제 7)

A-4. 클래스 불균형

클래스 불균형 Class Imbalance

한 클래스가 매우 적은 상황. 안락사가 6.8%라면 "모두 안락사 아님"이라고만 해도 정확도 93%가 나옵니다. 그래서 정확도 대신 소수 클래스를 얼마나 잘 잡는지 보는 지표가 필요합니다.

이 프로젝트에서 안락사 6.8% (전체) / 12.0% (비입양군)

class_weight Class Weight

소수 클래스를 틀렸을 때 더 큰 벌점을 주는 방법. 'balanced'는 클래스 비율의 역수로 가중치를 자동 설정합니다. 데이터를 바꾸지 않아 가장 간단하고 안전한 첫 번째 선택지입니다.

이 프로젝트에서 모든 모델에 class_weight='balanced' 적용 — 가장 좋은 결과

오버샘플링 · SMOTE Oversampling / SMOTE

소수 클래스 데이터를 늘리는 방법. SMOTE는 소수 클래스의 이웃 점들 사이에 **가상의 점을 합성**합니다. 반드시 **학습 폴드 안에서만** 적용해야 합니다(검증 데이터에 가짜 점이 섞이면 누수). 범주형(0/1) 변수가 섞여 있으면 **SMOTENC**를 써야 0.37 같은 비현실적 값이 생기지 않습니다.

이 프로젝트에서 imblearn Pipeline으로 폴드 내 SMOTE(○) — 성능은 오히려 하락

임곗값 조정 Threshold Tuning

모델이 낸 확률을 몇 이상일 때 양성으로 볼지 정하는 기준. 기본값은 0.5지만 낮추면 Recall↑ Precision↓, 높이면 반대입니다. "놓치면 안 되는" 문제는 원하는 Recall을 먼저 정하고 그때의 임곗값을 찾습니다. 임곗값은 **검증 데이터**로 정해야 합니다.

이 프로젝트에서 Recall ≥ 0.8 기준 탐색 → 0.499 (학습 데이터로 정해 효과 없음, 문제 5)

A-5. 모델

로지스틱 회귀 Logistic Regression

각 변수에 가중치를 곱해 더한 값을 0~1 확률로 바꾸는 선형 모델. 빠르고 해석이 쉬워 **기준 모델(baseline)**로 많이 씁니다. 변수 간 복잡한 상호작용은 잘 못 잡습니다.

이 프로젝트에서 baseline 모델

결정 트리 Decision Tree

"나이 > 7년?" "입소 유형 = 야생?" 같은 질문을 연달아 던져 데이터를 나누는 모델. 직관적이지만 하나만 쓰면 과적합되기 쉬워 여러 개를 묶는 앙상블로 씁니다.

이 프로젝트에서 랜덤포레스트와 LightGBM의 기본 부품

랜덤 포레스트 Random Forest (Bagging)

데이터와 변수를 무작위로 뽑아 만든 트리 수백 개의 **투표**로 예측(배깅). 안정적이고 과적합에 강합니다. 확률이 보수적으로 나와 Precision이 높은 경향이 있습니다.

이 프로젝트에서 n_estimators=300 — F1·Precision 최고

LightGBM Gradient Boosting

트리를 **순서대로** 만들되, 앞 트리가 틀린 부분을 다음 트리가 보완하는 부스팅 모델. 표 형태 데이터에서 가장 성능이 좋은 계열이며 빠릅니다. 하이퍼파라미터에 민감해 튜닝이 중요합니다.

이 프로젝트에서 입양·안락사 최종 모델

하이퍼파라미터 튜닝 Hyperparameter Tuning

트리 개수·깊이·학습률처럼 사람이 정하는 설정값을 바꿔가며 최적 조합을 찾는 과정. 반드시 검증 데이터(CV)로 고르고, test는 마지막에 한 번만 봐야 합니다.

이 프로젝트에서 입양 모델에 적용 (코드 폴더에 없음)

A-6. 평가지표

혼동행렬 (Confusion Matrix) — 모든 분류 지표의 출발점

	예측: 안락사	예측: 아님
실제: 안락사	**TP** (맞게 잡음)	**FN** (놓침)
실제: 아님	**FP** (헛경보)	**TN** (맞게 넘김)

지표	계산	쉬운 뜻	언제 중요한가
Accuracy (정확도)	(TP+TN) / 전체	전체 중 맞힌 비율	클래스가 균형일 때만 의미 있음
Precision (정밀도)	TP / (TP+FP)	"안락사"라고 한 것 중 진짜 비율	헛경보 비용이 클 때
Recall (재현율)	TP / (TP+FN)	실제 안락사 중 잡아낸 비율	**놓치면 안 될 때** (안락사 위험군)
F1-score	2PR / (P+R)	Precision과 Recall의 조화평균	둘의 균형을 볼 때
Balanced Accuracy	클래스별 Recall 평균	클래스 크기와 무관한 정확도	다중분류 · 불균형
macro / weighted avg	단순평균 / 건수가중평균	여러 클래스 점수를 합치는 방법	macro는 소수 클래스를 동등하게 대우

ROC 곡선 · ROC-AUC

Receiver Operating Characteristic

임곗값을 0~1로 바꿔가며 (가로: 헛경보율 FP/(FP+TN), 세로: Recall)을 그린 곡선의 아래 면적. 1이면 완벽, 0.5면 무작위. **양성 비율이 달라도 값이 크게 변하지 않아** 서로 다른 집단 비교에 비교적 안전합니다. 단, 음성이 압도적으로 많으면 성능이 좋아 보이는 경향이 있습니다.

이 프로젝트에서 직접 0.941 vs 2단계 0.932 — 오히려 직접모델이 높음

PR 곡선 · PR-AUC (Average Precision)

Precision-Recall Curve

임곗값을 바꿔가며 (가로: Recall, 세로: Precision)을 그린 곡선의 아래 면적. 소수 클래스에 집중하므로 불균형 문제의 핵심 지표입니다. **주의: 무작위 모델의 PR-AUC = 양성 비율**입니다. 양성이 6.9%인 집단에서는 기본점이 0.069, 12.5%인 집단에서는 0.125에서 시작하므로 **집단이 다르면 값을 직접 비교할 수 없습니다.**

이 프로젝트에서 0.777(12.5% 집단) vs 0.746(6.9% 집단) 비교의 함정 (문제 1)

A-7. 해석

특성 중요도

Feature Importance

트리 모델이 어떤 변수를 많이(또는 효과적으로) 사용했는지 나타낸 값. 빠르게 볼 수 있지만 **방향(증가/감소)을 알려주지 않고**, 범주가 많은 변수나 연속형 변수를 과대평가하는 경향이 있습니다.

이 프로젝트에서 안락사 모델 1위 age_days

SHAP

SHapley Additive exPlanations

게임이론의 섀플리 값을 이용해 **각 예측에 각 변수가 얼마나, 어느 방향으로** 기여했는지 계산하는 방법. "이 동물은 나이 때문에 입양 확률이 12%p 낮아졌다"처럼 개별 설명이 가능합니다.

이 프로젝트에서 입양 모델 주요 요인 분석 (발표 슬라이드 11)

상관 vs 인과

Correlation vs Causation

두 변수가 함께 움직인다고(상관) 하나가 다른 하나를 일으킨다(인과)는 뜻은 아닙니다. 예측 모델의 중요 변수는 "예측에 쓸모 있는 신호"일 뿐이며, 그 변수를 바꾸면 결과가 바뀐다는 보장은 없습니다.

이 프로젝트에서 "이름을 붙여주면 입양이 늘어난다"는 모델만으로는 주장할 수 없음

과적합 Overfitting

모델이 학습 데이터의 우연한 패턴까지 외워서, 학습 성능은 높지만 새 데이터에서는 떨어지는 현상. 소수 클래스·고카디널리티 변수·같은 개체의 반복 등장에서 잘 생깁니다.

이 프로젝트에서 상위 15개 그룹화, 그룹 분할, 교차검증으로 대응

부록 B. 재검증 방법

7장의 수치는 아래 방식으로 계산했습니다. 노트북의 설정(LightGBM, class_weight='balanced', random_state=42)을 그대로 따랐습니다.

- **데이터 품질**: 원본 CSV(반려동물 데이터셋.zip)를 다시 불러와 노트북과 같은 방식으로 병합 → 중복 행, 입·퇴소 횟수 불일치, 음수 체류기간, 안락사 구성 비율 계산
- **공정 비교**: 폴더의 X_train/X_test, y_*.csv를 사용해 입양 모델 · 직접모델 · 2단계 모델을 학습 → **전체 test 24,505건**에 대해 직접모델 확률과 (1-P(입양))×P(안락사|비입양) 점수의 PR-AUC · ROC-AUC · Recall 0.8에서의 Precision 비교
- **종류별 성능**: test를 Animal_Type_intake_Other 열로 나눠 직접모델 PR-AUC를 따로 계산
- 재검증에서 기본 설정 LightGBM 입양 모델의 test 성능은 ROC-AUC 0.804 · PR-AUC 0.734였습니다 (발표의 튜닝 모델과는 다를 수 있음).