발표·심사 대비용 해설지

Animal Shelter 최종본 노트북 해설지

절마다 무엇을·왜 했는지, 결과를 어떻게 말할지, 예상 질문과 답

대상: Animal_Shelter_Analytics_최종_논문용.ipynb · 수치 출처: outputs_final/ (실행 2026-10-09 16:09:10)

30초 설명

보호소에 들어온 개·고양이가 **90일 안에 안락사될 위험**을 입소 시점 정보만으로 예측합니다. 핵심은 모델보다 **평가 방법**입니다. 미래의 결과를 미리 보지 않도록 '결과가 확정된 시점'을 기준으로 데이터를 나누고, 3개 연도로 순차 검증해 모델을 골랐습니다. 최종 XGBoost 모델은 2024년 입소에서 AP 0.108(무작위로 고를 때의 4.9배), ROC-AUC 0.811이고, 입소의 32.4%를 검토 대상으로 표시하면 90일 이내 안락사의 78.2%를 미리 찾습니다.

이 해설지의 구성

장	내용
1	전체 흐름 한눈에 보기
2	절별 해설 (무엇을 · 왜 · 결과 · 이렇게 말하기)
3	꼭 외울 숫자
4	예상 질문과 답 (심사·발표)
5	말할 때 피해야 할 표현

SECTION 1

전체 흐름 한눈에 보기

단계	노트북 절	한 줄 요약
데이터 다듬기	2~4	날짜 형식을 판정하고, 입소와 퇴소를 '다음 입소 전 첫 퇴소' 규칙으로 연결
누수 점검	3-2, 5, 6-3	공개 데이터의 사후 수정, v3의 시간 위반, 이름 변수의 결과 반영 여부 확인
목표와 분할	6, 8	90일 이내 안락사 라벨, 결과 확정 시점 기준으로 선택 폴드 3개 → 보정 구간 → 2024 테스트
모델 고르기	10	5계열 기본값 비교 → 상위 3계열 같은 예산 튜닝 → 변수 → 직접 vs 2단계
평가	11	2024 테스트 AP·ROC·Recall, 선별 규모별·비용 비율별 운영점, 확률 보정
견고성	11-2, 12	민감도(이름·요청·사후 수정·성별 범주형 등), 무작위 분할과 비교, 계열별 테스트 참고값
비교 실험	별도 노트북	선행연구 방식 재현(E1), 평가 대상 고정(E2), 단순 기준선(E3) → 10/10 결론 수정
활용·해석	13, 14	입양 가능성 × 안락사 위험 두 축 분류, 변수 단위 SHAP, 개체 사례
검증·정리	15~19	자동 무결성 검사 22/22, 요약 json, 자동 생성 해석, 논문 배치

모든 선택(계열·변수·불균형 전략·하이퍼파라미터·구조·임곗값·기준값)은 2024 테스트를 보지 않고 미리 정한 규칙으로 했습니다. 2024 테스트는 결과 보고에만 씁니다.

SECTION 2

절별 해설

3. 날짜 형식 점검과 외부 대조

무엇을	퇴소 시각 형식을 정규식으로 분류하고, 시간대가 붙은 행이 실제로는 '날짜만 기록된 행'인지 확인. Kaggle 2021판과 시각을 대조.
왜	시간대 변환을 잘못하면 모든 시각이 5~6시간 밀려 입소보다 퇴소가 앞서는 가짜 오류가 생깁니다.
결과	-05:00이 붙은 퇴소 3,584건은 겨울에도 -05:00이고 시각이 모두 00:00 → 날짜 전용으로 판정해 그날 23:59:59로 둠. Kaggle판과 현지 시각 해석 일치 99.97%.
이렇게 말하기	"시간대 표시가 실제 시간대가 아니라 날짜 전용 표시라는 것을 형식과 외부 자료로 확인했습니다."

3-2. 공개 데이터의 사후 수정 점검

무엇을	2021년판과 현재판을 같은 입소끼리 맞춰 열 값이 바뀐 비율을 셈. 바뀐 입소를 빼고 다시 학습한 민감도도 봄.
왜	입소 후 알게 된 정보(예: 보호소에서 한 중성화)가 입소 기록에 거꾸로 반영되면 미래 정보가 섞입니다.
결과	특성 원천 열 변경 0.51%(중성화 안 됨 → 됨 포함), 안락사 라벨 변경 0건. 변경 입소 제외 시 AP 차이 -0.0000 [-0.003, 0.005].
이렇게 말하기	"사후 수정은 있었지만 규모가 작고, 빼고 학습해도 차이를 확인하지 못했습니다. 2021년 이후 기록은 점검할 수 없다는 한계가 있습니다."

4. 입·퇴소 연결

무엇을	같은 동물의 입소를 시간순으로 놓고, 입소 이후 첫 퇴소가 다음 입소보다 앞설 때만 연결.
왜	단순 순번 병합은 체류 기간이 음수인 행을 만들었습니다(원래 프로젝트의 문제).
결과	퇴소 1건이 두 입소에 연결되는 경우 0건, 규칙 위반 0건(무결성 검사).
이렇게 말하기	"연결 규칙을 명시하고 코드로 위반이 없음을 검사했습니다."

5. v3의 시간 위반 점검

무엇을	입소 연도로 나눴을 때, 학습·검증 라벨이 선택 시점 이후에 확정된 비율을 셈.
왜	오래 머문 동물의 결과는 늦게 확정되므로, 입소 연도로만 나누면 미래에 알게 될 결과로 모델을 고르게 됩니다.
결과	v3 검증 구간 라벨의 7.19%(766건)가 선택 시점 이후 확정.
이렇게 말하기	"그래서 라벨을 '입소 후 90일 이내'로 고정하고, 결과가 확정된 시점을 기준으로 나눴습니다."

6. 예측 목표와 이름 변수

무엇을	안락사가 입소 후 며칠 안에 일어나는지 분포를 보고 90일을 선택. 입소·퇴소 이름이 같은 비율과, 즉시 안락사의 이름 없음 비율을 비교.
왜	기간을 고정해야 결과 확정 시점이 분명해지고, 이름 변수가 결과를 반영하면 누수입니다.
결과	안락사의 97.5%가 90일 이내. 이름 일치 100%, 24시간 이내 안락사의 70.8%가 이름 없음(초과 41.6%). → 이름 변수 제외.
이렇게 말하기	"이름 변수는 성능과 무관하게 누수 근거로 뺐고, 넣었을 때의 결과는 민감도로만 보고합니다."

6-4. 성별 Unknown 점검

무엇을	2021판이 만들어질 때 아직 보호소에 있던 입소와 이미 나간 입소를 나눠, 그 판의 성별 Unknown이 지금 채워졌는지 비교. 안락사 시점별 Unknown 비율과 성별별 안락사율도 봄.
왜	값이 머무는 동안 채워진다면, 지금 데이터의 Unknown은 일찍 나간 동물을 가리키는 결과 반영 신호(누수)입니다.
결과	보호소에 있던 입소의 Unknown 7/7 채워짐 vs 이미 나간 입소 2/4,261. 24시간 이내 안락사의 Unknown 17.3%, 90일 초과 0.0%. → 범주형 제외, 이진 후보(중성화·수컷 여부)로 재평가.
이렇게 말하기	"성별은 의미 있는 변수지만, 공개 데이터의 '모름' 값이 결과에 따라 남는다는 것을 확인해 그 신호를 쓰지 않게 했습니다."

8. 시점 기준 분할

무엇을	선택 폴드 3개(각 12개월) → 보정 구간(12개월) → 2024 테스트. 각 학습 데이터는 그 구간 시작 전에 라벨이 확정된 입소만.
왜	한 기간에 맞춰 고르는 것을 막고, 확률 보정·임곗값은 선택과 분리합니다.
결과	학습·평가 동물 중복 없음, 모든 라벨이 사용 시점 전에 확정(무결성 검사).
이렇게 말하기	"과거로 배워 미래에 쓰는 실제 운영 상황을 그대로 흉내 냈습니다."

10. 모델 고르기

무엇을	5개 계열 기본값 비교 → 상위 3개를 같은 예산(후보 9개 × 불균형 전략)으로 튜닝 → 최종 계열로 변수 후보 평가 → 직접 vs 2단계.
왜	기본값만으로 계열을 고르면 튜닝에 민감한 계열이 불리합니다. 같은 예산이어야 공정합니다.
결과	기본값 1위는 LightGBM이었지만 같은 예산 튜닝 후 XGBoost가 1위(LightGBM - XGBoost = -0.0123 [-0.027, 0.004]). intake_season 추가 차이 +0.0006 [-0.003, 0.004](채택 안 함). 2단계 - 직접 -0.0129 [-0.027, -0.001].
이렇게 말하기	"계열·전략·구조 모두 결과를 보기 전에 정한 규칙으로 골랐고, 기본값 비교만 했을 때와 결론이 달라진다는 것도 보였습니다."

11. 최종 모델과 2024 테스트

무엇을	최종 모델을 보정 구간 이전 데이터로 학습, 보정 구간에서 임곗값(Recall 0.8 목표)과 확률 보정을 정하고 테스트에 그대로 적용.
왜	임곗값을 테스트에서 고르면 성능이 부풀려집니다.
결과	AP 0.108 [0.087, 0.143], 배수 4.9, ROC-AUC 0.811, 선별 32.4% → Recall 0.782, Precision 0.053.
이렇게 말하기	"입소 3마리 중 1마리꼴로 검토하면 안락사 10건 중 약 8건을 미리 찾지만, 검토한 동물 중 실제 안락사는 약 5%입니다."

11-1, 11-1b. 선별 규모와 비용

무엇을	선별 비율 5~30%별 성능과, '놓친 안락사 1건 = 검토 r건' 가정에서 비용이 가장 작은 운영점.
왜	검토 인력이 정해지지 않았으므로 하나의 정답 대신 의사결정 틀을 제공합니다.
결과	10% 선별 → Recall 0.538, 20% → 0.735. r=20이면 선별 9.1%·절감 24.9%, r=2면 거의 선별하지 않는 것이 최적.
이렇게 말하기	"보호소가 놓친 사례를 검토 몇 건만큼 무겁게 보는지에 따라 운영점이 달라집니다."

11-2. 민감도·성별 범주형·계열별 테스트 참고값

무엇을	이름 포함, 요청 입소 포함, 사후 수정 제외, 성별·중성화 범주형 포함, 계열별 최고 조합의 테스트 결과.
왜	결론이 한 가지 처리 방식에 기대고 있지 않은지 확인합니다. 모두 보고용이고 선택에 쓰지 않았습니다.
결과	이름 포함 차이 +0.0091 [-0.009, 0.027]. 성별·중성화 범주형 포함 차이 +0.0187 [-0.000, 0.044](운영 성능 아님). LightGBM 테스트 AP 0.104(최종 대비 -0.0046 [-0.020, 0.007]).
이렇게 말하기	"보고용 비교는 선택에 쓰지 않았고, 결과를 바꿀 수 있는 신호(이름·성별 Unknown)는 성능과 무관하게 뺐습니다."

12. 무작위 분할과 비교 (10/10 해석 수정)

무엇을	같은 데이터를 동물 ID로 무작위 8:2로 나눈 결과와 비교. 해석은 별도 비교 실험 E2(평가 대상 고정)로 다시 정함.
왜	선행 연구가 무작위 분할을 썼기 때문입니다. 다만 이 표는 평가 대상까지 달라 분할 효과만 볼 수 없습니다.
결과	전 기간 무작위 평가 AP 0.221 vs 시점 분할 0.108. 평가 대상을 2024로 고정하면 무작위 학습 0.108(T2 대비 -0.0009 [-0.004, 0.001]), 무작위 전체 0.108로 차이 확인 안 됨.
이렇게 말하기	"전 기간 무작위 평가의 높은 수치는 분할 방식이 아니라 평가 기간·대상 구성에서 왔습니다. 시간 검증은 수치를 낮추려는 게 아니라 선택에 미래 라벨이 섞이지 않게 하고 운영 시점 성능을 보고하려는 것입니다."

비교 실험 E1~E3 (비교실험_선행연구_평가설계.ipynb)

무엇을	E1: 결과 5종 다중분류를 선행 연구처럼 정확도로 평가(3가지 분할). E2: 2024 평가 대상 고정, 학습만 T1·T2·R1·R2로 변경. E3: 규칙(건강상태→나이)·로지스틱 회귀와 같은 검토량 비교.
왜	학회 심사의 '기존 연구와 비교'를 같은 데이터에서 하고, 이전 주장(무작위 분할이 부풀린다)이 맞는지 직접 확인하려고 했습니다.
결과	E1: 정확도 0.615~0.675, 안락사 재현율 0.286→0.036. E2: AP 0.1076~0.1084, 차이 모두 0 포함. E3: 로지스틱 0.102(-0.0055 [-0.023, 0.013]), 규칙 0.091(-0.0181 [-0.041, 0.001]), 같은 검토량 Recall 규칙 0.756 vs 최종 0.782.
이렇게 말하기	"정확도는 선행 연구와 비슷하게 나오지만 안락사는 거의 못 찾습니다. 보고 성능은 분할 방식보다 평가 기간·대상과 지표에 좌우됐고, 예측력의 대부분은 건강상태와 나이에서 나옵니다."

13. 두 축 운영 가설

무엇을	보정된 입양 확률(기준값 = 보정 구간 실제 90일 입양률)과 안락사 위험 선별로 4칸 분류.
왜	위험만이 아니라 '입양 가능성도 낮은' 동물에 자원을 먼저 쓰자는 운영 아이디어입니다.
결과	입양 낮음 × 위험 선별 칸: 입소 26.8%, 안락사의 67.2%.
이렇게 말하기	"이 칸에 개입하면 안락사가 줄어든다는 뜻은 아닙니다. 어디에 먼저 볼지 정하는 가설입니다."

14. 해석 (SHAP)

무엇을	최종 모델의 SHAP을 원래 변수 단위로 합산, 범주별 평균 기여, 기준을 고정한 개체 사례 2건.
왜	원-핫 범주가 흩어지면 해석이 어렵습니다. 사례는 미리 정한 규칙으로 골라 '골라 쓴 사례'가 아니게 했습니다.
결과	기여 1위 Intake Condition(0.814), 2위 age_days(0.310). 고위험 사례 A900135, 저위험 사례 A895639.
이렇게 말하기	"SHAP은 예측에 대한 연관성이지 원인이 아닙니다."

15~19. 무결성 검사와 자동 해석

무엇을	시간 위반·개체 중복·연결 규칙·특성 누수를 코드로 검사, 결과 요약 json, 해석 문단과 논문 배치를 실행 결과로 자동 생성.
왜	다시 실행해도 문장과 숫자가 어긋나지 않게 하고, 핵심 위험을 사람 대신 코드가 확인하게 합니다.
결과	무결성 검사 22/22 통과.
이렇게 말하기	"보고서의 모든 숫자는 실행 출력에서 읽었습니다."

SECTION 3

꼭 외울 숫자

항목	값	출처
테스트 입소 / 90일 이내 안락사	10,778 / 238 (기준선 2.2%)	11
AP [95% CI] · 배수	0.108 [0.087, 0.143] · 4.9배	11
ROC-AUC	0.811 [0.779, 0.838]	11
선별 비율 → Recall / Precision	32.4% → 0.782 / 0.053	11
최종 모델	XGBoost · 가중치 · 직접모델 (subsample=1.0, n_estimators=200, min_child_weight=10, max_depth=3, learning_rate=0.03, colsample_bytree=0.6)	10
90일 라벨 근거	안락사의 97.5%가 90일 이내	6-1
v3 시간 위반	검증 라벨의 7.19%	5
전 기간 무작위 vs 시점 분할	AP 0.221 vs 0.108 (평가 대상이 다름)	12-1
E2 같은 2024 평가 대상	T1 0.108 · T2 0.108 · R1 0.108 · R2 0.108	비교
E1 다중분류 안락사 재현율	0.286(2013~16 무작위) → 0.036(시간 분할), 정확도 0.61~0.67	비교
E3 AP 최종 / 로지스틱 / 규칙	0.108 / 0.102 / 0.091 (차이 확인 안 됨)	비교
두 축 핵심 칸	입소 26.8% → 안락사 67.2%	13
무결성 검사	22/22 통과	15

SECTION 4

예상 질문과 답

Q. AP 0.108이면 너무 낮지 않나요?

A. 안락사는 입소의 2.2%뿐이라 무작위로 고르면 AP가 0.022입니다. 그 4.9배이고, 입소의 32.4%만 검토해 안락사의 78.2%를 찾습니다. AP는 항상 기준선·배수·운영 지표와 함께 봐야 합니다.

Q. 선행 연구보다 성능이 낮은데요?

A. 과제·지표가 달라 직접 비교할 수 없어 같은 데이터에서 선행 연구 방식을 재현했습니다(E1). 정확도는 0.61~0.67로 선행 연구(0.627, 65.33%)와 비슷하지만 안락사 재현율은 시간 분할에서 0.036입니다. 정확도가 높아 보여도 드문 안락사는 거의 못 찾으므로, 본 연구는 안락사 탐지력을 AP로 직접 평가했습니다.

Q. 무작위 분할이 성능을 부풀린다고 하지 않았나요?

A. 이전 기획서에서는 그렇게 썼지만, 직접 검증해 보니 이 데이터에서는 뒷받침되지 않았습니다. 평가 대상을 2024로 고정하고 학습만 무작위로 바꾸면 AP 0.108(차이 -0.0009 [-0.004, 0.001])로 차이를 확인하지 못했습니다. 전 기간 무작위 평가가 높았던 건 평가 기간·대상(안락사율이 더 높던 시기 포함)이 달랐기 때문이라 결론을 바꿨습니다.

Q. 그럼 시간 검증은 왜 했나요?

A. 보호소는 과거로 배운 모델을 미래 입소에 쓰므로 보고 성능도 그 조건에서 나와야 하고, 결과가 늦게 확정되는 데이터라 선택에 미래 라벨이 섞이지 않게 해야 합니다. 수치를 낮추려는 목적이 아니며, 이 데이터에서 분할 효과가 작았다는 것 자체도 결과로 보고합니다.

Q. 단순 규칙과 차이가 없으면 머신러닝이 필요한가요?

A. 좋은 지적입니다. 같은 검토량에서 규칙(건강상태→나이)도 안락사의 75.6%를 찾고, 최종 모델과의 AP 차이 -0.0181 [-0.041, 0.001]는 확인되지 않았습니다(동등하다는 뜻은 아님). 그래서 기여를 모델 성능이 아니라 평가 설계·누수 점검·운영 지표에 두고, 예측력의 대부분이 건강상태와 나이에 있다고 보고합니다.

Q. 왜 90일인가요?

A. 안락사의 97.5%가 90일 안에 일어나고, 90일이면 2024년 12월 입소까지 결과를 관찰할 수 있습니다. 180일 이상은 2024년 전체를 관찰할 수 없습니다.

Q. 왜 이름 변수를 뺐나요? 성능이 오르지 않나요?

A. 입소·퇴소 기록의 이름이 100% 같고, 즉시 안락사된 개체에 이름 없음이 몰려 결과를 반영한 신호일 수 있기 때문입니다. 성능을 보고 정하지 않았고, 넣어도 차이는 +0.0091 [-0.009, 0.027]로 확인되지 않았습니다.

Q. 왜 LightGBM이 아니라 XGBoost인가요?

A. 상위 3개 계열을 같은 예산으로 튜닝한 뒤 미리 정한 규칙(3개 폴드 평균 AP 최고)으로 골랐습니다. 검증 차이는 LightGBM - XGBoost = -0.0123 [-0.027, 0.004]입니다. 다만 테스트에서는 계열 간 차이가 확인되지 않아(-0.0046 [-0.020, 0.007]), 특정 알고리즘의 우월성을 주장하지 않습니다.

Q. 딥러닝(MLP)은 왜 안 썼나요?

A. 비교에 포함했습니다. 같은 예산 튜닝 후 MLP의 검증 차이는 -0.0114 [-0.024, 0.001](차이를 확인하지 못함), 테스트 AP는 0.100였습니다. 학습 시간은 트리 부스팅보다 훨씬 깁니다.

Q. 불균형 데이터는 어떻게 처리했나요?

A. 가중치 없음·클래스 가중치·SMOTENC를 같은 후보로 튜닝해 비교했습니다. SMOTENC는 모든 계열에서 가장 낮았고, 가중치와 가중치 없음의 차이는 확인되지 않았습니다.

Q. 테스트 기간을 본 적이 있다던데요?

A. 2024 기간은 이전 버전(v3)에서 다른 목표로 결과를 본 적이 있어 '한 번도 안 본 테스트'라고 하지 않습니다. 최종본은 테스트를 어떤 선택에도 쓰지 않았고 이 이력을 한계로 밝힙니다.

Q. 데이터 누수는 어떻게 막았나요?

A. 결과 확정 시점 기준 분할, 학습·평가 동물 중복 금지, 퇴소 정보 특성 제외, 이름 변수 제외, 사후 수정 점검을 했고 이를 무결성 검사 21개로 코드에서 확인합니다.

Q. 성별은 중요한 변수인데 왜 뺐나요?

A. 성별 자체의 효과는 있습니다(수컷이 0.5~0.7%p 높음). 문제는 'Unknown' 값으로, 머무는 동안 채워져 일찍 나간 동물에만 남는 결과 반영 신호였습니다(2021판 대조). 그래서 범주형은 빼고, Unknown을 구별할 수 없게 만든 수컷 여부·중성화 여부를 후보로 다시 평가했습니다(수컷 -0.0018 [-0.005, 0.001], 중성화 +0.0139 [0.003, 0.027]).

Q. 범주형을 그대로 쓰면 성능이 더 좋지 않나요?

A. 테스트 AP가 0.127(차이 +0.0187 [-0.000, 0.044])이지만, 그 차이는 입소 시점에는 알 수 없는 정보(일찍 나갈지)에서 오므로 실제 운영 성능이 아닙니다.

Q. 확률로 '안락사 확률 78%'라고 말해도 되나요?

A. 안 됩니다. 가중치 모델의 점수는 확률이 아닙니다(평균 0.349 vs 실제 0.022). 확률은 보정 구간으로 보정한 값(평균 0.018)을 씁니다.

Q. 이 모델로 안락사를 줄일 수 있나요?

A. 예측은 위험군을 찾는 것이고, 개입이 안락사를 줄이는지는 이 데이터로 검증할 수 없습니다. 두 축 분류와 비용 분석은 운영을 위한 가설·틀입니다.

Q. 2단계 모델(입양 → 비입양 중 안락사)은요?

A. 같은 대상·같은 평가로 비교했고 2단계 - 직접 = -0.0129 [-0.027, -0.001]로 이득을 확인하지 못해 단순한 직접모델을 택했습니다. 1단계 입양 모델을 따로 튜닝하지 않은 점은 한계입니다.

Q. 다른 보호소에도 쓸 수 있나요?

A. 단일 보호소 데이터라 일반화는 검증하지 않았습니다. 다만 평가 절차(결과 확정 시점 분할, 순차 검증, 군집 부트스트랩)는 그대로 옮겨 쓸 수 있습니다.

SECTION 5

말할 때 피해야 할 표현

피할 표현	대신 이렇게
"두 모델은 성능이 같다"	"차이를 확인하지 못했다" (신뢰구간이 0을 포함)
"XGBoost가 가장 좋은 알고리즘이다"	"미리 정한 규칙에서 검증 성능이 가장 높았다, 테스트에서는 차이를 확인하지 못했다"
"안락사 확률 78%"	"위험 점수 상위" 또는 보정 확률로 표현
"이 모델로 안락사를 줄인다"	"위험군을 먼저 검토할 수 있게 한다" (개입 효과는 미검증)
"무작위 분할은 성능을 부풀린다"	"전 기간 무작위 평가가 높았지만, 같은 평가 대상에서는 분할 방식에 따른 차이를 확인하지 못했다"
"시간 검증을 하면 성능이 낮아진다"	"시간 검증은 선택에 미래 라벨이 섞이지 않게 하고 운영 시점 성능을 보고하기 위한 것이다"
"모델이 단순 규칙보다 낫다"	"AP 점추정은 가장 높지만 규칙·로지스틱 회귀와의 차이는 확인되지 않았다"
"선행 연구보다 성능이 좋다/나쁘다"	"과제·지표가 달라 직접 비교할 수 없고, 같은 데이터로 재현하면 정확도는 비슷하나 안락사 탐지가 약했다"
"한 번도 보지 않은 테스트"	"선택에 쓰지 않은 테스트 (이전 버전에서 다른 목표로 본 이력 있음)"

피할 표현	대신 이렇게
"SHAP 결과 부상이 안락사의 원인"	"부상 상태가 예측 위험과 가장 강하게 연관된다"