Animal Shelter 최종본 채점 보고서

대상: Animal_Shelter_Analytics_최종_논문용.ipynb (88셀, 실행 2026-10-09 16:09:10) · 기준: 이전 채점과 같은 100점 배점 · 근거: 노트북 코드와 실행 출력

종합 93 / 100 (이전 91 → 93, +2)

이전 채점의 남은 1순위였던 성별 'Unknown'을 자연 실험으로 점검해 **결과 반영 신호(누수)**임을 확인하고, 성별·중성화 범주형을 빼고 전체 선택을 다시 했습니다. 그 결과 테스트 AP는 0.126 → **0.108**로 낮아졌지만, 낮아진 만큼은 입소 시점에 알 수 없던 정보였습니다. 점수는 성능이 아니라 평가의 타당성으로 매겼고, 성능 하락을 감점하지 않았습니다.

1. 항목별 점수

기준	배점	이전	현재	근거	남은 감점 사유
1. 문제 정의	10	9	9	90일 라벨·대상·기간 근거를 결과 전에 명시	입양 모델의 역할(두 축 분류용)이 앞부분에서 약함
2. 데이터 정합성	15	14	14	날짜 판정·외부 대조, 연결 규칙, 사후 수정 점검, 성별 Unknown 자연 실험	2021-03 이후 기록 점검 불가, 같은 날 두 번 입소 17건 모호
3. 누수 방지·검증 설계	20	17	**18**	결과 확정 시점 분할, 순차 검증, 이름·성별 Unknown 누수 근거로 제외, 무결성 22/22	2024 테스트를 v3에서 본 이력, is_sterilized에 Unknown이 0으로 섞여 남는 약한 신호, 근거 표본(7건)이 작음
4. 모델 비교	15	14	14	상위 3계열 같은 예산 튜닝, 변수 후보를 최종 계열로 평가	후보 9개로 예산이 작음, 2단계 1단계 모델 미튜닝
5. 통계적 평가	15	14	14	군집 부트스트랩·짝지은 비교, 판단 문구 자동 결정, 계열별 테스트 참고값	다중 비교 보정 없음, 구간이 선택 변동 미반영
6. 해석·운영 활용	10	9	**10**	변수 단위 SHAP, 비용 비율별 운영점, 두 축 가설, 성별 효과를 모델과 분리해 보고	-
7. 재현성	10	9	9	버전 고정, 사용자 폴더 차단, 체크포인트·진행 로그	처음부터 약 5~6시간, 외부 zip·figures_v3 파일 의존, Windows만 검증
8. 문서화	5	5	5	해석 문단 자동 생성, 변경표·원칙·논문 배치	-
합계	100	91	**93**		

2. 이번 수정에서 확인한 사실 (실행 출력)

- **성별 Unknown은 결과 반영 신호**: 2021판 작성 당시 보호소에 있던 입소의 Unknown 7/7가 이후 채워졌고, 이미 나간 입소는 2/4,261만 바뀌었습니다. 24시간 이내 안락사의 Unknown 17.3%, 90일 초과 0.0%.
- **처리**: 성별·중성화 범주형 제외(넣으면 검증 +0.0563 [0.033, 0.081]). 이진 후보 중 중성화됨 여부(Unknown은 0)는 +0.0139 [0.003, 0.027]로 **채택**, 수컷 여부(Unknown 무작위 배정)는 -0.0018 [-0.005, 0.001]로 채택 안 함.
- **누수였다는 확인**: 범주형을 다시 넣으면 전체 테스트 AP 차이 +0.0187 [-0.000, 0.044]이지만, Unknown이 아닌 입소에서는 +0.0012 [-0.008, 0.009]로 거의 0입니다. 범주형이 주던 이득은 Unknown 입소에서만 나왔습니다.
- **주 결과**: XGBoost(가중치) 유지, AP 0.108 [0.087, 0.143], 배수 4.9, ROC-AUC 0.811, 선별 32.4% → Recall 0.782. 계열 간 검증 차이와 테스트 차이는 모두 확인되지 않았습니다.

- **성별 효과**: 수컷이 0.5~0.7%p 높아 의미는 있지만 작고, 이 표를 모델과 별도로 보고합니다.

3. 점수 변화 이력

시점	점수	핵심 변화
v3 (외부 평가)	74	입소 연도 분할, 단일 검증 기간, 행 단위 구간
최종본 (10/7)	84	90일 라벨·결과 확정 시점 분할, 순차 검증, 군집 부트스트랩, 이름·요청 제외
+ 사후 수정·분할 CI	86	Kaggle 2021판 대조, 2024 입소만 본 무작위 분할에 구간
+ 계열별 동일 튜닝·SHAP 합산	88	최종 계열 LightGBM → XGBoost, 변수 단위 SHAP
+ 변수 재평가·자동 해석·비용	91	모델 비교 불일치 해소, 문서화 자동화, 운영 비용 틀
+ 성별 Unknown 누수 제거 (현재)	93	자연 실험으로 누수 확인, 범주형 제외·이진 후보 재평가, 전체 재선택

74점은 다른 평가자의 기준이고 이후 점수는 같은 8개 기준으로 매긴 값입니다.

4. 남은 개선 후보 (효과 순)

- **is_sterilized의 남은 신호 점검** (3번): Unknown 입소를 빼고 학습·평가했을 때 중성화 변수의 효과가 유지되는지 확인합니다.
- **2단계 후보의 1단계 입양 모델 튜닝** (4번): 같은 예산으로 입양 모델을 튜닝한 뒤 직접모델과 다시 비교합니다.
- **다중 비교 보정 또는 사전 지정 비교 목록** (5번): 결론에 쓰는 비교만 미리 지정해 보정 대상을 줄입니다.
- **재현성 정리** (7번): v3 보고값을 참고자료 폴더로 옮겨 이전 버전 폴더 의존을 없애고, cache_tune 배포 방법을 문서화합니다.

5. 10/10 비교 실험과의 관계 (점수 미반영)

비교 실험(E1~E3)은 별도 노트북(비교실험_선행연구_평가설계.ipynb)에서 했으므로 이 채점(최종 노트북 대상)의 점수는 바꾸지 않았습니다. 결과가 노트북 해석과 맞는지만 확인했습니다.

- **무작위 분할 해석**: 노트북 12-1은 "차이의 일부가 평가 시기·표본 구성에서 왔을 가능성을 시사"한다고만 썼습니다. E2(평가 대상 고정)에서 학습 분할에 따른 차이를 확인하지 못해(R1 -0.0009 [-0.004, 0.001]) 이 신중한 해석과 어긋나지 않습니다. 다만 "무작위 분할이 성능을 부풀린다"는 문서 표현은 모두 고쳤습니다.
- **단순 기준선**: 로지스틱 회귀 -0.0055 [-0.023, 0.013], 규칙 -0.0181 [-0.041, 0.001]로 최종 모델과의 차이를 확인하지 못했습니다. 노트북 4번(모델 비교) 항목의 남은 감점 사유로 "단순 기준선 비교가 노트북 밖에 있음"을 더할 수 있습니다.
- **선행연구 재현**: 다중분류 정확도 0.615~0.675, 안락사 재현율 0.286→0.036. AP를 주 지표로 쓴 노트북의 선택을 뒷받침합니다.