논문 기획서 · 10월 10일 비교 실험(E1~E3) 반영

결과 확정 시점을 고려한 시간 검증으로 본 동물보호소 개·고양이의 입소 후 90일 이내 안락사 위험 조기 탐지

Early Detection of 90-day Euthanasia Risk for Shelter Dogs and Cats under Label-availability Temporal Validation

학술대회	2026 한국정보기술학회 추계종합학술대회 및 **대학생논문경진대회** (ICT 관련 전 분야)
논문 형식	**표준형식**: 2단 편집 2쪽 (최대 5쪽) · 학회 양식(학술대회논문양식_표준형식.hwp)
일정	투고 마감 **2026-10-23(금)** · 채택 통보 10/26~ · 사전등록 ~11/10 · 발표 11/26~27 (메종글래드 제주)
등록비	대학생논문경진대회 부문 오프라인 13만원 / 온라인 8만원
저자	1저자 전건우 · 공동저자/지도교수: (기입) · 소속: (기입)
분석 자료	Animal_Shelter_Analytics_최종_논문용.ipynb · 비교실험_선행연구_평가설계.ipynb · outputs_final/ · outputs_compare/ · 최종본 노트북 설명 보고서
논문 초안	논문초안/논문_초안_작성본_v3.hwp (학회 양식, 5쪽) · 같은 내용의 .docx

※ 9/25·10/6판 대비: 예측 목표를 90일 이내 안락사로, 선택을 3개 연도 순차 검증으로 바꾸고 이름 변수·안락사 요청 입소를 제외한 최종본 수치로 전면 갱신했습니다.

10/10 결론 수정: 이전 기획서는 "무작위 분할이 성능을 부풀린다"를 핵심 주장으로 삼았습니다. 문헌 조사와 비교 실험(E1~E3)에서 같은 2024 평가 대상으로 고정하면 학습을 무작위로 나눠도 성능 차이를 확인하지 못해, 이 주장을 버리고 아래 결론으로 바꿨습니다. 보고 성능은 분할 방식보다 평가 기간·대상 구성과 평가 지표에 좌우된다. 정확도 중심 평가는 드문 안락사의 탐지력을 가리고, 같은 2024 평가 대상에서는 학습을 시간 순으로 하든 무작위로 하든 차이를 확인하지 못했다. 단순 규칙·로지스틱 회귀와의 차이도 확인되지 않아 예측력의 대부분은 건강상태와 나이에서 나온다. 시간 검증의 의의는 수치를 낮추는 데 있지 않고, 선택에 미래 라벨이 섞이지 않게 하고 운영 시점의 성능을 제시하는 데 있다.

1. 연구 요약

동물보호소가 입소 시점에 안락사 위험이 높은 동물을 선별할 수 있다면 의료·행동 교정·입양 연계를 먼저 배정할 수 있다. 본 연구는 미국 오스틴 동물보호센터의 2013~2025년 입·퇴소 기록으로 개·고양이의 **입소 후 90일 이내 안락사**를 예측한다. 기존 분석은 입소 연도로만 데이터를 나눠, 학습·선택에 쓰는 라벨 일부가 그 시점 이후에 확정되는 문제가 있었다(검증 라벨의 7.19%). 본 연구는 **라벨 확정 시점 기준 분할**과 **3개 연도 순차 검증**으로 이를 막고, 입·퇴소 기록 연결 규칙, 이름·성별 기록의 누수, 공개 데이터의 사후 수정을 점검했다. 5개 계열을 비교하고 상위 3개 계열을 같은 예산으로 튜닝해 고른 XGBoost 모델은 2024년 테스트에서 AP 0.108(기준선의 4.9배), ROC-AUC 0.811를 보였다. 위험 점수가 높은 입소 동물 32.4%(약 3마리 중 1마리)를 우선 검토하면 90일 안에 안락사된 동물 10마리 중 약 8마리(78.2%)를 미리 찾을 수 있었다. 비교 실험에서는 선행연구 방식(결과 5종 다중분류·정확도)을 재현하면 정확도는 0.61~0.67로 비슷했지만 안락사 재현율이 0.036까지 떨어졌고, 같은 2024 평가 대상에서는 학습 분할 방식(시간 순·무작위)에 따른 AP 차이를 확인하지 못했다. 단순 규칙·로지스틱 회귀와의 차이도 신뢰구간이 0을 포함했다.

2. 논문 제목 후보

	국문	영문
안 1 (추천)	결과 확정 시점을 고려한 시간 검증으로 본 동물보호소 개·고양이의 입소 후 90일 이내 안락사 위험 조기 탐지	Early Detection of 90-day Euthanasia Risk for Shelter Dogs and Cats under Label-availability Temporal Validation
안 2	XGBoost 기반 보호소 반려동물 안락사 위험 선별과 평가 설계에 따른 성능 차이 분석	XGBoost-based Screening of Shelter Pet Euthanasia Risk and Performance Differences by Evaluation Design
안 3	누수와 시간 검증을 고려한 설명 가능한 보호소 동물 위험 선별 모델	An Explainable Shelter Animal Risk Screening Model Accounting for Leakage and Temporal Validation

Key words (논문 v3): animal shelter, euthanasia prediction, temporal validation, data leakage, evaluation design, XGBoost

3. 연구 배경과 필요성

- 공공 동물보호소는 연간 수만 건의 입소를 제한된 자원으로 처리하며 관리 우선순위를 경험에 의존한다. 입소 시점 위험 선별은 **공공 서비스의 지능형 의사결정 지원**이다.
- 오스틴 공개 데이터를 쓴 선행 연구는 대부분 결과 유형을 **다중분류해 정확도**로 보고했고(9절), 평가 기간과 분할 방식이 성능에 주는 영향은 따로 살피지 않았다. 안락사는 전체 결과의 몇 퍼센트라 정확도로는 그 탐지력을 알 수 없다.
- 보호소 결과는 입소 후 시간이 지나야 확정되고, 공개 데이터에는 결과에 따라 나중에 채워지는 기록(이름·성별)이 섞여 있다. 운영 시점에 알 수 있었던 정보만으로 평가해야 한다.
- 본 연구는 **운영 시점 기준의 평가**로 성능을 제시하고, 선행연구 방식 재현·평가 대상 고정 실험·단순 기준선 비교로 **보고 성능이 무엇에 좌우되는지**를 분리한다.

4. 연구 질문과 기여

	연구 질문	답 (최종본 결과)
RQ1	입소 시점 정보만으로 개·고양이의 90일 이내 안락사 위험을 선별할 수 있는가?	AP 0.108 [0.087, 0.143] (기준선 4.9배), ROC-AUC 0.811
RQ2	보고 성능은 분할 방식·평가 기간·평가 지표 중 무엇에 좌우되는가? (E1·E2)	전 기간 무작위 평가 AP 0.221 vs 시간 검증 0.108이지만, 평가 대상을 2024로 고정하면 무작위 학습 0.108 (-0.0009 [-0.004, 0.001]) → 분할 효과는 확인되지 않음. 다중분류 정확도는 비슷해도 안락사 재현율 0.286→0.036
RQ4	단순 규칙·로지스틱 회귀보다 나은가? (E3)	AP 최종 0.108 vs 로지스틱 0.102 (-0.0055 [-0.023, 0.013]), 규칙 0.091 (-0.0181 [-0.041, 0.001]) → 차이 확인되지 않음
RQ3	운영에 적용하면 검토 규모에 따라 무엇을 얻는가?	선별 10% → Recall 0.538, 20% → 0.735, 30% → 0.782

기여점

- **라벨 확정 시점 기준의 평가 체계**: 기간 고정 라벨(90일)과 시점 기준 분할로, 입소 연도 분할에서 생기는 시간 위반(검증 라벨 7.19%)을 제거
- **데이터 정합성 검증**: 날짜 형식 판정·외부 대조, 입·퇴소 연결 규칙, 이름 변수 누수(입소·퇴소 이름 100% 일치, 즉시 안락사의 70.8%가 이름 없음), 2021년판 대조 사후 수정 점검, **성별 Unknown이 체류 중 채워지는 결과 반영 신호**임을 자연 실험으로 확인해 제외
- **선행연구 방식 재현 (E1)**: 결과 5종 다중분류·정확도 평가를 같은 데이터로 재현해, 정확도가 비슷해도 드문 안락사를 거의 찾지 못함을 보임
- **평가 설계 효과의 분리 (E2)**: 평가 대상을 2024로 고정하고 학습 분할만 바꿔, 무작위 분할의 높은 수치가 분할 방식이 아니라 평가 기간·대상 구성에서 옴을 확인

- **단순 기준선 비교 (E3)**: 규칙(건강상태→나이)·로지스틱 회귀와 같은 검토량에서 비교해, 예측력의 대부분이 건강상태·나이에 있음을 정직하게 보고
- **운영 관점 보고**: 선별 규모별 Recall·Precision·검토 건수와 입양 × 안락사 두 축 분류(운영 가설)

5. 데이터와 방법

항목	내용
데이터	City of Austin Open Data, Austin Animal Center 입소 173,812건 · 퇴소 173,775건 (2013-10 ~ 2025-05)
대상	개·고양이, 안락사 요청 입소 제외, 관찰 기간 90일이 끝난 입소. 야생동물 등 기타 동물은 비교용
라벨	입소 후 90일 이내 안락사 (안락사의 97.5%가 90일 이내)
특성 (12개)	동물 종류, 입소 유형, 건강상태, 품종군, 생애단계, 품종(상위 15), 색상(상위 15), 나이, 입소 월, 혼종, 다색, 중성화됨 여부 (이름·성별·중성화 범주형 제외: 결과 반영 신호)
분할	선택 폴드 3개(2019-10 ~ 2022-10) → 보정 구간(2022-10 ~ 2023-10) → 테스트(2024년 입소)
선택	모델 5계열 기본값 비교 → 변수 → 상위 3계열 × 불균형 전략 × 하이퍼파라미터(같은 예산) → 직접 vs 2단계, 모두 명시한 규칙 적용
평가	AP·기준선 대비 배수·ROC-AUC, 운영 임곗값의 Recall·Precision, 선별 규모별 지표, 동물 ID 군집 부트스트랩 95% CI, 자동 무결성 검사 (아래 표)

5-1. 평가 기준과 선택 이유

기준	뜻	왜 썼나
AP (PR-AUC)	위험 순위대로 검토할 때, 안락사를 찾아내는 비율이 커지는 동안의 정밀도 평균 (0~1)	양성이 2.2%로 드물어 정확도는 의미가 없음(모두 '아님'이라고만 해도 97.8%). AP는 드문 사건 탐지력을 직접 보여 주고 기준선(양성 비율)이 명확함
기준선 대비 배수	AP ÷ 양성 비율. 무작위로 고를 때보다 몇 배 나은가	구간마다 안락사율이 달라 AP 원값끼리는 비교가 어려움. 배수로 바꾸면 시기·분할이 달라도 비교 가능
ROC-AUC	안락사 동물과 아닌 동물을 하나씩 뽑을 때 안락사 동물의 점수가 더 높을 확률	가장 널리 쓰는 순위 지표라 다른 연구와 소통이 쉬움. 드문 사건에서는 좋게 나오는 경향이 있어 보조 지표로 둠
Recall · Precision (운영 임곗값)	임곗값을 넘은 동물을 검토할 때 찾아낸 안락사 비율 / 검토 대상 중 실제 안락사 비율	보호소가 실제로 쓰는 방식(일부만 검토)의 결과. 임곗값은 테스트가 아니라 보정 구간에서 Recall 0.8 목표로 정함
선별 규모별 지표	5~30% 선별 시 Recall·Precision, 월평균 검토 건수, 안락사 1건당 검토 건수	검토 인력이 정해지지 않았으므로 하나의 정답 대신 여러 규모의 결과를 제시
동물 ID 군집 부트스트랩 95% CI	동물 단위로 다시 뽑아 계산한 지표의 불확실성 범위	같은 동물이 여러 번 입소해 행 단위로 뽑으면 구간이 실제보다 좁아짐. 모델 비교도 같은 재표본에서 짝지어 함
자동 무결성 검사	시간 위반·학습/평가 동물 중복·연결 규칙 위반·누수 변수를 코드로 확인	성능이 아니라 평가 자체가 올바른지 확인하는 장치 (22/22 통과)

요약하면, 사건이 드물어서 AP와 배수를, 운영에 쓰려고 선별 규모별 Recall·Precision을, 불확실성을 정직하게 보고하려고 군집 신뢰구간과 무결성 검사를 썼습니다.

6. 현재 결과 (최종본 실행 출력)

구분	지표	값
주 결과	AP [군집 95% CI]	**0.108** [0.087, 0.143] · 기준선 0.022의 4.88배
	ROC-AUC	0.811 [0.779, 0.838]
	보정 구간 임곗값 적용	선별 32.4% → Recall 0.782, Precision 0.053
선택	모델 · 전략 · 구조	XGBoost (부스팅) · 가중치 · 직접모델
민감도	이름 포함 / 요청 포함	AP 0.116 (차이 +0.0091 [-0.009, 0.027]) / 0.109
비교 실험	E1 선행연구 방식 재현 (XGB 다중분류)	정확도 0.615~0.675, 안락사 재현율 0.286(2013~16 무작위) → 0.036(시간 분할)
	E2 같은 2024 평가, 학습 분할만 변경	T1 0.108 · T2 0.108 · R1 0.108 (-0.0009 [-0.004, 0.001]) · R2 0.108 → 차이 확인되지 않음
	E3 단순 기준선 (같은 검토량 3,492건)	Recall 최종 0.782 · 로지스틱 0.777 · 규칙 0.756 · 무작위 0.332
	참고: 전 기간 무작위 분할 평가	AP 0.221 vs 시간 검증 0.108 — 평가 대상(기간)이 달라 생긴 차이 (E2)
	같은 예산 튜닝 후 계열	XGBoost 평균 AP 0.177, LightGBM 대비 -0.0123 [-0.027, 0.004] (LightGBM - XGBoost, 검증)
	계열별 테스트 참고값 (보고용)	LightGBM 테스트 AP 0.104 (최종 대비 -0.0046 [-0.020, 0.007]) — 검증·테스트 모두 계열 간 차이는 확인되지 않음
	성별·중성화 범주형 포함 (보고용)	AP 0.127 (차이 +0.0187 [-0.000, 0.044]) — 결과 반영 신호라 운영 성능 아님
	비용 비율 r=20 / 50	선별 9.1%·Recall 0.454 / 선별 21.1%·Recall 0.727
	사후 수정 입소 제외	AP 0.107 (차이 -0.0000 [-0.003, 0.005])
운영 가설	두 축 핵심 칸	입소 26.8%에 양성의 67.2% (입양 기준값 0.559)
검증	자동 무결성 검사	22/22 통과

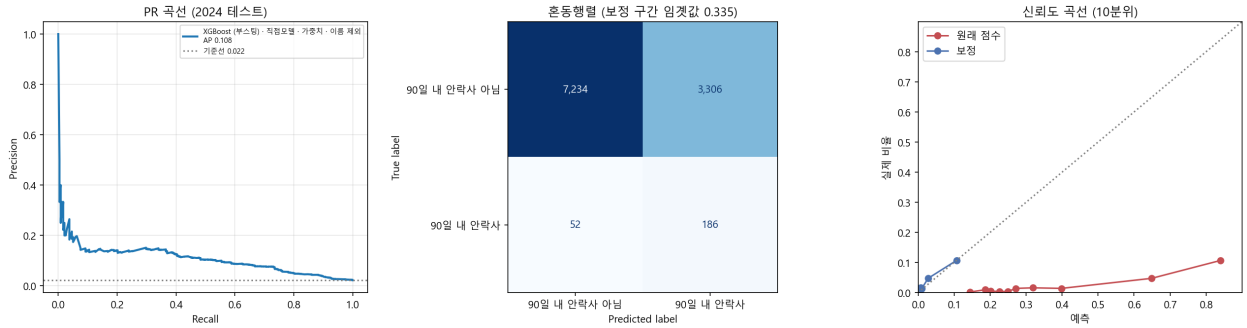


그림 A. 2024 테스트 PR 곡선 · 혼동행렬 · 신뢰도 곡선 (논문 그림 1 후보)

7. 논문 구성안 (2단, 4~5쪽 목표)

절	내용	분량	그림·표
요약 · Abstract · Key words	국·영문 초록, 키워드 6개	0.4쪽	-
Ⅰ. 서론	보호소 문제, 지능형 의사결정 지원, 기존 평가의 한계(정확도 중심·평가 기간 미명시·시점 위반·누수), 기여 4가지	0.5쪽	-

절	내용	분량	그림·표
Ⅱ. 관련 연구	오스틴 데이터 선행 연구(9절), 누수 유형, 시간 검증 찬반(Roberts / Bergmeir), TRIPOD, 불균형 평가	0.5쪽	-
Ⅲ. 제안 방법	3.1 데이터와 누수 점검 / 3.2 라벨과 시점 기준 분할 / 3.3 모델 선택과 평가 지표 / 3.4 비교 실험 설계(E1~E3)	1.2쪽	그림 1: 분할 구조
Ⅳ. 실험 및 결과	4.1 모델 선택·2024 테스트·단순 기준선(E3) / 4.2 선행연구 방식 재현(E1) / 4.3 평가 설계 효과의 분리(E2) / 4.4 누수 영향과 운영 지표	1.8쪽	표 1~3, 그림 2
Ⅴ. 결론	요약(보고 성능은 평가 기간·대상·지표에 좌우), 한계, 향후 과제	0.4쪽	-

논문 v3 구성: 표 1 = 2024 테스트와 단순 기준선(E3), 표 2 = 선행연구 방식 재현(E1), 표 3 = 평가 설계 효과 분리(E2), 그림 1 = 분할 구조, 그림 2 = 변수 단위 SHAP. 5쪽에 맞췄습니다.

8. 초록 (논문 v3에 실은 문안)

정확한 수치 대신 큰 흐름 위주로 썼습니다. 수치는 본문 표 1~3에 있습니다.

요약

동물보호소가 입소 시점에 안락사 위험이 높은 동물을 미리 알 수 있다면 의료·행동 교정·입양 연계 같은 제한된 자원을 먼저 배정할 수 있다. 그러나 기존 연구는 대부분 결과 유형을 다중분류해 정확도로 평가했고, 평가 기간과 데이터 분할 방식이 성능에 미치는 영향은 따로 살피지 않았다. 본 논문은 미국 오스틴 동물보호센터의 공개 기록으로 개·고양이의 입소 후 90일 이내 안락사를 예측하면서, 결과가 확정된 시점을 기준으로 데이터를 나누고, 공개 데이터의 이전 판과 대조해 이름·성별처럼 결과에 따라 나중에 채워지는 기록을 학습에서 제외했다. 제안 모델은 입소 동물의 약 3분의 1만 우선 검토해도 90일 이내 안락사의 대부분을 미리 찾아냈다. 선행연구 방식을 재현하면 정확도는 비슷하게 나왔지만 안락사는 거의 찾지 못했고, 같은 평가 대상에서는 학습 데이터를 시간 순으로 나누든 무작위로 나누든 성능 차이가 거의 없었다. 즉 보고 성능은 분할 방식보다 평가 기간과 대상 구성, 그리고 평가 지표에 크게 좌우되므로, 보호소 예측 연구는 이를 명시하고 드문 결과의 탐지력을 직접 평가해야 한다.

Abstract

If animal shelters could identify animals at high risk of euthanasia at intake, they could prioritize limited resources such as medical care, behavioral support, and adoption partnerships. However, most previous studies classified outcome types and reported accuracy, without examining how the evaluation period and data split affect performance. Using public records from the Austin Animal Center, this paper predicts euthanasia within 90 days of intake for dogs and cats, splitting data by the time outcomes are confirmed and excluding records, such as name and sex, that are filled in later depending on the outcome, identified by comparison with an earlier public release. The proposed model identified most euthanasia cases within 90 days while prioritizing only about one third of intakes for review. Reproducing previous setups yielded similar accuracy but detected almost no euthanasia cases, and on the same evaluation set, chronological and random training splits performed almost identically. Reported performance therefore depends more on the evaluation period, population, and metric than on the split method, and shelter prediction studies should state these and directly evaluate the detection of rare outcomes.

근거: '약 3분의 1' = 선별 32.4%, '대부분' = Recall 78.2%, '거의 찾지 못했다' = 시간 분할 다중분류의 안락사 재현율 0.036, '차이가 거의 없었다' = E2의 AP 0.1076~0.1084이고 차이 신뢰구간이 모두 0을 포함(동등하다는 뜻은 아님).

9. 선행 연구 (원문 확인, 논문 참고문헌 15편 중 주요 문헌)

연구	데이터·과제	분할	보고 성능	본 연구와의 차이
[1] Lepper, Kass, Hart (2002), J. Appl. Anim. Welf. Sci. 5(1)	캘리포니아 한 보호소 개·고양이, 입양 vs 안락사 로지스틱 회귀	-	요인 분석 (나이·성별·털색·포기 사유)	예측 성능 평가가 아님
[3] Parte (2019), NCI 석사 프로젝트	오스틴 2013.10~2016.03 약 2.6만 건, 결과 다중분류	무작위 80:20	XGBoost 정확도 65.33%	정확도 중심. E1 (i)에서 정확도 0.615로 재현
[4] Kim, Choi, Kang (2021), 한국인공지능학회지 9(1), 29-35	오스틴 입·퇴소, 결과 다중분류(다중 로지스틱 회귀)	명시 없음	정확도 0.627, 매크로 재현율 0.255	소수 결과(안락사) 탐지가 약함
[5] Bradley & Rajendran (2021), BMC Vet. Res. 17:70	여러 보호소 114,256건, 체류기간 4등급(안락사 포함)	무작위 80:20 + 10-fold	안락사 등급 F1 0.748	무작위 분할, 평가 기간 구분 없음
[6] Rodriguez 외 (2022), Front. Vet. Sci. 9	미국 보호소 2016~2020 입소·결과 추세	-	입소·안락사 유의하게 감소	평가 기간에 따라 기준선이 달라지는 근거

방법론 문헌	내용	본 연구에서의 쓰임
[7] Kaufman 외 (2012) TKDD · [8] Kapoor & Narayanan (2023) Patterns	누수 유형 정리 (시간 누수, 예측 시점에 없는 정보)	이름·성별 Unknown 제외, 라벨 확정 시점 분할의 근거
[9] Roberts 외 (2017) Ecography	구조가 있는 데이터에서 무작위 CV는 오차를 과소추정, 블록 검증 권고	시간 검증을 쓰는 근거
[10] Bergmeir, Hyndman, Koo (2018) CSDA	오차 상관이 없으면 일반 k겹 CV도 타당 (반증)	시간 검증 효과는 데이터마다 실증해야 함 → E2
[11] TRIPOD (Collins 외 2015) · [12] Saito & Rehmsmeier (2015)	시간적 검증을 엄격한 검증으로 분류 / 불균형에서는 PR 곡선이 더 유익	검증 설계와 AP 주 지표의 근거

지표·과제·데이터가 달라 선행 연구 수치를 직접 비교할 수 없어, 같은 데이터에서 선행연구 방식을 재현(E1)해 비교 근거로 씁니다. Kiv 외(2024, 댈러스, ARIMA+RF/LSTM)도 확인했으나 쪽수 때문에 인용하지 않았습니다.

9-1. 시간 검증을 택한 이유 (10/10 수정)

이전 기획서는 "무작위 분할은 성능을 부풀린다"를 이유로 들었지만, E2에서 같은 2024 평가 대상으로 고정하면 학습 분할에 따른 차이를 확인하지 못해 이 근거는 뺐습니다. 남는 이유는 다음과 같습니다.

- **실제 쓰임과 같은 조건**: 보호소는 지금까지의 기록으로 모델을 만들어 앞으로 들어올 동물에 쓴다. 보고하는 성능도 그 조건(과거로 학습, 미래 입소로 평가)에서 나와야 운영 성능이라 할 수 있다.
- **결과가 늦게 확정되는 데이터**: 안락사 여부는 입소 후 시간이 지나야 확정되므로 '선택에 쓰는 결과는 그 시점 이전에 확정된 것만'이라는 조건이 필요하다. 입소 연도로만 나눈 이전 버전은 검증 라벨의 7.19%가 선택 시점 이후에 확정된 정보였다.
- **평가 기간에 따라 기준선이 바뀜**: 안락사율이 구간마다 다르다(선택 폴드 2.1%~2.4%, 보정 구간 1.6%, 테스트 2.2%). 전 기간 무작위 평가 AP 0.221가 시간 검증 0.108보다 높은 것도 평가 기간·대상 차이에서 온다(E2).
- **반증도 함께 제시**: Bergmeir 외[10]는 조건에 따라 일반 교차검증도 타당함을 보였다. 이 데이터에서도 학습 분할 효과는 확인되지 않았으므로, 시간 검증의 의의를 '수치를 낮춘다'가 아니라 '선택에 미래 라벨이 섞이지 않고 운영 시점 성능을 보고한다'로 한정한다.
- **보고 지침**: TRIPOD[11]도 시간적 검증을 무작위 분할보다 엄격한 검증으로 분류한다.

학습 데이터 (평가는 모두 2024 테스트)	AP [95% CI]	차이 [95% CI]
T1 시간 순 (주 분석)	0.108 [0.087, 0.143]	기준
T2 시간 순 + 최신 (~2023-10)	0.108 [0.087, 0.145]	+0.0008 [-0.004, 0.005] (T1 대비)
R1 무작위 (T1과 같은 크기, 5회)	0.108 [0.087, 0.143]	-0.0009 [-0.004, 0.001] (T2 대비)
R2 무작위 (전체 풀)	0.108 [0.087, 0.143]	-0.0009 [-0.004, 0.002] (T2 대비)

> 논문용 문장 (v3 4.3절): 평가 대상을 2024년으로 고정하면 학습을 시간 순으로 하든, 최신 데이터를 더하든, 미래를 포함해 무작위로 뽑든 AP 차이를 확인하지 못했다. 즉 이 데이터에서 무작위 분할의 높은 수치는 분할 방식보다 평가 기간과 대상 구성의 차이에서 온다. 시간 검증의 의의는 수치를 낮추는 데 있지 않고, 선택에 미래 라벨이 섞이지 않게 하고 운영 시점의 성능을 제시하는 데 있다.

9-2. 선행 연구와의 성능 비교 (E1)

직접 비교는 할 수 없다. 선행 연구는 결과 다중분류·체류기간 등급을 정확도·F1로 보고했고, 본 연구는 90일 이내 안락사(이진)를 AP·ROC-AUC로 평가했다. 대신 같은 데이터에서 선행연구 방식을 재현했다.

평가 설정	정확도	매크로 재현율	안락사 Recall	안락사 AP	안락사 비율
(i) 2013~16 무작위 80:20	0.615	0.436	0.286	0.323	5.2%
(ii) 2013~24 무작위 80:20	0.641	0.391	0.129	0.218	2.7%
(iii) 시간 분할 (평가 2024)	0.675	0.389	0.036	0.110	2.3%

XGBoost 결과 5종 다중분류. 다중 로지스틱 회귀도 시간 분할에서 안락사 재현율 0.057. 정확도는 Parte(65.33%)·Kim 외(0.627)와 비슷하게 재현되었습니다.

- **정확도는 비슷하지만 안락사를 못 찾음**: 정확도는 0.615~0.675로 선행 연구 수준이지만, 최대 확률 클래스로 판정하면 안락사 재현율이 0.286→0.036로 떨어진다. 정확도가 가장 높은 설정에서 안락사를 거의 찾지 못했다.
- **AP 차이는 기준선 차이**: 안락사 AP가 0.323→0.110로 낮아지지만, 같은 기간 안락사 비율도 5.2%→2.3%로 줄어 기준선 자체가 다르다.
- **쉽게 맞히는 경우를 뺌**: 결과가 입소 때 정해지는 안락사 요청 입소와 야생동물 등 기타 동물을 분석 대상에서 제외했다.
- **누수 변수를 뺌**: 이름 변수를 처음부터 제외했고, 성별 Unknown 신호(성별·중성화 범주형)를 없애자 테스트 AP가 0.126에서 0.108로 내려갔다. 줄어든 만큼은 입소 시점에 알 수 없는 정보였다.

> 논문용 문장 (v3 4.2절): 정확도는 선행연구와 비슷하게 재현되었으나, 최대 확률 클래스로 판정하면 안락사 재현율은 0.286(2013~16 무작위)에서 0.036(시간 분할)로, 정확도가 가장 높은 설정에서 안락사를 거의 찾지 못했다. 정확도 중심의 평가는 드문 결과의 탐지력을 가린다.

9-3. 단순 기준선 비교 (E3)

방법	AP [95% CI]	배수	최종 대비 차이 [95% CI]	같은 검토량 Recall
최종 모델 (XGBoost)	0.108 [0.087, 0.143]	4.88	기준	0.782
로지스틱 회귀	0.102 [0.082, 0.135]	4.63	-0.0055 [-0.023, 0.013]	0.777
규칙 (건강상태→나이)	0.091 [0.071, 0.121]	4.11	-0.0181 [-0.041, 0.001]	0.756
무작위 선택	0.024 [0.020, 0.034]	1.09	-0.0867 [-0.117, -0.061]	0.332

같은 검토량(3,492건)에서 규칙만으로도 안락사의 75.6%를 찾습니다. 최종 모델의 AP가 가장 높지만 차이 신뢰구간이 0을 포함하므로 "모델이 규칙보다 낫다"고 쓰지 않고 "예측력의 대부분은 건강상태와 나이에서 나온다"고 씁니다. '차이를 확인하지 못함'을 '동등하다'로 쓰지도 않습니다.

10. 일정 (10/7 ~ 10/23)

기간	할 일	상태
~ 10/9	분석 최종본 확정 (두 수정 요청 통합, 사후 수정 점검, 같은 예산 계열 튜닝 → XGBoost, 성별 Unknown 누수 제거, 무결성 검사 통과)	**완료**
10/10	문헌 조사(15편 원문 확인) · 비교 실험 E1~E3 · 결론 수정 · 논문 초안 v3(한글 양식 5쪽) · 보고서·기획서·해설지 갱신	**완료**
10/11 ~ 10/18	소속·이메일·공동저자 기입, 지도교수 검토, 문장 다듬기·유사도 점검	예정
10/19 ~ 10/23	수치 대조(outputs_final/·outputs_compare/와 비교) · 최종 hwp 확인 · **10/23 투고**(hwp + 웹 양식)	예정

11. 추정 채점 기준과 자체 평가

공식 채점 기준은 공개되지 않아, 학회 안내문(창의성·독창성·타당성, 기존 연구와 비교, 25점 중 18점)과 대학생 부문 수상작 77편의 공통점으로 만든 추정 기준입니다.

기준 (각 5점)	점수	근거	보완
1. 주제 적합성·필요성	4	공공 서비스의 지능형 의사결정 지원, 기술 용어를 넣은 제목	서론에서 ICT 연구로 위치 설정
2. 창의성·독창성	4	라벨 확정 시점 기준 평가 체계, 공개 데이터 이전판 대조로 찾은 누수, 평가 대상 고정으로 분할·기간 효과 분리(E2)	모델보다 평가 설계를 기여로 서술. 단순 기준선과 차이가 확인되지 않아 모델 성능은 기여로 내세우기 어려움
3. 방법의 타당성·완성도	5	순차 검증, 보정 구간 분리, 군집 부트스트랩, 무결성 검사 22개 통과, 이름·성별 누수 제거	분할 구조 그림 1장
4. 실험·비교 검증	5	선행연구 방식 재현(E1), 평가 설계 분리(E2), 단순 기준선(E3)으로 학회 안내의 '기존 연구와 비교'를 같은 데이터에서 수행. 5계열·같은 예산 튜닝, 민감도 9종, 비용 분석	기준선과 차이 미확인을 결과로 정직하게 서술
5. 작성 완성도 (예상)	4	한글 양식 5쪽 초안(v3), 표 3개·그림 2개, 국·영문 초록	소속 기입, 문장 다듬기, 수치 대조
합계	**22**	18점 기준선 통과 (범위 19~23, 이전 21)	4번은 실제로 추가된 비교 실험을 근거로 올림. 심사 결과를 보장하지 않음

12. 위험요소와 대응

위험요소	대응
AP 수치가 작아 보임	항상 기준선·배수·군집 CI와 함께 제시하고, 선별 규모별 지표로 의미를 설명
계열 선택이 LightGBM에서 바뀜	미리 정한 규칙의 결과임을 밝히고, 검증 차이와 테스트 참고값(계열 간 차이 미확인)을 함께 보고
성별을 왜 뺐느냐는 질문	Unknown이 체류 중 채워지는 근거(6-4)와 성별 효과 표를 함께 제시, 이진 후보(중성화·수컷 여부)로 정상 정보를 다시 평가했음을 설명
v3보다 수치가 낮아짐	누수 제거·대상 변경의 결과임을 밝히고, v3 방식 재현 행으로 차이의 출처를 보여줌
"시간 검증해도 수치가 같은데 왜 했나"	E2 결과를 그대로 인정하고, 시간 검증의 의의를 미래 라벨 차단과 운영 시점 성능 보고로 한정(9-1)
"단순 규칙과 차이가 없으면 ML이 왜 필요한가"	차이 미확인은 동등을 뜻하지 않음을 밝히고, 기여를 모델 성능이 아니라 평가 설계·누수 점검·운영 지표로 둠
공개 데이터의 사후 수정 (중성화 상태 등)	2021년판 대조로 변경 0.51% 확인, 변경 입소 제외 민감도에서 영향 미확인. 2021-03 이후 기록은 점검 불가임을 한계로 명시
테스트 기간을 이전 버전에서 본 적 있음	한계로 명시하고, 최종본은 테스트를 어떤 선택에도 쓰지 않았음을 강조
두 축 분류가 처방처럼 읽힘	운영 가설·제안으로만 표기하고 인과 주장을 하지 않음
쪽수 제한	표 2개·그림 2개로 압축, 나머지는 한 문장 처리

13. 제출 전 체크리스트

☐	학회 표준형식 양식(hwp), 2단, 2~5쪽 · 대학생논문경진대회 부문 · 1저자 대학생
☐	국·영문 제목·요약·Abstract·Key words
☐	모든 수치를 outputs_final/summary.json·CSV와 대조
☐	그림 150dpi 이상, 그림·표 번호와 본문 인용 일치
☐	참고문헌은 원문 확인한 것만, 보고서 문장을 그대로 옮기지 않기(유사도)
☐	사전등록 11/10까지