동물보호소 개·고양이 안락사 예측에서 평가 설계와 데이터 누수가 보고 성능에 미치는 영향

전건우*

Effects of Evaluation Design and Data Leakage on Reported Performance in Predicting Euthanasia of Shelter Dogs and Cats

Geon Woo Jeon*

요 약

입소 시점에 안락사 위험이 높은 동물을 알면 보호소는 그 동물에게 자원을 먼저 배정할 수 있다. 그러나 기존 연구는 대부분 결과 유형을 다중분류해 정확도로 평가했고, 평가 기간·데이터 분할·기록 누수가 보고 성능에 주는 영향은 살피지 않았다. 본 연구는 미국 오스틴 동물보호센터의 공개 기록으로 개·고양이의 입소 후 90일 이내 안락사를 예측하며 이를 분석했다. 첫째, 공개 데이터의 이전 판과 대조해 성별 'Unknown'처럼 결과에 따라 나중에 채워지는 기록(누수)을 찾았다. 둘째, 선행연구 방식(결과 5종 다중분류)을 재현하면 정확도는 선행연구와 비슷한 0.61~0.67이었지만 2024년 평가에서 안락사 재현율은 0.036에 그쳤다. 셋째, 전 기간을 무작위로 나눠 평가하면 평균 정밀도(AP)가 0.221로 2024년 성능(0.108)의 약 2배였으나, 평가 대상을 2024년으로 고정하면 학습 데이터를 어떻게 나누든 AP가 같아(0.108) 이 차이는 분할 방식이 아니라 평가 기간에서 온 것으로 보였다. 최종 모델은 입소의 32.4%를 검토해 90일 이내 안락사의 78.2%를 찾았으나 단순 규칙과의 차이는 확인되지 않았다. 보호소 예측 연구는 운영 시점과 같은 미래 기간으로 평가하고 드문 결과의 탐지력을 직접 보고해야 한다.

Abstract

Identifying animals at high risk of euthanasia at intake would let shelters prioritize their care. However, most previous studies evaluated outcome-type classification by accuracy, without examining how the evaluation period, data split, and record leakage affect reported performance. Using public records from the Austin Animal Center, we predict euthanasia within 90 days of intake for dogs and cats and examine these effects. First, by comparison with an earlier public release, we found records such as sex 'Unknown' that are filled in later depending on the outcome (leakage). Second, reproducing previous setups (five-class outcome classification) gave an accuracy of 0.61-0.67, similar to previous studies, but a euthanasia recall of only 0.036 on 2024 intakes. Third, a random split over all periods reported an average precision (AP) of 0.221, about twice the 2024 performance (0.108); with the 2024 evaluation set fixed, however, AP was the same (0.108) regardless of how the training data were split, so the gap appeared to come from the evaluation period rather than the split method. The final model found 78.2% of 90-day euthanasia cases while reviewing 32.4% of intakes, but no difference from a simple rule was confirmed. Shelter prediction studies should evaluate on future periods matching deployment and report the detection of rare outcomes directly.

Key words

animal shelter, euthanasia prediction, evaluation design, data leakage, temporal validation, public administrative data

*소속, Email, **소속, Email(교신저자표시), ...

※ 지원기관표기(사사표기)

Ⅰ. 서 론

공공 동물보호소는 제한된 의료·행동 교정·입양 연계 자원으로 연간 수만 건의 입소를 처리한다. 입소 시점에 위험이 높은 동물을 알면 그 동물을 먼저 돌볼 수 있어, 위험 예측은 동물 복지와 보호소의 의사결정을 함께 돕는다.

미국 오스틴 동물보호센터의 공개 데이터를 쓴 선행 연구는 대부분 결과 유형을 다중분류해 정확도로 성능을 보고했고[1, 2], 여러 보호소 데이터를 쓴 연구도 무작위 분할로 평가했다[3]. 그러나 안락사는 전체 결과의 몇 퍼센트라 정확도로는 그 탐지력을 알기 어렵다. 또 보호소 결과는 입소 후 시간이 지나야 확정되므로 입소 연도로만 나누어도 모델 선택에 쓰는 라벨 일부가 그 시점 이후에 확정되며(입소 연도로 나눈 예비 분석에서 검증 라벨의 7.19%), 공개 데이터에는 결과에 따라 나중에 채워지는 기록이 섞일 수 있다[4].

이에 본 연구는 개·고양이의 입소 후 90일 이내 안락사 예측을 사례로 '공개 행정 데이터로 보호소 결과를 예측할 때 무엇이 보고 성능(논문에 보고되는 성능)을 운영 성능(실제 미래 입소에서의 성능)과 다르게 만드는가'를 묻는다. 이를 두 축으로 살핀다. 첫째, 결과에 따라 나중에 채워지는 기록(누수)이 있는지 이전 공개판과 대조해 점검한다. 둘째, 보고 성능이 분할 방식, 평가 기간, 평가 지표 중 무엇에 좌우되는지 분리한다. 아울러 최종 모델을 단순 기준선과 비교한다. 본 연구는 더 좋은 예측 모델을 제안하기보다, 운영 시점에 실제로 알 수 있었던 정보만으로 성능을 평가하는 방법을 제시하고 그 효과를 실제 데이터로 확인한다.

Ⅱ. 관련 연구

Parte[1]는 2013~2016년 약 2.6만 건을 80:20으로 무작위로 나누어 XGBoost로 정확도 65.33%를 보고했다. Kim 등[2]은 상관 분석으로 동물 종류, 입소 유형, 퇴소 시점 나이를 골라 다중 로지스틱 회귀로 정확도 0.627, 매크로 재현율 0.255를 보고했으나, 퇴소 시점 나이는 입소 때는 알 수 없는 정보이다. Bradley와 Rajendran[3]은 여러 보호소의 114,256건으로 안락사를 포함한 체류기간 등급을 무작위 분할로 예측해 안락사 등급 F1 0.748을 보고했다. 세 연구는 평가 기간을 구분하지 않고 정확도·F1 중심으로 평가했으며, 기록이 언제 채워졌는지는 다루지 않았다.

Kapoor와 Narayanan[4]은 예측 시점에 알 수 없는 정보가 학습에 섞이는 누수를 재현성 위기의 한 원인으로 지적했다. Roberts 등[5]은 시간 구조가 있는 데이터에서 무작위 교차검증이 오차를 과소추정할 수 있다고 했지만, Bergmeir 등[6]은 오차 상관이 없으면 일반 교차검증도 타당함을 보였다.

Ⅲ. 연구 방법

3.1 데이터와 누수 점검

City of Austin 공개 데이터(data.austintexas.gov)의 입소 173,812건과 퇴소 173,775건(2013-10~2025-05)을 썼다. 입소와 퇴소는 동물 ID로 연결하되, 입소 뒤 다음 입소 전에 처음 나온 퇴소만 그 입소의 결과로 보았다. 대상은 개·고양이이며, 보호자가 안락사를 요청한 입소는 결과가 입소 때 정해지므로 제외했다. 이름은 입소 기록이 퇴소 기록과 100.0% 같아 입소 뒤에 갱신된 값으로 보이고, 이름 없음이 24시간 이내 안락사에 몰려 있어(70.8% 대 24시간 초과 41.6%) 제외했다. 성별 'Unknown'은 세 근거로 결과에 따라 나중에 채워지는 기록(결과 반영 기록)으로 판단했다. 첫째, 2021년 3월 공개판(Kaggle 'Animal Shelter Analytics') 작성 당시 보호소에 있던 입소의 Unknown은 7건 모두 이후 성별로 채워졌으나 이미 퇴소한 입소는 4,261건 중 2건만 바뀌었다. 둘째, 입소 기록의 Unknown 비율은 24시간 이내 안락사에서 17.3%, 24시간~90일 안락사에서 5.4%, 90일 초과 안락사에서 0.0%였다. 셋째, 성별 변수의 성능 향상은 Unknown 입소에서만 나타났다(4.1절). 따라서 성별·중성화 범주형 변수를 빼고, Unknown을 구별할 수 없게 만든 이진 변수(중성화됨 여부: Unknown을 0으로, 수컷 여부: Unknown을 무작위 배정)만 후보로 평가해 중성화됨 여부를 채택했다.

3.2 라벨과 시점 기준 분할

라벨은 입소 후 90일 이내 안락사이다(개·고양이

안락사의 97.5%가 90일 이내). 결과가 확정된 입소만 학습에 쓰도록 각 구간의 학습 데이터는 '입소일 +90일 ≤ 구간 시작'인 입소로 한정했다. 그림 1과 같이 모델 선택용 검증 구간(선택 폴드, 2019-10~2022-10의 12개월 구간 3개), 보정 구간(2022-10~2023-10), 2024년 테스트로 나눈다. 선택 폴드에서는 모델만 고르고, 보정 구간에서는 검토 대상을 고르는 점수 기준(임곗값, 재현율 0.8 목표)만 정한다. 임곗값을 선택 폴드나 테스트에서 정하면 같은 데이터를 두 번 쓰게 되므로 별도 구간을 두었다. 테스트는 어떤 선택에도 쓰지 않으며, 학습과 같은 동물이 섞이지 않도록 평가 구간에서는 이전에 입소한 적이 있는 동물을 제외했다.

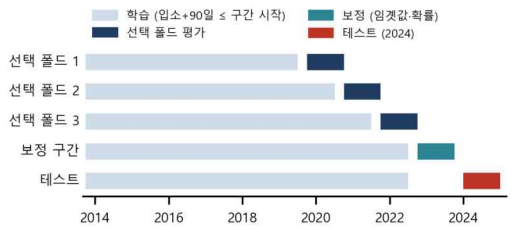


그림 1. 결과 확정 시점 기준 분할 구조
Fig. 1. Data split based on the time when labels are confirmed

3.3 모델 선택과 평가 지표

양성 비율이 2.2%로 낮아 정확도 대신 평균 정밀도(Average Precision, AP: 정밀도-재현율 곡선 아래 면적)를 주 지표로, 무작위로 고를 때의 몇 배인지(무작위 대비 배수 = AP ÷ 양성 비율)와 ROC-AUC를 보조 지표로 썼다. 특성은 입소 시점에 알 수 있는 12개(동물 종류, 입소 유형, 건강상태, 품종군, 생애단계, 품종·색상, 나이, 입소 월, 혼종·다색·중성화 여부)이다. 로지스틱 회귀, 랜덤 포레스트, LightGBM, XGBoost, MLP를 기본 설정으로 비교한 뒤 상위 3개 계열을 같은 수(9개)의 하이퍼파라미터 조합으로 튜닝해 3개 선택 폴드의 평균 AP가 가장 높은 것을 골랐다. 신뢰구간은 같은 동물의 입소를 묶어 재표집하는 군집 부트스트랩(500회)으로 구했고, 차이의 95% 신뢰구간이 0을 포함하면 '차이를 확인하지 못함'으로 쓰되 동등하다고 해석하지 않는다.

3.4 비교 실험 설계

세 가지 비교 실험을 했다. 실험 1(E1, 선행연구 방식 재현)은 최종 결과 5종(입양·이송·보호자 반환·안락사·기타)을 최종 모델과 같은 특성으로 다중 로지스틱 회귀와 XGBoost로 분류하고, (i) 2013~16 무작위 80:20, (ii) 전 기간 무작위 80:20, (iii) 시간 분할(평가 2024년)에서 정확도와 안락사 재현율을 비교한다. 실험 2(E2, 평가 대상 고정)는 2024년 테스트를 고정하고 학습 데이터만 시간 순(T1, ~2022-07 입소), 시간 순+최신(T2, ~2023-10 입소), 미래를 포함한 무작위 추출(R1: T1과 같은 크기, 5회 평균, R2: 전체)로 바꾸며, R1·R2는 학습 기간이 비슷한 T2와 비교한다. 실험 3(E3, 단순 기준선)은 같은 검토량에서 최종 모델을 로지스틱 회귀, 그리고 학습 없는 규칙과 비교한다. 규칙은 선행연구[2]처럼 소수 요인만 쓰되 입소 시점 정보로 한정해, 건강상태(부상·질병 > 기타 비정상 > 정상) 순, 같은 상태에서는 나이가 많은 순으로 위험을 매긴다.

Ⅳ. 실험 및 결과

4.1 이전 공개판 대조로 찾은 결과 반영 기록

성별·중성화 범주형 변수를 넣으면 2024년 테스트 AP가 0.108에서 0.127로 높아졌다(차이 +0.0187, 95% 신뢰구간 하한은 약 0). 그러나 성별이 Unknown이 아닌 입소만 놓고 같은 비교를 하면 차이가 +0.0012 [-0.008, 0.009]로 거의 사라져, 성능 향상은 성별 정보가 아니라 Unknown이라는 결과 반영 기록에서 온 것으로 보인다.

4.2 판정 방식이 바꾸는 탐지율 (E1)

그림 2의 E1에서 정확도는 0.615(2013~16 무작위), 0.641(전 기간 무작위), 0.675(시간 분할)로 선행연구[1, 2]와 비슷했고, 시간 분할에서 오히려 가장 높았다. 평가 데이터의 안락사 비율이 5.2%, 2.7%, 2.3%로 낮아져 다수 결과(입양 등)를 맞히기 쉬워졌기 때문으로 보인다. 반면 각 동물을 확률이 가장 높은 결과로 분류했을 때 안락사 재현율은 0.286, 0.129, 0.036으로 떨어져, 정확도가 높아도 드문 안락사는 거의 찾지 못했다. 그런데 2024년 다중분류 모델의 안락사 AP(0.110)는 최종 모델(0.108)과 비슷

해(라벨은 최종 결과 대 90일 이내로 조금 다름), 순위 능력이 비슷해도 가장 높은 확률로 분류하면 안락사의 3.6%만, 위험 점수 순으로 입소의 32.4%를 검토하면 78.2%를 찾는다.

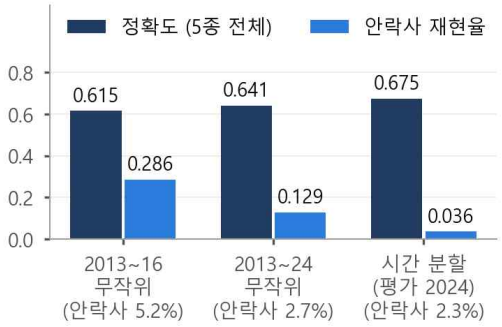


그림 2. 선행연구 방식 재현 결과 (E1)
Fig. 2. Reproducing previous setups (E1)

4.3 무작위 평가가 보고하는 운영 성능 (E2)

이진 모델(90일 이내 안락사)을 동물 단위 무작위 8:2로 나눠 전 기간으로 평가하면 AP는 0.221(무작위 대비 8.1배)로 2024년 시간 검증 결과(0.108, 4.9배)의 약 2배였지만, 같은 무작위 분할 모델도 2024년 입소로만 평가하면 0.120 [0.067, 0.191]로 시간 검증에 가까워졌다(양성 46건).

표 1. 같은 2024년 평가 대상에서 학습 데이터만 바꾼 결과 (E2, *T2는 T1, R은 T2 대비)
Table 1. AP when only the training split changes (E2)

학습 데이터	AP [95% CI]	차이 [95% CI]*
T1 과거(~2022-07)	0.108 [0.087, 0.143]	기준
T2 과거(~2023-10)	0.108 [0.087, 0.145]	+0.0008 [-0.004, 0.005]
R1 무작위(T1 크기)	0.108 [0.087, 0.143]	-0.0009 [-0.004, 0.001]
R2 무작위(전체)	0.108 [0.087, 0.143]	-0.0009 [-0.004, 0.002]

표 1은 평가 대상(2024년 입소)을 고정하고 학습 데이터만 바꾼 E2 결과로, 분할 방식 자체가 성능을 바꾸는지 확인한다. 과거만 쓰든(T1), 최신 데이터를 더하든(T2), 미래 기록을 섞어 무작위로 뽑든(R1·R2) AP는 모두 0.108이었고, 차이는 0.001 이하이며 95% 신뢰구간도 0을 포함했다. 따라서 무작위 평가의 높은 수치는 분할 방식이 아니라 평가 기간·대상의 차이(양성 비율 2.7% 대 2.2%)에서 온 것으로 보이며, 이는 조건에 따라 일반 교차검증도 타당할 수 있다는 관점[6]과 일치한다.

4.4 단순 기준선과의 비교 (E3)

검증 평균 AP가 가장 높은 XGBoost(깊이 3, 트리 200개, 클래스 가중치)를 최종 모델로 골랐다(다른 계열과의 차이는 확인되지 않음). 보정 구간에서 정한 임곗값을 2024년 입소에 적용하면 입소의 32.4%(3,492건)가 검토 대상이 되고, 그중 실제 안락사 비율(정밀도)은 0.053, 전체 안락사 중 찾아낸 비율(재현율)은 0.782였다.

표 2. 2024년 테스트 성능과 단순 기준선 (E3, *최종 모델과 같은 3,492건 검토 시)
Table 2. 2024 test performance and simple baselines (E3)

방법	AP [95% CI]	배수	ROC-AUC	재현율*
최종(XGBoost)	0.108 [0.087, 0.143]	4.88	0.811	0.782
로지스틱 회귀	0.102 [0.082, 0.135]	4.63	0.803	0.777
규칙(상태·나이)	0.091 [0.071, 0.121]	4.11	0.773	0.756
무작위 선택	0.024 [0.020, 0.034]	1.09	0.508	0.332

표 2와 같이 최종 모델의 AP가 가장 높았지만 로지스틱 회귀(차이 -0.0055 [-0.023, 0.013]), 규칙(-0.0181 [-0.041, 0.001])과의 차이는 확인되지 않았고, 건강상태와 나이만 쓰는 규칙도 안락사의 75.6%를 찾았다.

V. 결 론

본 연구는 보호소 안락사 예측에서 보고 성능을 운영 성능과 다르게 만드는 요인을 살폈다. 이전 공개판과의 대조로 성별 Unknown이 결과 반영 기록임을 찾았고, 선행연구 방식은 정확도가 비슷해도 안락사 재현율이 0.036에 그쳤으며, 전 기간 무작위 평가가 보고한 약 2배의 AP는 평가 기간의 차이에서 온 것으로 보였다. 최종 모델은 입소의 32.4%를 검토해 안락사의 78.2%를 찾았으나 단순 규칙과의 차이는 확인되지 않았다. 따라서 보호소 예측은 미래 기간에서 검토량별 재현율과 AP로 평가하고 기록 시점을 점검해야 한다.

한계로, 테스트 결과를 예비 분석에서 봤고, Unknown 근거(7건)가 적으며, 단일 보호소이고, 모델은 기존 기법 비교에 그쳤다. 예측은 개입 효과가 아니며, 시기 변화 반영과 외부 검증이 필요하다.

참 고 문 헌

[1] S. Parte, "Predicting of Hosting Animal Centre Outcome Based on Supervised Machine Learning Models", MSc Research Project, National College of Ireland, 2019.

[2] S.-E. Kim, J.-H. Choi, and M. Kang, "Adoption factor prediction to prevent euthanasia based on artificial intelligence", Korean Journal of Artificial Intelligence, 9(1), pp. 29-35, 2021.

[3] J. Bradley and S. Rajendran, "Increasing adoption rates at animal shelters: a two-phase approach to predict length of stay and optimal shelter allocation", BMC Veterinary Research, 17, 70, 2021.

[4] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science", Patterns, 4, 100804, 2023.

[5] D. R. Roberts et al., "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure", Ecography, 40(8), pp. 913-929, 2017.

[6] C. Bergmeir, R. J. Hyndman, and B. Koo, "A note on the validity of cross-validation for evaluating autoregressive time series prediction", Computational Statistics & Data Analysis, 120, pp. 70-83, 2018.