동물보호소 개·고양이 안락사 예측에서 평가 설계와 데이터 누수가 보고 성능에 미치는 영향

전건우*

Effects of Evaluation Design and Data Leakage on Reported Performance in Predicting Euthanasia of Shelter Dogs and Cats

Geon Woo Jeon*

요 약

입소 시점에 안락사 위험이 높은 동물을 알면 보호소는 그 동물에게 자원을 먼저 배정할 수 있지만, 기존 연구는 대부분 결과 유형을 다중분류해 정확도로 평가했고 평가 기간·분할 방식·기록 누수의 영향은 살피지 않았다. 미국 오스틴 동물보호센터의 개·고양이 90일 이내 안락사 예측으로 이를 살폈다. 첫째, 이전 공개판과 대조해 성별 'Unknown'처럼 결과에 따라 나중에 채워지는 기록을 찾았다. 둘째, 선행연구 방식을 재현하면 정확도는 0.675로 비슷했지만 안락사 재현율은 0.036에 그쳤다. 셋째, 같은 2024년 평가 대상에서는 학습 데이터를 시간 순으로 나누든 무작위로 나누든 평균 정밀도(AP) 차이를 확인하지 못했고(모두 0.108), 무작위 분할의 높은 수치(0.221)는 평가 기간·대상의 차이에서 온 것으로 보였다. 결과 확정 시점 기준으로 검증한 최종 모델은 입소의 32.4%를 검토해 90일 이내 안락사의 78.2%를 찾았으나 단순 규칙과의 차이는 확인되지 않았다. 보호소 예측 연구는 평가 기간과 지표를 명시하고 드문 결과의 탐지력을 직접 평가해야 한다.

Abstract

Identifying high-risk animals at intake would let shelters prioritize their care, but most previous studies classified outcome types by accuracy without examining how the evaluation period, data split, and record leakage affect reported performance. We examine these effects by predicting 90-day euthanasia of dogs and cats at the Austin Animal Center. First, by comparison with an earlier public release, we found records such as sex 'Unknown' that are filled in later depending on the outcome. Second, reproducing previous setups yielded a similar accuracy of 0.675 but a euthanasia recall of only 0.036. Third, on the same 2024 evaluation set, chronological and random training splits showed no detectable difference in average precision (AP; all 0.108), and the higher value under a random split (0.221) appeared to come from differences in the evaluation period and population. The final model, validated by the time outcomes were confirmed, found 78.2% of euthanasia cases within 90 days while reviewing 32.4% of intakes, but no difference from a simple rule was confirmed. Shelter prediction studies should state the evaluation period and metric and directly evaluate the detection of rare outcomes.

Key words

animal shelter, euthanasia prediction, evaluation design, data leakage, temporal validation, dataset shift

*소속, Email, **소속, Email(교신저자표시), ...

※ 지원기관표기(사사표기)

Ⅰ. 서 론

공공 동물보호소는 연간 수만 건의 입소를 제한된 의료·행동 교정·입양 연계 자원으로 처리하며, 관리 우선순위는 대개 실무자의 경험에 의존한다. 입소 시점에 위험이 높은 동물을 알면 그 동물을 먼저 돌볼 수 있어, 위험 예측은 동물 복지와 공공 서비스의 의사결정을 함께 돕는다.

미국 오스틴 동물보호센터의 공개 데이터를 쓴 선행 연구는 대부분 결과 유형을 다중분류해 정확도로 성능을 보고했고[1, 2], 여러 보호소 데이터를 쓴 연구도 무작위 분할로 평가했다[3]. 그러나 안락사는 전체 결과의 몇 퍼센트라 정확도로는 그 탐지력을 알기 어렵다. 또 보호소 결과는 입소 후 시간이 지나야 확정되므로 입소 연도로만 나누어도 선택에 쓰는 라벨 일부가 그 시점 이후에 확정되며(본 연구 이전 분석에서 검증 라벨의 7.19%), 공개 데이터에는 결과에 따라 나중에 채워지는 기록이 섞일 수 있다[4].

이에 본 연구는 개·고양이의 입소 후 90일 이내 안락사 예측을 사례로 '공개 행정 데이터로 보호소 결과를 예측할 때 무엇이 보고 성능을 운영 성능과 다르게 만드는가'를 묻는다. 이를 두 축으로 살핀다. 첫째, 결과에 따라 나중에 채워지는 기록(누수)이 있는지 이전 공개판과 대조해 점검한다. 둘째, 보고 성능이 분할 방식, 평가 기간, 평가 지표 중 무엇에 좌우되는지 분리한다. 아울러 최종 모델을 단순 기준선과 비교한다. 본 연구는 더 좋은 예측 모델을 제안하기보다, 운영 시점에 실제로 알 수 있었던 정보만으로 성능을 평가하는 방법을 제시하고 그 효과를 실제 데이터로 확인한다.

Ⅱ. 관련 연구

Parte[1]는 2013~2016년 약 2.6만 건을 80:20으로 무작위로 나누어 XGBoost로 정확도 65.33%를, Kim 등[2]은 상관 분석으로 고른 동물 종류, 입소 유형, 퇴소 시점 나이로 다중 로지스틱 회귀를 적합해 정확도 0.627, 매크로 재현율 0.255를 보고했는데, 퇴소 시점 나이는 입소 때는 알 수 없는 정보이다. Bradley와 Rajendran[3]은 여러 보호소의 114,256건으로 안락사를 포함한 체류기간 등급을 무작위 분할로 예측해 안락사 등급 F1 0.748을 보고했다. 세 연구는 평가 기간을 구분하지 않았고(Kim 등은 분할 방식을 명시하지 않음), 정확도·F1 중심으로 평가했으며, 기록이 언제 채워졌는지는 다루지 않았다.

Kapoor와 Narayanan[4]은 예측 시점에 알 수 없는 정보가 학습에 섞이는 누수를 재현성 위기의 한 원인으로 지적했다. Roberts 등[5]은 시간·공간 구조가 있는 데이터에서 무작위 교차검증이 오차를 과소추정할 수 있다며 블록 단위 검증을 권했지만, Bergmeir 등[6]은 오차 상관이 없으면 일반 k겹 교차검증도 타당함을 보였다. 본 연구는 이 문제들이 보호소 데이터의 보고 성능을 실제로 바꾸는지 실증한다.

Ⅲ. 연구 방법

3.1 데이터와 누수 점검

City of Austin 공개 데이터(data.austintexas.gov)의 입소 173,812건과 퇴소 173,775건(2013-10~2025-05)을 썼다. 입소와 퇴소는 동물 ID로 연결하되, 입소 뒤 다음 입소 전에 처음 나온 퇴소만 그 입소의 결과로 보았다. 대상은 개·고양이이며, 보호자가 안락사를 요청한 입소는 결과가 입소 때 정해지므로 제외했다. 입소·퇴소 기록의 이름은 100.0% 같았고 24시간 이내 안락사의 70.8%가 이름이 없어(24시간 초과 41.6%) 이름을 제외했다. 성별 'Unknown'은 세 근거로 결과 반영 신호로 판단했다. 첫째, 2021년 3월 공개판(Kaggle 'Animal Shelter Analytics') 작성 당시 보호소에 있던 입소의 Unknown은 7건 모두 이후 성별로 채워졌으나 이미 퇴소한 입소는 4,261건 중 2건만 바뀌었다. 둘째, 입소 기록의 Unknown 비율은 24시간 이내 안락사에서 17.3%, 24시간~90일 안락사에서 5.4%, 90일 초과 안락사에서 0.0%였다. 셋째, 성별 변수의 성능 향상은 Unknown 입소에서만 나타났다(4.1절). 따라서 성별·중성화 범주형 변수를 빼고, Unknown을 구별할 수 없게 만든 이진 변수(중성화됨 여부: Unknown을 0으로, 수컷 여부: Unknown을 무작위 배정)만 후보로 평가해 중성화됨

여부를 채택했다. 2021년 공개판은 점검에만 쓰고 학습에는 쓰지 않았다.

3.2 라벨과 시점 기준 분할

라벨은 입소 후 90일 이내 안락사이다(개·고양이 안락사의 97.5%가 90일 이내). 그림 1과 같이 12개월 선택 폴드 3개, 보정 구간, 2024년 테스트로 나누고, 각 구간의 학습 데이터는 '입소일+90일 ≤ 구간 시작'인 입소만 쓴다. 선택 폴드로는 모델만 고르고, 보정 구간(2022-10~2023-10)에서는 운영 임곗값(재현율 0.8 목표)만 정한다. 임곗값을 선택 폴드나 테스트에서 정하면 같은 데이터를 두 번 쓰게 되므로 별도 구간을 두었다. 테스트는 어떤 선택에도 쓰지 않으며, 평가 구간에서는 이전에 입소한 적이 있는 동물을 제외했다.



그림 1. 결과 확정 시점 기준 분할 구조
Fig. 1. Data split based on the time when labels are confirmed

3.3 모델 선택과 평가 지표

양성 비율이 2.2%로 낮아 정확도 대신 평균 정밀도(Average Precision, AP: 정밀도-재현율 곡선 아래 면적)와 기준선 대비 배수(AP ÷ 양성 비율)를 주 지표로 썼다. 입소 시점 특성 12개(동물 종류, 입소 유형, 건강상태, 품종군, 생애단계, 품종·색상, 나이, 입소 월, 혼종·다색·중성화 여부)로 로지스틱 회귀, 랜덤 포레스트, LightGBM, XGBoost, MLP를 기본값으로 비교한 뒤 상위 3개 계열을 같은 예산(계열마다 조합 9개, 지원하는 불균형 전략별)으로 튜닝하고, 3개 폴드 평균 AP가 가장 높은 조합을 골랐다. 신뢰구간은 동물 ID 단위 군집 부트스트랩(500회)으로 구했고, 비교 차이의 95% 신뢰구간이 0을 포함하면 '차이를 확인하지 못함'으로 쓰고 동등하다고 해석하지 않는다.

3.4 비교 실험 설계

평가 설계의 영향은 두 실험으로 본다. 실험 1(E1, 선행연구 방식 재현)은 최종 결과 5종을 최종 모델과 같은 특성으로 다중 로지스틱 회귀와 XGBoost로 분류하되 (i) 2013~16 무작위 80:20, (ii) 전 기간 무작위 80:20, (iii) 시간 분할(평가 2024년)로 평가해 정확도와 안락사 재현율을 본다. 실험 2(E2, 평가 대상 고정)는 2024년 테스트를 평가 대상으로 고정하고 학습 데이터만 시간 순(T1, ~2022-07 입소), 시간 순+최신(T2, ~2023-10 입소), 무작위(R1, T1과 같은 크기, 5회), 무작위 전체(R2)로 바꾼다. R1·R2는 테스트 동물을 뺀 2025-02까지의 입소(미래 포함)에서 뽑으므로 T2와 비교한다. 실험 3(E3, 단순 기준선)은 최종 모델이 단순한 방법보다 나은지 보기 위해 같은 검토량에서 로지스틱 회귀, 그리고 학습 없이 미리 정한 규칙과 비교한다. 규칙은 선행연구[2]처럼 소수 요인만 쓰되 입소 시점 정보로 한정해 건강상태(부상·질병 > 기타 비정상 > 정상), 같은 상태에서는 고령 순으로 위험을 매긴다.

IV. 실험 및 결과

4.1 이전 공개판 대조로 찾은 결과 반영 기록

성별·중성화 범주형을 넣으면 테스트 AP가 0.108에서 0.127로 높아졌지만(차이 +0.0187, 신뢰구간 하한 약 0), Unknown이 아닌 입소만 보면 차이가 +0.0012 [-0.008, 0.009]로 줄어 그 이득이 결과 반영 신호에서 왔음을 시사한다.

4.2 판정 방식이 바꾸는 탐지율 (E1)

그림 2(a)의 E1에서 정확도는 0.615(2013~16 무작위), 0.641(전 기간 무작위), 0.675(시간 분할)로 선행연구[1, 2]와 비슷했고 시간 분할에서 오히려 가장 높았다. 평가 기간의 안락사 비율이 5.2%, 2.7%, 2.3%로 낮아져 다수 결과를 맞히기 쉬워졌기 때문으로 보인다. 반면 최대 확률 클래스로 판정한 안락사 재현율은 0.286, 0.129, 0.036으로 떨어져, 정확도가 오를수록 드문 안락사는 덜 찾았다. 그런데 2024년 입소에서 다중분류 모델의 안락사 AP(0.110)는 최종 모델(0.108)과 비슷한 수준이었다(라벨: 최종 결과 대 90일 이내). 위험 순위 능력은 비슷해도 판

정 방식에 따라 탐지율이 3.6%와 78.2%(입소의 32.4% 검토)로 갈린 것이다.

4.3 무작위 평가가 보고하는 운영 성능 (E2)

그림 2(b)는 같은 이진 모델을 평가 방식만 바꿔 본 결과이다. 동물 단위 무작위 8:2 분할을 전 기간으로 평가하면 AP 0.221(기준선의 8.1배)로, 2024년 입소에 대한 시간 검증 결과(0.108, 4.9배)의 약 2배였다. 그러나 같은 무작위 분할도 평가를 2024년 입소로 좁히면 0.120 [0.067, 0.191]로 시간 검증에 가까워졌다(양성 46건으로 구간이 넓음).

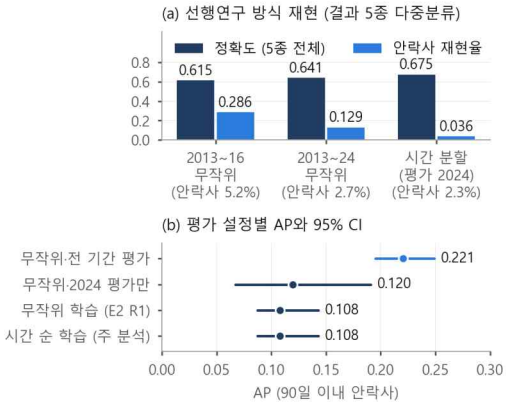


그림 2. 평가 설정별 보고 성능 ((a) E1, (b) AP와 95% CI)
Fig. 2. Reported performance by evaluation setting

표 1. 같은 2024년 평가 대상에서 학습 데이터만 바꾼 결과 (E2, *T2는 T1, R은 T2 대비)
Table 1. AP when only the training split changes (E2)

학습 데이터	AP [95% CI]	차이 [95% CI]*
T1 과거(~2022-07)	0.108 [0.087, 0.143]	기준
T2 과거(~2023-10)	0.108 [0.087, 0.145]	+0.0008 [-0.004, 0.005]
R1 무작위(T1 크기)	0.108 [0.087, 0.143]	-0.0009 [-0.004, 0.001]
R2 무작위(전체)	0.108 [0.087, 0.143]	-0.0009 [-0.004, 0.002]

표 1은 평가 대상(2024년 입소)을 고정하고 학습 데이터만 바꾼 E2 결과로, 분할 방식 자체가 성능을 바꾸는지 확인한다. 과거만 쓰든(T1), 최신 데이터를 더하든(T2), 미래 기록을 섞어 무작위로 뽑든(R1·R2) AP는 모두 0.108이었고 차이의 신뢰구간은 ±0.005 이내에서 0을 포함했다. 즉 무작위 평가의 높은 수치는 분할 방식이 아니라 평가 기간·대상의 차이(양성 비율 2.7% 대 2.2%)에서 온 것으로 보이며, 이는 조건에 따라 일반 교차검증도 타당할 수 있다는 관점[6]과 일치한다.

4.4 단순 기준선과의 비교 (E3)

최종 모델(XGBoost, 깊이 3, 트리 200개, 클래스 가중치; 계열 간 검증 차이의 신뢰구간은 0 포함)은 보정 구간 임곗값으로 2024년 입소의 32.4%를 선별하면 Recall 0.782, Precision 0.053이었다.

표 2. 2024년 테스트와 단순 기준선 (E3, *같은 검토량)
Table 2. 2024 test and simple baselines (E3, *same review volume)

방법	AP [95% CI]	배수	ROC-AUC	Recall*
최종(XGBoost)	0.108 [0.087, 0.143]	4.88	0.811	0.782
로지스틱 회귀	0.102 [0.082, 0.135]	4.63	0.803	0.777
규칙(상태·나이)	0.091 [0.071, 0.121]	4.11	0.773	0.756
무작위 선택	0.024 [0.020, 0.034]	1.09	0.508	0.332

표 2의 배수는 AP ÷ 양성 비율, Recall*은 최종 모델이 선별한 3,492건과 같은 수만 검토했을 때 찾은 안락사 비율이다. 최종 모델의 AP가 가장 높았지만 로지스틱 회귀(-0.0055 [-0.023, 0.013])·규칙(-0.0181 [-0.041, 0.001])과의 차이는 확인되지 않았고, 건강상태와 나이만 쓰는 규칙도 안락사의 75.6%를 찾았다.

V. 결 론

본 연구는 오스틴 보호소의 개·고양이 90일 이내 안락사 예측에서 보고 성능을 운영 성능과 다르게 만드는 요인을 실증했다. 성별 Unknown은 결과에 따라 나중에 채워지는 기록이었고, 선행연구 방식은 정확도가 비슷해도 안락사를 거의 찾지 못했으며(재현율 0.036), 무작위 평가가 보고한 약 2배의 성능은 분할 방식이 아니라 평가 기간에서 왔다. 최종 모델은 입소의 32.4% 검토로 안락사의 78.2%를 찾았으나 단순 규칙과의 차이는 확인되지 않았다. 따라서 보호소 예측은 미래 기간에서 검토량별 재현율과 AP로 평가하고 기록 시점을 점검해야 한다.

한계로, 테스트 기간을 이전 분석에서 본 적이 있고, Unknown 근거(7건)가 작으며, 단일 보호소 데이터이고, 모델은 기존 기법 비교에 그쳤으며, 예측은 개입 효과가 아니다. 향후 시기 변화를 반영한 학습과 외부 검증으로 확장한다.

참 고 문 헌

[1] S. Parte, "Predicting of Hosting Animal Centre Outcome Based on Supervised Machine Learning Models", MSc Research Project, National College of Ireland, 2019.

[2] S.-E. Kim, J.-H. Choi, and M. Kang, "Adoption factor prediction to prevent euthanasia based on artificial intelligence", Korean Journal of Artificial Intelligence, 9(1), pp. 29-35, 2021.

[3] J. Bradley and S. Rajendran, "Increasing adoption rates at animal shelters: a two-phase approach to predict length of stay and optimal shelter allocation", BMC Veterinary Research, 17, 70, 2021.

[4] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science", Patterns, 4, 100804, 2023.

[5] D. R. Roberts et al., "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure", Ecography, 40(8), pp. 913-929, 2017.

[6] C. Bergmeir, R. J. Hyndman, and B. Koo, "A note on the validity of cross-validation for evaluating autoregressive time series prediction", Computational Statistics & Data Analysis, 120, pp. 70-83, 2018.